

TRƯỜNG ĐẠI HỌC QUY NHƠN
KHOA TOÁN & THỐNG KÊ



TIỂU LUẬN MÔN HỌC:
PHÂN TÍCH DỮ LIỆU KHOA HỌC CHUYÊN NGÀNH

XÂY DỰNG VÀ SO SÁNH MÔ HÌNH
HỌC MÁY CẢNH BÁO SỚM
RỦI RO HỌC TẬP

Trình độ đào tạo: Thạc sĩ

Học viên thực hiện: Nguyễn Hồ Bảo Thiên

Mã số sinh viên: 8282548017

Lớp: Khoa học dữ liệu K28B

Giảng viên hướng dẫn: TS. Hồ Văn Lâm

Gia Lai, 2026

Mục lục

1	Giới thiệu	1
2	Tiền xử lý dữ liệu	1
2.1	Điền giá trị thiếu ở đặc trưng động	1
2.2	Xử lý giá trị thiếu ở imd_band	2
2.3	Mã hoá đặc trưng phân loại	2
2.4	Tập đặc trưng cuối cùng	3
2.5	Chuẩn hoá bài toán về phân loại nhị phân	3
3	Khảo sát sơ bộ theo các mốc dự đoán	3
3.1	Thiết lập thử nghiệm	4
3.2	Kết quả theo thời gian	4
3.3	Lựa chọn mốc dự đoán cho phân tích chuyên sâu	7
4	Phương pháp xây dựng mô hình	8
4.1	Các thuật toán sử dụng	8
4.2	Xử lý mất cân bằng nhãn	8
4.3	Thiết lập thực nghiệm	9
5	Kết quả trên bộ đặc trưng đầy đủ	9
6	Độ quan trọng của đặc trưng	12
7	Rút gọn đặc trưng: Top-10 và Top-5	13
8	Hiệu chỉnh ngưỡng và độ tin cậy của kết quả	15
8.1	Hiệu chỉnh ngưỡng phân loại	15
8.2	Khoảng tin cậy bootstrap của các chỉ số	17
9	Diễn giải mô hình bằng SHAP	19
9.1	Biểu đồ tổng quan (beeswarm và mean SHAP)	19
9.2	Diễn giải cục bộ: hai trường hợp minh hoạ	21
10	Kết luận	22

Danh sách hình vẽ

1	Xu hướng hiệu suất mô hình theo từng mốc dự đoán (mỗi mốc một mô hình riêng).	5
2	Ma trận nhầm lẫn trên tập kiểm tra tại từng mốc dự đoán. . .	6
3	Ma trận nhầm lẫn trên tập kiểm tra — bộ đặc trưng đầy đủ, tại mốc 150 ngày.	11
4	Độ quan trọng đặc trưng (theo định nghĩa riêng của từng mô hình) tại mốc 150 ngày.	12
5	Precision, recall và F1 của lớp At-risk theo ngưỡng phân loại. .	15
6	Ma trận nhầm lẫn trên tập kiểm tra tại bốn mức ngưỡng. . . .	16
7	Phân phối bootstrap của năm chỉ số đánh giá; đường liền là ước lượng điểm, hai đường đứt là biên khoảng tin cậy 95%.	18
8	Diễn giải SHAP của CatBoost trên bộ đặc trưng đầy đủ (15 đặc trưng).	19
9	Diễn giải SHAP của CatBoost trên bộ đặc trưng Top-10.	20
10	Diễn giải SHAP của CatBoost trên bộ đặc trưng Top-5.	20
11	Diễn giải cục bộ (waterfall) cho hai sinh viên đại diện.	21

Danh sách bảng

1	Phương án mã hoá các đặc trưng phân loại.	2
2	Kết quả sơ bộ của mô hình Logistic Regression — một mô hình riêng cho mỗi mốc dự đoán T — trên tập kiểm tra. Precision/Recall/F1 tính riêng cho lớp At-risk.	5
3	Siêu tham số xử lý mất cân bằng nhãn được Optuna lựa chọn cho từng mốc dự đoán, cùng F1 At-risk trung bình qua 3-fold cross-validation.	7
4	Quy mô và phân phối nhãn nhị phân tại mốc dự đoán 150 ngày, sau khi gộp Fail và Withdrawn thành At-risk.	8
5	So sánh các mô hình trên bộ 15 đặc trưng đầy đủ tại mốc 150 ngày. Chỉ số Precision/Recall/F1 tính riêng cho lớp At-risk . . .	10
6	Thứ hạng độ quan trọng của từng đặc trưng theo mỗi mô hình (1 = quan trọng nhất) và hạng trung bình, sắp xếp tăng dần theo hạng trung bình.	12

7	Hiệu suất của CatBoost — mô hình tốt nhất ở bước so sánh thuật toán — trên ba bộ đặc trưng tại mốc 150 ngày. Chỉ số Precision/Recall/F1 tính riêng cho lớp At-risk	14
8	Ảnh hưởng của ngưỡng phân loại lên kết quả dự báo của CatBoost tại mốc 150 ngày. Tập kiểm tra có 1,559 sinh viên At-risk thực tế; hàng in đậm là ngưỡng mặc định.	16
9	Ngưỡng cần dùng để đạt các mức recall mục tiêu, và cái giá phải trả. Cột “Bắt thêm” và “Nhầm thêm” so với ngưỡng mặc định 0.5; cột cuối là số cảnh báo nhằm phát sinh trên mỗi sinh viên At-risk bắt thêm được.	17
10	Khoảng tin cậy 95% của các chỉ số đánh giá, ước lượng bằng bootstrap trên tập kiểm tra ($B = 2,000$ lần lấy mẫu có hoàn lại) tại ngưỡng mặc định 0.5.	18

1 Giới thiệu

Báo cáo này trình bày giai đoạn *xây dựng và so sánh mô hình học máy* cho bài toán cảnh báo sớm rủi ro học tập, kế thừa trực tiếp kết quả của giai đoạn phân tích khám phá dữ liệu (EDA) trước đó. Bài toán được xác định lại ở dạng **phân loại nhị phân**: nhận diện sinh viên **có nguy cơ** (At-risk) — gộp từ hai nhóm kết quả trượt môn (Fail) và bỏ học (Withdrawn) — so với nhóm **hoàn thành** (Pass), dựa trên đặc trưng nhân khẩu học và hành vi học tập tích lũy đến một mốc thời gian xác định trong khoá học.

Nội dung báo cáo gồm bốn phần chính:

1. **Tiền xử lý dữ liệu**: điền giá trị thiếu, mã hoá đặc trưng phân loại, gộp nhãn và chuẩn hoá bài toán về dạng nhị phân.
2. **Khảo sát sơ bộ theo các mốc dự đoán**: huấn luyện một mô hình cơ sở xuyên suốt toàn bộ các mốc thời gian trong khoá học để hiểu xu hướng hiệu suất theo thời gian, làm cơ sở lựa chọn mốc dự đoán cho các thử nghiệm chuyên sâu.
3. **Xây dựng mô hình**: huấn luyện và tinh chỉnh bốn thuật toán học máy (Logistic Regression, Random Forest, CatBoost, LightGBM) kết hợp kỹ thuật xử lý mất cân bằng nhãn, tập trung vào mốc thời gian đã chọn.
4. **So sánh và diễn giải mô hình**: đối chiếu hiệu suất giữa các thuật toán, đánh giá độ ổn định khi rút gọn số lượng đặc trưng, và diễn giải các dự báo bằng phương pháp SHAP.

2 Tiền xử lý dữ liệu

2.1 Điền giá trị thiếu ở đặc trưng động

Các đặc trưng phản ánh hành vi học tập tích lũy (tương tác với hệ thống học trực tuyến và kết quả bài đánh giá) có giá trị thiếu ở những sinh viên chưa từng tương tác hoặc chưa nộp bài nào tính đến mốc thời gian quan sát. Quy tắc điền khuyết được áp dụng riêng cho từng nhóm đặc trưng:

- **Đặc trưng tương tác VLE** (`total_clicks`, `active_weeks`, `avg_weekly_clicks`) và **đặc trưng bài đánh giá** (`num_submitted`, `num_failed`) — điền

bằng 0, vì giá trị thiếu ở đây đồng nghĩa với việc sinh viên chưa phát sinh hoạt động nào.

- `avg_score` — điền bằng giá trị **-1** (nằm ngoài thang điểm $[0, 100]$) để phân biệt rõ ràng với trường hợp sinh viên nộp bài và bị điểm 0.
- `avg_days_early` — điền bằng 0; thông tin về việc sinh viên không nộp bài dù đã đến hạn đã được nắm bắt riêng bởi đặc trưng nhị phân `no_submission_despite_due`, nên việc điền 0 ở đây không gây nhầm lẫn.

Sau bước điền khuyết, toàn bộ đặc trưng động không còn giá trị thiếu.

2.2 Xử lý giá trị thiếu ở `imd_band`

Như đã trình bày ở giai đoạn phân tích khám phá, biến `imd_band` (chỉ số thiếu thốn kinh tế theo khu vực) có một dạng thiếu riêng biệt, được mã hoá bằng ký hiệu '?' thay vì giá trị rỗng thông thường. Một biến chỉ báo `imd_missing` được tạo trước khi điền khuyết, để mô hình có thể tận dụng chính tín hiệu “thiếu dữ liệu” như một đặc trưng dự báo.

Giá trị thiếu được điền theo **phân phối riêng của từng vùng** (`region`), ước lượng trên tập huấn luyện rồi áp dụng lại cho tập kiểm tra. Sau bước xử lý, biến `imd_band_filled` không còn giá trị thiếu ở cả hai tập huấn luyện và kiểm tra.

2.3 Mã hoá đặc trưng phân loại

Các đặc trưng phân loại được mã hoá theo bản chất của từng biến, tóm tắt ở Bảng 1.

Bảng 1: Phương án mã hoá các đặc trưng phân loại.

Đặc trưng	Kiểu mã hoá	Lý do
<code>disability</code>	Nhị phân	$Y \rightarrow 1, N \rightarrow 0$
<code>highest_education</code>	Thứ tự (ordinal)	Có thứ bậc học vấn rõ ràng
<code>imd_band_filled</code>	Thứ tự (ordinal)	Có thứ bậc mức độ nghèo

Ba đặc trưng nhân khẩu học còn lại từ dữ liệu gốc — `gender`, `region`, `age_band` — không được đưa vào ma trận đặc trưng huấn luyện. Các đặc trưng nhân khẩu học được giữ lại (`highest_education`, `disability`, `imd_band_filled`) là

những đặc trưng đã cho thấy liên hệ rõ ràng với kết quả học tập ở giai đoạn phân tích khám phá dữ liệu trước đó.

2.4 Tập đặc trưng cuối cùng

Sau các bước xử lý trên, ma trận đặc trưng dùng cho huấn luyện mô hình gồm **15 đặc trưng**:

- **Tĩnh (5)**: `highest_education`, `disability`, `num_of_prev_attempts`, `studied_credits`, `imd_band_filled`, cùng biến chỉ báo `imd_missing`.
- **Động (9)**: `total_clicks_filled`, `active_weeks_filled`, `avg_weekly_clicks_filled`, `num_due`, `num_submitted_filled`, `avg_score_filled`, `num_failed_filled`, `avg_days_early_filled`, `no_submission_despite_due`.

Việc chia tập huấn luyện và kiểm tra được giữ nguyên theo **từng sinh viên** như đã thiết lập ở giai đoạn EDA (tỷ lệ 80:20), đảm bảo không xảy ra rò rỉ dữ liệu giữa hai tập.

2.5 Chuẩn hoá bài toán về phân loại nhị phân

Với mục tiêu cảnh báo sớm, ranh giới quan trọng nhất không nằm giữa Fail và Withdrawn, mà giữa nhóm **hoàn thành** và nhóm **không hoàn thành** học phần. Do đó, nhãn mục tiêu được chuẩn hoá lại:

$$\text{At-risk (1)} = \text{Fail} \cup \text{Withdrawn}, \quad \text{Pass (0)} = \text{Pass}.$$

Phép gộp nhãn này được áp dụng thống nhất cho toàn bộ dữ liệu dạng panel, tức trên mọi bản ghi ở cả tám mốc dự đoán $T \in \{30, 60, \dots, 240\}$ đã thiết kế ở giai đoạn EDA — không giới hạn ở một mốc thời gian cụ thể nào. Với dữ liệu đã ở dạng nhị phân, câu hỏi tiếp theo là mốc dự đoán nào nên được chọn để huấn luyện và đánh giá mô hình; đây là nội dung được khảo sát ở phần kế tiếp.

3 Khảo sát sơ bộ theo các mốc dự đoán

Trước khi đi sâu so sánh nhiều thuật toán tại một mốc thời gian cố định, cần khảo sát sơ bộ hiệu suất mô hình học máy **xuyên suốt toàn bộ các mốc dự đoán** đã thiết kế ở giai đoạn tiền xử lý, nhằm hai mục đích: (i) hiểu xu hướng

biến động hiệu suất theo thời gian khi sinh viên tích lũy ngày càng nhiều hành vi học tập, và (ii) làm cơ sở lựa chọn một mốc thời gian đại diện, phù hợp cho các thử nghiệm chuyên sâu ở phần sau.

3.1 Thiết lập thử nghiệm

Với mỗi mốc dự đoán T , một mô hình **Logistic Regression** được huấn luyện riêng, chỉ sử dụng dữ liệu của đúng mốc đó — đây cũng là thuật toán cơ sở, đơn giản và dễ diễn giải nhất trong bốn thuật toán được đề xuất ở giai đoạn EDA, phù hợp để khảo sát nhanh xu hướng hiệu suất theo thời gian trước khi mở rộng sang các mô hình phức tạp hơn. Quy trình tinh chỉnh áp dụng cho từng mô hình tương tự cách tiếp cận sẽ được dùng ở giai đoạn so sánh nhiều thuật toán tại Mục 4: dữ liệu được chuẩn hoá bằng **StandardScaler** (fit trên train-fold, tránh rò rỉ dữ liệu), siêu tham số điều chuẩn C của mô hình, tỷ lệ oversampling SMOTE và trọng số lớp At-risk được tinh chỉnh đồng thời bằng Optuna (30 lượt thử nghiệm, kiểm định chéo phân tầng 3-fold), sau đó huấn luyện lại trên toàn bộ tập huấn luyện của mốc đó và đánh giá trên tập kiểm tra giữ nguyên.

Một lưu ý về mặt phương pháp: ở lần thử đầu tiên, hàm mục tiêu tối ưu là *recall thuần* của lớp At-risk, nhưng cách làm này khiến mô hình suy biến về việc dự đoán **toàn bộ** sinh viên đều là At-risk (recall đạt gần tuyệt đối nhưng precision rất thấp, không có giá trị thực tiễn). Hàm mục tiêu sau đó được đổi sang **F1-score của lớp At-risk** để buộc mô hình cân bằng giữa precision và recall — đây là hàm mục tiêu được giữ nguyên xuyên suốt các thử nghiệm còn lại của báo cáo.


3.2 Kết quả theo thời gian

Bảng 2 tổng hợp hiệu suất trên tập kiểm tra của tám mô hình, mỗi mô hình ứng với một mốc dự đoán.

Bảng 2: Kết quả sơ bộ của mô hình Logistic Regression — một mô hình riêng cho mỗi mốc dự đoán T — trên tập kiểm tra. Precision/Recall/F1 tính riêng cho lớp At-risk.

T (ngày)	Train	Test	Accuracy	Precision	Recall	F1
30	19,988	5,043	0.6488	0.5750	0.8013	0.6695
60	19,123	4,835	0.7231	0.6429	0.7666	0.6993
90	18,508	4,680	0.7402	0.6442	0.7857	0.7080
120	17,917	4,518	0.7915	0.7123	0.7555	0.7333
150	17,386	4,363	0.8263	0.7524	0.7659	0.7591
180	16,786	4,215	0.8451	0.7533	0.7987	0.7754
210	16,486	4,162	0.8659	0.7976	0.7894	0.7935
240	16,190	4,094	0.8796	0.8269	0.7814	0.8035

Hình 1 trực quan hoá xu hướng của bốn chỉ số theo mốc thời gian.




Hình 1: Xu hướng hiệu suất mô hình theo từng mốc dự đoán (mỗi mốc một mô hình riêng).

- **Accuracy** và **precision At-risk** tăng **đơn điệu tuyệt đối** theo thời gian — không có mốc nào sụt giảm so với mốc liền trước (accuracy từ 0.6488 ở $T = 30$ lên 0.8796 ở $T = 240$; precision từ 0.5750 lên 0.8269) — phù hợp với trực giác: sinh viên càng tích lũy nhiều hành vi học tập, tín hiệu dự báo càng rõ ràng và đáng tin cậy hơn.
- **Recall At-risk** lại dao động trong một biên độ hẹp (0.7555–0.8013) mà không theo xu hướng rõ ràng, thậm chí đạt giá trị cao nhất ngay ở mốc sớm nhất

$T = 30$ (0.8013) — khi độ chính xác tổng thể còn rất thấp (accuracy 0.6488, precision 0.5750). Điều này cho thấy ở giai đoạn đầu khoá, khi tín hiệu hành vi còn thừa thớt, ranh giới tuyến tính của Logistic Regression có xu hướng dự báo At-risk khá rộng rãi — bắt được phần lớn sinh viên có nguy cơ nhưng đánh đổi bằng rất nhiều cảnh báo nhầm.

- **F1 At-risk** — chỉ số tổng hợp được dùng làm mục tiêu tối ưu — vì vậy cũng tăng đơn điệu tuyệt đối theo thời gian, từ 0.6695 ($T = 30$) lên 0.8035 ($T = 240$), nhưng động lực tăng chủ yếu đến từ **precision** chứ không phải recall, vốn gần như đi ngang xuyên suốt khoá học.

Mã trận nhầm lẫn của cả tám mô hình được thể hiện ở Hình 2.



Hình 2: Mã trận nhầm lẫn trên tập kiểm tra tại từng mốc dự đoán.

Bảng 3 cho thấy siêu tham số xử lý mất cân bằng nhãn mà Optuna lựa chọn theo từng mốc thời gian.

Bảng 3: Siêu tham số xử lý mất cân bằng nhãn được Optuna lựa chọn cho từng mốc dự đoán, cùng F1 At-risk trung bình qua 3-fold cross-validation.

T (ngày)	F1 At-risk (CV)	Tỷ lệ SMOTE	Trọng số At-risk
30	0.6734	+0.67x	1.12
60	0.7065	+0.56x	1.24
90	0.7160	+0.57x	1.33
120	0.7486	+0.69x	1.01
150	0.7767	+0.55x	1.05
180	0.7918	+0.90x	1.01
210	0.8047	+0.51x	1.03
240	0.8182	+0.42x	1.01

Trọng số At-risk tối ưu hầu như luôn hội tụ gần giá trị 1 (1.01–1.33) ở mọi mốc thời gian, trong khi tỷ lệ SMOTE dao động ở mức khá cao và không theo xu hướng rõ rệt (0.42–0.90x). Nói cách khác, với Logistic Regression, việc bổ sung mẫu tổng hợp qua SMOTE đóng vai trò chủ đạo trong xử lý mất cân bằng nhãn, hơn là điều chỉnh trọng số lớp — đây là đặc điểm nhất quán của thuật toán này xuyên suốt mọi mốc thời gian khảo sát.

3.3 Lựa chọn mốc dự đoán cho phân tích chuyên sâu

Kết quả khảo sát cho thấy một sự đánh đổi rõ ràng giữa **độ tin cậy của dự báo** và **thời gian còn lại để can thiệp**: các mốc càng muộn cho hiệu suất càng cao, nhưng đồng thời càng gần thời điểm kết thúc khoá học, làm giảm giá trị thực tiễn của một cảnh báo sớm. Với khoá học OULAD kéo dài khoảng 240–270 ngày, hai mốc cho F1 cao nhất — 210 và 240 ngày, lần lượt 0.7935 và 0.8035 — chỉ còn lại khoảng 10–20% thời lượng khoá học, quá muộn để nhà trường triển khai các biện pháp hỗ trợ có ý nghĩa.

Mốc **150 ngày** được chọn làm đại diện cho các thử nghiệm chuyên sâu ở phần còn lại của báo cáo, vì đạt được điểm cân bằng hợp lý nhất giữa hai yêu cầu trên. Về hiệu suất, mốc này đã cho kết quả khá cao (accuracy 0.8263, F1 At-risk 0.7591) và chỉ thấp hơn khoảng 0.016 so với mốc 180 ngày liền sau — một khoảng cách nhỏ so với lợi ích thu được về mặt thời gian. Về khả năng

can thiệp, cảnh báo phát ra ở ngày thứ 150 vẫn còn khoảng 90–120 ngày, tương đương 37–50% thời lượng khoá học, đủ để nhà trường tổ chức các hoạt động hỗ trợ có chiều sâu thay vì chỉ nhắc nhở gấp rút ở giai đoạn cuối.

Bảng 4 tóm tắt quy mô và phân phối nhãn tại mốc 150 ngày sau khi gộp nhãn, được dùng thống nhất cho toàn bộ các thử nghiệm từ Mục 4 trở đi.

Bảng 4: Quy mô và phân phối nhãn nhị phân tại mốc dự đoán 150 ngày, sau khi gộp Fail và Withdrawn thành At-risk.

Tập		Pass	At-risk	Tổng
Train	11,067 (63.7%)	6,319 (36.3%)	17,386	
Test	2,804 (64.3%)	1,559 (35.7%)	4,363	

Tỷ lệ At-risk chiếm khoảng **36%** tổng số sinh viên ở cả hai tập, tương đồng giữa train và test — xác nhận việc chia dữ liệu theo sinh viên không gây lệch phân phối nhãn. Đây vẫn là một bài toán **mất cân bằng nhãn vừa phải**, cần được xử lý ở bước huấn luyện mô hình.

4 Phương pháp xây dựng mô hình

Kế thừa kết luận ở Mục 3.3, các thử nghiệm từ đây trở đi tập trung vào mốc 150 ngày, mở rộng từ một mô hình cơ sở duy nhất (đã dùng để khảo sát xu hướng theo thời gian ở Mục 3) sang so sánh trực tiếp **bốn thuật toán học máy** khác nhau.

4.1 Các thuật toán sử dụng

Bốn thuật toán được đề xuất từ giai đoạn EDA — Logistic Regression, Random Forest, CatBoost và LightGBM — được đưa vào huấn luyện và so sánh trực tiếp. Thuật toán **SVM (kernel RBF)** được loại khỏi phạm vi thử nghiệm do độ phức tạp huấn luyện tăng theo bậc hai với số lượng mẫu, không khả thi với quy mô dữ liệu ở mốc 150 ngày (hơn 17 nghìn bản ghi huấn luyện) trong khuôn khổ tài nguyên tính toán của nghiên cứu.

4.2 Xử lý mất cân bằng nhãn

Hai kỹ thuật được kết hợp đồng thời để xử lý mất cân bằng nhãn:

- **SMOTE** (Synthetic Minority Over-sampling Technique): sinh thêm mẫu tổng hợp cho lớp At-risk, với tỷ lệ oversampling là một siêu tham số được tinh chỉnh riêng cho từng mô hình.
- **Trọng số lớp** (`class_weight`): tăng chi phí phân loại sai đối với lớp At-risk trong hàm mất mát của mô hình, cũng được tinh chỉnh như một siêu tham số.

Để tránh rò rỉ dữ liệu, **SMOTE chỉ được áp dụng trên từng fold huấn luyện** trong quá trình kiểm định chéo, không áp dụng lên fold kiểm định. Tương tự, với Logistic Regression — mô hình duy nhất cần chuẩn hoá dữ liệu số (`StandardScaler`) — bước chuẩn hoá cũng chỉ được ước lượng (fit) trên fold huấn luyện.

4.3 Thiết lập thực nghiệm

Với mỗi mô hình, siêu tham số của thuật toán được tinh chỉnh **đồng thời** với tỷ lệ SMOTE và trọng số lớp At-risk, thông qua khung tối ưu Bayesian **Optuna** (thuật toán lấy mẫu TPE), với 30 lượt thử nghiệm cho mỗi mô hình. Hàm mục tiêu được tối ưu là **F1-score của lớp At-risk**, đánh giá qua kiểm định chéo phân tầng 3-fold (`StratifiedKFold`) nhằm giữ nguyên tỷ lệ lớp ở mỗi fold. Sau khi xác định bộ siêu tham số tốt nhất, mô hình được huấn luyện lại trên toàn bộ tập huấn luyện và đánh giá lần cuối trên tập kiểm tra giữ nguyên (holdout), độc lập hoàn toàn với quá trình tinh chỉnh.

Các chỉ số đánh giá trên tập kiểm tra gồm: accuracy, precision, recall, F1 (tính riêng cho lớp At-risk) và ROC-AUC.

5 Kết quả trên bộ đặc trưng đầy đủ


Bảng 5 tổng hợp hiệu suất của bốn mô hình trên tập kiểm tra, sử dụng đầy đủ 15 đặc trưng.

Bảng 5: So sánh các mô hình trên bộ 15 đặc trưng đầy đủ tại mốc 150 ngày. Chỉ số Precision/Recall/F1 tính riêng cho lớp **At-risk**.

Model	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.8263	0.7524	0.7659	0.7591	0.8972
Random Forest	0.8435	0.7804	0.7819	0.7812	0.9076
CatBoost	0.8501	0.8055	0.7652	0.7849	0.9114
LightGBM	0.8455	0.7868	0.7787	0.7827	0.9116

- **CatBoost** dẫn đầu ở ba chỉ số: accuracy (0.8501), precision At-risk (0.8055) và F1 At-risk (0.7849) — mô hình cho cảnh báo đáng tin cậy nhất, đồng thời cân bằng tốt nhất giữa precision và recall.
- **LightGBM** đạt ROC-AUC cao nhất (0.9116), nhưng chênh lệch so với CatBoost (0.9114) là không đáng kể; F1 At-risk của mô hình này (0.7827) cũng chỉ thấp hơn CatBoost khoảng 0.002.
- **Random Forest** có recall At-risk cao nhất (0.7819), tức bỏ sót ít sinh viên có nguy cơ nhất, nhưng đánh đổi bằng precision thấp hơn CatBoost. Nhìn chung ba mô hình cây cho kết quả rất sát nhau (F1 nằm trong khoảng hẹp 0.7812–0.7849), không mô hình nào vượt trội hẳn.
- **Logistic Regression** có hiệu suất thấp nhất ở mọi chỉ số, phù hợp với kỳ vọng đặt ra từ giai đoạn EDA: dữ liệu tồn tại quan hệ phi tuyến và đa cộng tuyến giữa các đặc trưng hành vi trực tuyến, là những đặc điểm mà mô hình tuyến tính khó nắm bắt đầy đủ.

Ma trận nhầm lẫn (confusion matrix) của từng mô hình trên tập kiểm tra được thể hiện ở Hình 3.




Hình 3: Ma trận nhầm lẫn trên tập kiểm tra — bộ đặc trưng đầy đủ, tại mốc 150 ngày.

Nhìn chung, phần lớn sai số của cả bốn mô hình đều nằm ở việc **bỏ sót sinh viên At-risk** (dự báo Pass trong khi thực tế At-risk) nhiều hơn là cảnh báo nhầm (dự báo At-risk trong khi thực tế Pass). Đây là điểm cần lưu ý khi triển khai thực tế: có thể cân nhắc hạ ngưỡng phân loại để tăng recall, chấp nhận đánh đổi thêm một số cảnh báo nhầm nhằm giảm thiểu rủi ro bỏ sót sinh viên cần hỗ trợ.

6 Độ quan trọng của đặc trưng

Hình 4 thể hiện độ quan trọng đặc trưng theo định nghĩa riêng của từng thuật toán (hệ số hồi quy tuyệt đối với Logistic Regression, độ giảm tạp chất Gini với Random Forest, PredictionValuesChange với CatBoost, và số lần được dùng để phân tách với LightGBM) — các giá trị này **không cùng đơn vị** nên chỉ so sánh được thứ hạng, không so sánh trực tiếp độ lớn giữa các mô hình.



Hình 4: Độ quan trọng đặc trưng (theo định nghĩa riêng của từng mô hình) tại mốc 150 ngày.

Để tổng hợp một thứ hạng chung, mỗi đặc trưng được xếp hạng riêng trong từng mô hình rồi lấy trung bình cộng bốn hạng. Bảng 6 trình bày kết quả, sắp xếp tăng dần theo hạng trung bình.

Bảng 6: Thứ hạng độ quan trọng của từng đặc trưng theo mỗi mô hình (1 = quan trọng nhất) và hạng trung bình, sắp xếp tăng dần theo hạng trung bình.

Đặc trưng	LogReg	RF	CatBoost	LightGBM	Hạng TB
num_submitted_filled	1	2	1	2	1.50
avg_score_filled	4	1	4	1	2.50
num_due	5	7	3	5	5.00
active_weeks_filled	9	3	5	3	5.00
total_clicks_filled	2	4	11	6	5.75
avg_days_early_filled	8	5	8	3	6.00
highest_education	7	8	2	9	6.50
avg_weekly_clicks_filled	3	6	12	7	7.00
imd_band_filled	11	10	7	8	9.00
num_failed_filled	10	9	9	12	10.00
num_of_prev_attempts	13	12	6	10	10.25
no_submission_despite_due	6	13	15	15	12.25
studied_credits	15	11	13	11	12.50
disability	14	14	10	14	13.00
imd_missing	12	15	14	13	13.50

- **Nhóm dẫn đầu** — `num_submitted_filled` (số bài đã nộp) đứng hạng 1 ở Logistic Regression và CatBoost, hạng 2 ở Random Forest và LightGBM (hạng trung bình 1.50), khẳng định đây là tín hiệu dự báo mạnh và nhất quán nhất. Theo sau là `avg_score_filled` (điểm trung bình, hạng trung bình 2.50 — dẫn đầu ở Random Forest và LightGBM), rồi đến `num_due` (số bài đến hạn) và `active_weeks_filled` (số tuần hoạt động) cùng ở hạng trung bình 5.00. Cả bốn đều là đặc trưng **động**, phản ánh trực tiếp mức độ tham gia và kết quả học tập tích lũy.
- **Nhóm giữa** gồm các đặc trưng tương tác VLE còn lại (`total_clicks_filled`, `avg_weekly_clicks_filled`), `avg_days_early_filled` và `highest_education` — đóng góp bổ sung nhưng không mang tính quyết định.
- **Nhóm cuối** — `studied_credits`, `disability`, `imd_missing` có hạng trung bình cao nhất (ít quan trọng nhất), cho thấy các đặc trưng tĩnh mang tính nhân khẩu học có vai trò dự báo khiêm tốn hơn nhiều so với các đặc trưng hành vi động.

7 Rút gọn đặc trưng: Top-10 và Top-5

Dựa trên thứ hạng ở Bảng 6, mười đặc trưng quan trọng nhất (Top-10) và năm đặc trưng quan trọng nhất (Top-5) được chọn ra để huấn luyện lại theo đúng quy trình tinh chỉnh đã mô tả ở Mục 3, nhằm kiểm tra hiệu suất mô hình có **ổn định** hay không khi giảm số lượng đặc trưng đầu vào — một yếu tố quan trọng khi triển khai hệ thống cảnh báo thực tế, nơi việc thu thập và duy trì ít đặc trưng hơn giúp đơn giản hoá quy trình vận hành.

Phân tích ở phần này chỉ tập trung vào **CatBoost**, mô hình đạt hiệu suất tốt nhất ở bước so sánh thuật toán. Việc thu hẹp về một mô hình duy nhất giúp câu hỏi trở nên rõ ràng: *với mô hình sẽ được đưa vào triển khai, có thể cắt bớt bao nhiêu đặc trưng mà hiệu suất vẫn giữ nguyên?* Bảng 7 đặt cạnh nhau kết quả của CatBoost trên cả ba bộ đặc trưng.

Bảng 7: Hiệu suất của CatBoost — mô hình tốt nhất ở bước so sánh thuật toán — trên ba bộ đặc trưng tại mốc 150 ngày. Chỉ số Precision/Recall/F1 tính riêng cho lớp **At-risk**.

Bộ đặc trưng	Số đặc trưng	Accuracy	Precision	Recall	F1	ROC-AUC
Full (15)	15	0.8501	0.8055	0.7652	0.7849	0.9114
Top-10	10	0.8501	0.7979	0.7774	0.7875	0.9119
Top-5	5	0.8462	0.7910	0.7742	0.7825	0.9088

- Hiệu suất **gần như không đổi** qua cả ba bộ đặc trưng: F1 At-risk chỉ dao động trong khoảng 0.7825–0.7875, tức biên độ vón vện 0.005; accuracy cũng chỉ chênh 0.004. Điều này khẳng định kết luận ở phần độ quan trọng đặc trưng: phần lớn sức mạnh dự báo tập trung ở một nhóm nhỏ đặc trưng hành vi động.
- Đáng chú ý, bộ **Top-10 còn nhỉnh hơn cả bộ đầy đủ** ở ba trên năm chỉ số — F1 (0.7875 so với 0.7849), recall (0.7774 so với 0.7652) và ROC-AUC (0.9119 so với 0.9114) — trong khi dùng ít hơn một phần ba số đặc trưng. Việc loại bỏ năm đặc trưng kém quan trọng nhất không những không gây thiệt hại mà còn giúp mô hình bắt được nhiều sinh viên có nguy cơ hơn, dấu hiệu cho thấy nhóm đặc trưng bị loại chủ yếu đóng vai trò gây nhiễu.
- Khi cắt tiếp xuống **Top-5**, hiệu suất mới bắt đầu giảm nhẹ nhưng vẫn ở mức không đáng kể: F1 thấp hơn bộ đầy đủ đúng 0.0024 và thấp hơn Top-10 0.0050. Đổi lại, số đặc trưng cần thu thập giảm từ 15 xuống 5.
- Xu hướng chung khi giảm đặc trưng là **precision giảm, recall tăng**: precision đi từ 0.8055 (Full) xuống 0.7910 (Top-5) trong khi recall nhích từ 0.7652 lên 0.7742. Với bài toán cảnh báo sớm, đây là hướng đánh đổi có lợi, vì bỏ sót một sinh viên cần hỗ trợ tốn kém hơn một cảnh báo nhầm.

Tổng hợp lại, **bộ Top-5 là lựa chọn hợp lý cho triển khai thực tế**: chỉ cần năm đặc trưng — `num_submitted_filled`, `avg_score_filled`, `num_due`, `active_weeks_filled`, `total_clicks_filled`, toàn bộ đều là hành vi học tập và không yêu cầu thông tin nhân khẩu học — mà vẫn giữ được gần như trọn vẹn hiệu suất của mô hình dùng đủ 15 đặc trưng. Nếu ưu tiên hiệu suất cao nhất và chấp nhận thu thập nhiều dữ liệu hơn thì Top-10 là phương án tốt nhất.


8 Hiệu chỉnh ngưỡng và độ tin cậy của kết quả

Hai phân tích trong phần này bổ sung cho các kết quả đã trình bày, đều thực hiện trên **CatBoost** với bộ 15 đặc trưng đầy đủ — cấu hình đã cho hiệu suất tốt nhất ở bước so sánh thuật toán. Phân tích thứ nhất trả lời câu hỏi vận hành: có thể bắt thêm bao nhiêu sinh viên có nguy cơ nếu chấp nhận thêm cảnh báo nhầm. Phân tích thứ hai trả lời câu hỏi phương pháp: các con số hiệu suất trong báo cáo đáng tin đến mức nào.

8.1 Hiệu chỉnh ngưỡng phân loại

Mọi kết quả từ đầu chương đến giờ đều dùng **ngưỡng mặc định 0.5**: sinh viên bị gán nhãn At-risk khi xác suất dự báo vượt quá 0.5. Ngưỡng này tối đa hoá F1 — thực tế F1 đạt đỉnh tại 0.53, gần như trùng với mặc định — nhưng F1 coi precision và recall quan trọng ngang nhau, điều không đúng với bài toán cảnh báo sớm. Bỏ sót một sinh viên đang trượt dốc khiến em đó mất cơ hội được hỗ trợ, trong khi một cảnh báo nhầm chỉ tốn thêm chút thời gian của cố vấn học tập để rà soát. Hai loại sai lầm này rõ ràng **không cùng chi phí**.

Hình 5 theo dõi ba chỉ số khi ngưỡng thay đổi từ 0.05 đến 0.95.



Hình 5: Precision, recall và F1 của lớp At-risk theo ngưỡng phân loại.


Điểm quan trọng nhất ở hình này là **F1 gần như đi ngang** trong cả một dải ngưỡng rộng, khoảng 0.35–0.60, trong khi precision và recall đổi chỗ cho nhau rất mạnh. Nói cách khác, có thể dịch ngưỡng xuống khá nhiều mà chất

lượng tổng thể của mô hình gần như không suy giảm, đổi lại cán cân lệch hẳn về phía bắt được nhiều sinh viên có nguy cơ hơn.

Bảng 8 và Hình 6 lượng hoá điều đó bằng số sinh viên cụ thể.

Bảng 8: Ảnh hưởng của ngưỡng phân loại lên kết quả dự báo của CatBoost tại mốc 150 ngày. Tập kiểm tra có 1,559 sinh viên At-risk thực tế; hàng in đậm là ngưỡng mặc định.

Ngưỡng	Recall	Precision	F1	Bắt được	Bỏ sót	Cảnh báo nhầm
0.50	0.7652	0.8055	0.7849	1193	366	288
0.40	0.8095	0.7490	0.7781	1262	297	423
0.30	0.8647	0.6710	0.7556	1348	211	661
0.20	0.9179	0.5884	0.7171	1431	128	1001



Hình 6: Ma trận nhầm lẫn trên tập kiểm tra tại bốn mức ngưỡng.

Đi từ ngưỡng 0.5 xuống 0.4, số sinh viên có nguy cơ bị bỏ sót giảm từ 366 xuống 297 — tức **cứu thêm được 69 em** — trong khi F1 chỉ giảm 0.0068 (từ 0.7849 xuống 0.7781). Cái giá là 135 cảnh báo nhầm phát sinh thêm. Nếu tiếp tục hạ xuống 0.2 thì chỉ còn bỏ sót 128 em, nhưng số cảnh báo nhầm tăng vọt lên 1.001, tức danh sách cảnh báo phình to đến mức gần một nửa là báo động giả (precision chỉ còn 0.5884).

Bảng 9 tiếp cận theo chiều ngược lại: đặt ra mức recall mong muốn rồi tính ngưỡng cần dùng và cái giá phải trả.

Bảng 9: Ngưỡng cần dùng để đạt các mức recall mục tiêu, và cái giá phải trả. Cột “Bắt thêm” và “Nhầm thêm” so với ngưỡng mặc định 0.5; cột cuối là số cảnh báo nhầm phát sinh trên mỗi sinh viên At-risk bắt thêm được.

Recall mục tiêu	Ngưỡng	Recall thực tế	Precision	Bắt thêm	Nhầm thêm	Còn bỏ sót	Nhầm/ 1 ca
80%	0.425	0.8005	0.7656	+55	+94	311	1.7
85%	0.335	0.8525	0.7024	+136	+275	230	2.0
90%	0.230	0.9012	0.6109	+212	+607	154	2.9
95%	0.145	0.9513	0.5350	+290	+1001	76	3.5

Cột cuối cùng — số cảnh báo nhầm phát sinh trên mỗi sinh viên bắt thêm được — cho thấy **quy luật lợi ích cận biên giảm dần** rất rõ: chẳng đầu tiên chỉ tốn khoảng 2 cảnh báo nhầm cho mỗi em bắt thêm, nhưng khi đẩy recall lên 95% thì con số này tăng lên 3,45, và nếu hạ ngưỡng xuống dưới 0.2 thì mỗi em bắt thêm phải trả giá bằng gần 8 cảnh báo nhầm.

Khuyến nghị. Vùng ngưỡng **0.40–0.43** là điểm cân bằng hợp lý nhất: recall đạt khoảng 80%, precision vẫn giữ trên 0.75 (tức ba trong bốn cảnh báo là chính xác), F1 gần như không đổi so với ngưỡng mặc định, và chi phí đánh đổi ở mức thấp nhất trong toàn dải. Tuy vậy, lựa chọn cuối cùng nên phụ thuộc vào **năng lực hỗ trợ thực tế** của nhà trường: nếu đội ngũ cố vấn đủ sức theo sát khoảng 2.000 sinh viên mỗi kỳ thì có thể hạ sâu hơn để tăng recall; nếu nguồn lực eo hẹp, giữ ngưỡng cao giúp danh sách cảnh báo ngắn và chính xác hơn.

Một lưu ý về phương pháp: ngưỡng ở đây được khảo sát **trực tiếp trên tập kiểm tra**, nên các con số mang tính minh họa cho sự đánh đổi hơn là một ngưỡng đã được kiểm định độc lập. Khi triển khai thực tế, ngưỡng nên được chọn bằng kiểm định chéo trên tập huấn luyện rồi mới xác nhận lại một lần trên tập kiểm tra.

8.2 Khoảng tin cậy bootstrap của các chỉ số


Mọi chỉ số trong báo cáo đều là **ước lượng điểm** tính trên một tập kiểm tra hữu hạn gồm 4.363 bản ghi. Nếu thu thập một tập kiểm tra khác, các con số này chắc chắn sẽ khác đi đôi chút. Câu hỏi đặt ra là: khác đi bao nhiêu?

Phương pháp **bootstrap** trả lời câu hỏi đó mà không cần thêm dữ liệu mới: lấy mẫu lại chính tập kiểm tra **có hoàn lại**, giữ nguyên kích thước, lặp lại $B = 2.000$ lần; mỗi lần tính lại toàn bộ chỉ số. Phân phối của 2.000 giá trị thu

được xấp xỉ phân phối lấy mẫu của chỉ số, từ đó lấy phân vị 2,5% và 97,5% làm khoảng tin cậy 95%.

Bảng 10: Khoảng tin cậy 95% của các chỉ số đánh giá, ước lượng bằng bootstrap trên tập kiểm tra ($B = 2,000$ lần lấy mẫu có hoàn lại) tại ngưỡng mặc định 0.5.

Chỉ số	Ước lượng điểm	KTC 95%	Độ rộng	Sai số chuẩn
Accuracy	0.8501	[0.8398; 0.8609]	0.0211	0.0053
Precision (At-risk)	0.8055	[0.7851; 0.8258]	0.0407	0.0105
Recall (At-risk)	0.7652	[0.7442; 0.7863]	0.0421	0.0108
F1 (At-risk)	0.7849	[0.7692; 0.8012]	0.0320	0.0082
ROC-AUC	0.9114	[0.9022; 0.9206]	0.0184	0.0047



Hình 7: Phân phối bootstrap của năm chỉ số đánh giá; đường liền là ước lượng điểm, hai đường đứt là biên khoảng tin cậy 95%.

- Trung bình bootstrap trùng khớp với ước lượng điểm tới bốn chữ số thập phân ở cả năm chỉ số — dấu hiệu cho thấy các ước lượng **không bị chệch**.
- **Accuracy** và **ROC-AUC** là hai chỉ số ổn định nhất (độ rộng khoảng tin cậy lần lượt 0.0211 và 0.0184), vì được tính trên toàn bộ 4.363 bản ghi.
- **Precision** và **recall** của lớp At-risk dao động mạnh gấp đôi (độ rộng 0.0407 và 0.0421), điều dễ hiểu vì chỉ dựa trên nhóm thiểu số 1.559 sinh viên At-risk.

Hệ quả quan trọng nhất của phân tích này liên quan đến việc **xếp hạng các mô hình** ở bước so sánh thuật toán. Khoảng tin cậy của F1 trải từ 0.7692 đến 0.8012, tức rộng 0.032 — trong khi khoảng cách F1 giữa ba mô hình cây chỉ là 0.0022 đến 0.0037. Chênh lệch giữa chúng **nhỏ hơn nhiều so với sai số lấy mẫu**, nên kết luận “CatBoost tốt hơn LightGBM và Random Forest” không đứng vững về mặt thống kê: ba mô hình này nên được xem là **tương đương**, và việc CatBoost dẫn đầu có thể chỉ là ngẫu nhiên của riêng tập kiểm tra này. Ngược lại, khoảng cách giữa Logistic Regression (0.7591) và nhóm mô hình cây

lớn hơn hẳn độ rộng khoảng tin cậy, nên kết luận mô hình tuyến tính thực sự yếu hơn là đáng tin cậy.


Nhận xét này không làm mất giá trị của việc chọn CatBoost để triển khai — vẫn cần chọn ra một mô hình, và CatBoost là lựa chọn hợp lý — nhưng nó cảnh báo rằng không nên diễn giải quá mức các chênh lệch nhỏ ở chữ số thập phân thứ ba. Muốn khẳng định một mô hình thực sự vượt trội, cần đánh giá trên nhiều tập kiểm tra độc lập hoặc dùng kiểm định thống kê trên chênh lệch giữa từng cặp mô hình.

9 Diễn giải mô hình bằng SHAP

Để hiểu sâu hơn cơ chế ra quyết định của mô hình, phương pháp **SHAP** (SHapley Additive exPlanations) được áp dụng cho mô hình có F1 At-risk cao nhất trên bộ đặc trưng đầy đủ — **CatBoost** — trên cả ba bộ đặc trưng (Full, Top-10, Top-5) để đối chiếu mức độ nhất quán của các diễn giải khi số lượng đặc trưng thay đổi.

9.1 Biểu đồ tổng quan (beeswarm và mean|SHAP|)

Hình 8 trình bày kết quả SHAP trên bộ đặc trưng đầy đủ: biểu đồ beeswarm cho biết chiều và độ phân tán ảnh hưởng của từng đặc trưng lên từng sinh viên cụ thể, trong khi biểu đồ cột thể hiện mức độ quan trọng trung bình.




Hình 8: Diễn giải SHAP của CatBoost trên bộ đặc trưng đầy đủ (15 đặc trưng).


Kết quả SHAP đồng thuận cao với thứ hạng độ quan trọng đặc trưng gốc ở

Bảng 6: `num_submitted_filled`, `avg_score_filled` và `active_weeks_filled` là ba đặc trưng có ảnh hưởng lớn nhất. Chiều tác động phù hợp với trực giác nghiệp vụ: giá trị `num_submitted_filled` và `avg_score_filled` **thấp** (màu xanh) đẩy dự báo về phía **At-risk** (SHAP dương), trong khi giá trị **cao** (màu đỏ/tím) kéo dự báo về phía Pass. Riêng `num_due` (số bài đến hạn) thể hiện chiều **ngược lại**: giá trị cao (màu đỏ) lại đẩy về phía At-risk — hợp lý vì số bài đến hạn cao đồng nghĩa với khối lượng công việc dồn lại lớn, thường đi kèm nguy cơ trễ hạn hoặc bỏ bài cao hơn.

Hình 9 và Hình 10 lặp lại phân tích trên với hai bộ đặc trưng rút gọn.



Hình 9: Diễn giải SHAP của CatBoost trên bộ đặc trưng Top-10.




Hình 10: Diễn giải SHAP của CatBoost trên bộ đặc trưng Top-5.

Thứ tự và chiều ảnh hưởng của các đặc trưng còn lại hầu như **không đổi** khi loại bỏ dần các đặc trưng ít quan trọng — một bằng chứng bổ sung cho tính ổn định đã quan sát ở Bảng 7, đồng thời cho thấy các đặc trưng bị loại bỏ đóng góp thông tin trùng lặp hoặc không đáng kể.

9.2 Diễn giải cục bộ: hai trường hợp minh hoạ

Để minh hoạ cách mô hình đưa ra quyết định ở cấp độ từng cá nhân, Hình 11 trình bày biểu đồ waterfall của hai sinh viên đại diện, sử dụng mô hình CatBoost trên bộ đặc trưng đầy đủ: một trường hợp bị đẩy mạnh về phía At-risk và một trường hợp bị đẩy mạnh về phía Pass.



Hình 11: Diễn giải cục bộ (waterfall) cho hai sinh viên đại diện.

- **Trường hợp At-risk:** sinh viên chưa nộp bài nào (`num_submitted_filled` = 0, kéo theo `avg_score_filled` = -1 — giá trị đánh dấu chưa có điểm) trong khi đã có 9 bài đến hạn (`num_due` = 9). Hai yếu tố này đóng góp lần lượt +2.60 và +3.01 vào điểm số dự báo; cộng thêm số tuần hoạt động thấp (`active_weeks_filled` = 6, đóng góp +1.24), tổng điểm bị đẩy lên 8.84 — rất cao so với giá trị nền 0.92, tương ứng xác suất At-risk gần như tuyệt đối.
- **Trường hợp Pass:** sinh viên có điểm trung bình cao (`avg_score_filled` = 95.33, kéo điểm số giảm 1.97) và số tuần hoạt động nhiều (`active_weeks_filled` = 25, giảm 1.17), cộng thêm lượt truy cập rất lớn (`total_clicks_filled` = 9115, giảm 0.67) — tổng hợp lại cho điểm số rất thấp (-5.18), tương ứng xác suất Pass gần như tuyệt đối.

Hai ví dụ trên cho thấy mô hình đưa ra quyết định dựa trên những tín hiệu phù hợp với trực giác sư phạm: mức độ hoàn thành bài tập và điểm số tích lũy là yếu tố quyết định, đúng như đã được xác nhận qua phân tích độ quan trọng đặc trưng ở quy mô toàn cục.

10 Kết luận

Từ toàn bộ quá trình xây dựng và so sánh mô hình, có thể rút ra các kết luận chính sau:

- Việc gộp nhãn Fail và Withdrawn thành nhóm At-risk và giới hạn dữ liệu về mốc dự đoán 150 ngày đưa bài toán về dạng phân loại nhị phân, mất cân bằng nhãn ở mức vừa phải (At-risk chiếm khoảng 36%) — được xử lý hiệu quả bằng cách kết hợp SMOTE và trọng số lớp, đồng thời tinh chỉnh cả hai kỹ thuật này cùng với siêu tham số của từng mô hình thông qua Optuna.
- Trong số bốn thuật toán thử nghiệm, **CatBoost** đạt F1 At-risk cao nhất trên bộ đặc trưng đầy đủ (0.7849), đồng thời dẫn đầu cả về accuracy và precision; LightGBM bám sát ngay phía sau và giữ ROC-AUC cao nhất. Hai mô hình boosting này vượt trội hơn Logistic Regression một cách nhất quán trên mọi bộ đặc trưng, dù khoảng cách với Random Forest là không lớn.
- Hiệu suất mô hình **ổn định cao** khi giảm số lượng đặc trưng từ 15 xuống chỉ còn 5 — thậm chí CatBoost trên bộ Top-10 đạt F1 At-risk cao nhất toàn thực nghiệm (0.7875). Kết quả này gợi ý một bộ **5 đặc trưng** (num_submitted_filled, avg_score_filled, num_due, active_weeks_filled, total_clicks_filled) — toàn bộ đều là đặc trưng hành vi học tập, không yêu cầu thông tin nhân khẩu học — là đủ để xây dựng một hệ thống cảnh báo sớm gọn nhẹ, dễ triển khai và duy trì.
- Phân tích SHAP xác nhận các dự báo của mô hình dựa trên những tín hiệu phù hợp với trực giác sư phạm — mức độ hoàn thành bài tập, điểm số tích lũy và khối lượng công việc còn tồn đọng — và các diễn giải này giữ nguyên tính nhất quán qua cả ba bộ đặc trưng.

Hạn chế và hướng phát triển. Nghiên cứu hiện chỉ đánh giá tại một mốc thời gian duy nhất — 150 ngày; một hướng mở rộng tự nhiên là huấn luyện và so sánh mô hình tại **nhiều mốc dự đoán** khác nhau để xác định thời điểm cảnh báo sớm nhất mà mô hình vẫn đạt độ tin cậy chấp nhận được, đồng thời theo dõi cách các dự báo về cùng một sinh viên thay đổi theo thời gian. Bên cạnh đó, việc **hiệu chỉnh ngưỡng phân loại** theo chi phí thực tế của việc bỏ sót so với cảnh báo nhầm, cũng như thử nghiệm mô hình trên dữ liệu của các cơ sở đào tạo khác, là những bước cần thiết trước khi đưa hệ thống vào vận hành thực tế.