

TRƯỜNG ĐẠI HỌC QUY NHƠN
KHOA TOÁN & THỐNG KÊ



TIỂU LUẬN MÔN HỌC:
PHÂN TÍCH DỮ LIỆU KHOA HỌC CHUYÊN NGÀNH

XÂY DỰNG VÀ SO SÁNH MÔ HÌNH
HỌC MÁY CẢNH BÁO SỚM
RỦI RO HỌC TẬP

Trình độ đào tạo: Thạc sĩ

Học viên thực hiện: Nguyễn Hồ Bảo Thiên

Mã số sinh viên: 8282548017

Lớp: Khoa học dữ liệu K28B

Giảng viên hướng dẫn: TS. Hồ Văn Lâm

Gia Lai, 2026

Mục lục

1	Giới thiệu	1
2	Tiền xử lý dữ liệu	1
2.1	Điền giá trị thiếu ở đặc trưng động	1
2.2	Xử lý giá trị thiếu ở imd_band	2
2.3	Mã hoá đặc trưng phân loại	2
2.4	Tập đặc trưng cuối cùng	3
2.5	Chuẩn hoá bài toán về phân loại nhị phân	3
3	Khảo sát sơ bộ theo các mốc dự đoán	3
3.1	Thiết lập thử nghiệm	4
3.2	Kết quả theo thời gian	4
3.3	Lựa chọn mốc dự đoán cho phân tích chuyên sâu	7
4	Phương pháp xây dựng mô hình	8
4.1	Các thuật toán sử dụng	8
4.2	Xử lý mất cân bằng nhãn	8
4.3	Thiết lập thực nghiệm	9
5	Kết quả trên bộ đặc trưng đầy đủ	9
6	Độ quan trọng của đặc trưng	12
7	Rút gọn đặc trưng: Top-10 và Top-5	13
8	Diễn giải mô hình bằng SHAP	17
8.1	Biểu đồ tổng quan (beeswarm và mean SHAP)	17
8.2	Diễn giải cục bộ: hai trường hợp minh hoạ	18
9	Kết luận	19

Danh sách hình vẽ

1	Xu hướng hiệu suất mô hình theo từng mốc dự đoán (mỗi mốc một mô hình riêng).	5
2	Ma trận nhầm lẫn trên tập kiểm tra tại từng mốc dự đoán.	6

3	Ma trận nhầm lẫn trên tập kiểm tra — bộ đặc trưng đầy đủ (T=180).	11
4	Độ quan trọng đặc trưng (theo định nghĩa riêng của từng mô hình) tại T=180.	12
5	Ma trận nhầm lẫn của bốn mô hình trên hai bộ đặc trưng rút gọn Top-10 và Top-5 (T=180).	14
6	Biến động các chỉ số hiệu suất khi giảm số lượng đặc trưng: Full(15) $\rightarrow$ Top-10 $\rightarrow$ Top-5 (T=180).	15
7	So sánh F1 At-risk giữa bộ Top-10 và Top-5 theo từng mô hình.	16
8	Diễn giải SHAP của LightGBM trên bộ đặc trưng đầy đủ (15 đặc trưng).	17
9	Diễn giải SHAP của LightGBM trên bộ đặc trưng Top-10.	18
10	Diễn giải SHAP của LightGBM trên bộ đặc trưng Top-5.	18
11	Diễn giải cục bộ (waterfall) cho hai sinh viên đại diện.	19

Danh sách bảng

1	Phương án mã hoá các đặc trưng phân loại.	2
2	Kết quả sơ bộ của mô hình Logistic Regression — một mô hình riêng cho mỗi mốc dự đoán T — trên tập kiểm tra. Precision/Recall/F1 tính riêng cho lớp At-risk.	5
3	Siêu tham số xử lý mất cân bằng nhãn được Optuna lựa chọn cho từng mốc dự đoán, cùng F1 At-risk trung bình qua 3-fold cross-validation.	7
4	Quy mô và phân phối nhãn nhị phân tại mốc dự đoán $T = 180$, sau khi gộp Fail và Withdrawn thành At-risk.	8
5	So sánh các mô hình trên bộ 15 đặc trưng đầy đủ (T=180). Chỉ số Precision/Recall/F1 tính riêng cho lớp At-risk	9
6	Thứ hạng độ quan trọng của từng đặc trưng theo mỗi mô hình (1 = quan trọng nhất) và hạng trung bình, sắp xếp tăng dần theo hạng trung bình.	12
7	So sánh các mô hình sau khi rút gọn về 10 đặc trưng quan trọng nhất (Top-10).	13
8	So sánh các mô hình sau khi rút gọn về 5 đặc trưng quan trọng nhất (Top-5).	14

9	Siêu tham số tối ưu liên quan đến xử lý mất cân bằng nhãn — tỷ lệ oversampling SMOTE và trọng số lớp At-risk — được Optuna lựa chọn cho từng mô hình và từng bộ đặc trưng, cùng F1 At-risk trung bình qua 3-fold cross-validation.	16
---	--	----

1 Giới thiệu

Báo cáo này trình bày giai đoạn *xây dựng và so sánh mô hình học máy* cho bài toán cảnh báo sớm rủi ro học tập, kế thừa trực tiếp kết quả của giai đoạn phân tích khám phá dữ liệu (EDA) trước đó. Bài toán được xác định lại ở dạng **phân loại nhị phân**: nhận diện sinh viên **có nguy cơ** (At-risk) — gộp từ hai nhóm kết quả trượt môn (Fail) và bỏ học (Withdrawn) — so với nhóm **hoàn thành** (Pass), dựa trên đặc trưng nhân khẩu học và hành vi học tập tích lũy đến một mốc thời gian xác định trong khoá học.

Nội dung báo cáo gồm bốn phần chính:

1. **Tiền xử lý dữ liệu**: điền giá trị thiếu, mã hoá đặc trưng phân loại, gộp nhãn và chuẩn hoá bài toán về dạng nhị phân.
2. **Khảo sát sơ bộ theo các mốc dự đoán**: huấn luyện một mô hình cơ sở xuyên suốt toàn bộ các mốc thời gian trong khoá học để hiểu xu hướng hiệu suất theo thời gian, làm cơ sở lựa chọn mốc dự đoán cho các thử nghiệm chuyên sâu.
3. **Xây dựng mô hình**: huấn luyện và tinh chỉnh bốn thuật toán học máy (Logistic Regression, Random Forest, CatBoost, LightGBM) kết hợp kỹ thuật xử lý mất cân bằng nhãn, tập trung vào mốc thời gian đã chọn.
4. **So sánh và diễn giải mô hình**: đối chiếu hiệu suất giữa các thuật toán, đánh giá độ ổn định khi rút gọn số lượng đặc trưng, và diễn giải các dự báo bằng phương pháp SHAP.

2 Tiền xử lý dữ liệu

2.1 Điền giá trị thiếu ở đặc trưng động

Các đặc trưng phản ánh hành vi học tập tích lũy (tương tác với hệ thống học trực tuyến và kết quả bài đánh giá) có giá trị thiếu ở những sinh viên chưa từng tương tác hoặc chưa nộp bài nào tính đến mốc thời gian quan sát. Quy tắc điền khuyết được áp dụng riêng cho từng nhóm đặc trưng:

- **Đặc trưng tương tác VLE** (`total_clicks`, `active_weeks`, `avg_weekly_clicks`) và **đặc trưng bài đánh giá** (`num_submitted`, `num_failed`) — điền

bằng 0, vì giá trị thiếu ở đây đồng nghĩa với việc sinh viên chưa phát sinh hoạt động nào.

- `avg_score` — điền bằng giá trị **-1** (nằm ngoài thang điểm $[0, 100]$) để phân biệt rõ ràng với trường hợp sinh viên nộp bài và bị điểm 0.
- `avg_days_early` — điền bằng 0; thông tin về việc sinh viên không nộp bài dù đã đến hạn đã được nắm bắt riêng bởi đặc trưng nhị phân `no_submission_despite_due`, nên việc điền 0 ở đây không gây nhầm lẫn.

Sau bước điền khuyết, toàn bộ đặc trưng động không còn giá trị thiếu.

2.2 Xử lý giá trị thiếu ở `imd_band`

Như đã trình bày ở giai đoạn phân tích khám phá, biến `imd_band` (chỉ số thiếu thốn kinh tế theo khu vực) có một dạng thiếu riêng biệt, được mã hoá bằng ký hiệu '?' thay vì giá trị rỗng thông thường. Một biến chỉ báo `imd_missing` được tạo trước khi điền khuyết, để mô hình có thể tận dụng chính tín hiệu “thiếu dữ liệu” như một đặc trưng dự báo.

Giá trị thiếu được điền theo **phân phối riêng của từng vùng** (`region`), ước lượng trên tập huấn luyện rồi áp dụng lại cho tập kiểm tra. Sau bước xử lý, biến `imd_band_filled` không còn giá trị thiếu ở cả hai tập huấn luyện và kiểm tra.

2.3 Mã hoá đặc trưng phân loại

Các đặc trưng phân loại được mã hoá theo bản chất của từng biến, tóm tắt ở Bảng 1.

Bảng 1: Phương án mã hoá các đặc trưng phân loại.

Đặc trưng	Kiểu mã hoá	Lý do
<code>disability</code>	Nhị phân	$Y \rightarrow 1, N \rightarrow 0$
<code>highest_education</code>	Thứ tự (ordinal)	Có thứ bậc học vấn rõ ràng
<code>imd_band_filled</code>	Thứ tự (ordinal)	Có thứ bậc mức độ nghèo

Ba đặc trưng nhân khẩu học còn lại từ dữ liệu gốc — `gender`, `region`, `age_band` — không được đưa vào ma trận đặc trưng huấn luyện. Các đặc trưng nhân khẩu học được giữ lại (`highest_education`, `disability`, `imd_band_filled`) là

những đặc trưng đã cho thấy liên hệ rõ ràng với kết quả học tập ở giai đoạn phân tích khám phá dữ liệu trước đó.

2.4 Tập đặc trưng cuối cùng

Sau các bước xử lý trên, ma trận đặc trưng dùng cho huấn luyện mô hình gồm **15 đặc trưng**:

- **Tĩnh (5):** `highest_education`, `disability`, `num_of_prev_attempts`, `studied_credits`, `imd_band_filled`, cùng biến chỉ báo `imd_missing`.
- **Động (9):** `total_clicks_filled`, `active_weeks_filled`, `avg_weekly_clicks_filled`, `num_due`, `num_submitted_filled`, `avg_score_filled`, `num_failed_filled`, `avg_days_early_filled`, `no_submission_despite_due`.

Việc chia tập huấn luyện và kiểm tra được giữ nguyên theo **từng sinh viên** như đã thiết lập ở giai đoạn EDA (tỷ lệ 80:20), đảm bảo không xảy ra rò rỉ dữ liệu giữa hai tập.

2.5 Chuẩn hoá bài toán về phân loại nhị phân

Với mục tiêu cảnh báo sớm, ranh giới quan trọng nhất không nằm giữa Fail và Withdrawn, mà giữa nhóm **hoàn thành** và nhóm **không hoàn thành** học phần. Do đó, nhãn mục tiêu được chuẩn hoá lại:

$$\text{At-risk (1)} = \text{Fail} \cup \text{Withdrawn}, \quad \text{Pass (0)} = \text{Pass}.$$

Phép gộp nhãn này được áp dụng thống nhất cho toàn bộ dữ liệu dạng panel, tức trên mọi bản ghi ở cả tám mốc dự đoán $T \in \{30, 60, \dots, 240\}$ đã thiết kế ở giai đoạn EDA — không giới hạn ở một mốc thời gian cụ thể nào. Với dữ liệu đã ở dạng nhị phân, câu hỏi tiếp theo là mốc dự đoán nào nên được chọn để huấn luyện và đánh giá mô hình; đây là nội dung được khảo sát ở phần kế tiếp.

3 Khảo sát sơ bộ theo các mốc dự đoán

Trước khi đi sâu so sánh nhiều thuật toán tại một mốc thời gian cố định, cần khảo sát sơ bộ hiệu suất mô hình học máy **xuyên suốt toàn bộ các mốc dự đoán** đã thiết kế ở giai đoạn tiền xử lý, nhằm hai mục đích: (i) hiểu xu hướng

biến động hiệu suất theo thời gian khi sinh viên tích lũy ngày càng nhiều hành vi học tập, và (ii) làm cơ sở lựa chọn một mốc thời gian đại diện, phù hợp cho các thử nghiệm chuyên sâu ở phần sau.

3.1 Thiết lập thử nghiệm

Với mỗi mốc dự đoán T , một mô hình **Logistic Regression** được huấn luyện riêng, chỉ sử dụng dữ liệu của đúng mốc đó — đây cũng là thuật toán cơ sở, đơn giản và dễ diễn giải nhất trong bốn thuật toán được đề xuất ở giai đoạn EDA, phù hợp để khảo sát nhanh xu hướng hiệu suất theo thời gian trước khi mở rộng sang các mô hình phức tạp hơn. Quy trình tinh chỉnh áp dụng cho từng mô hình tương tự cách tiếp cận sẽ được dùng ở giai đoạn so sánh nhiều thuật toán tại Mục 4: dữ liệu được chuẩn hoá bằng **StandardScaler** (fit trên train-fold, tránh rò rỉ dữ liệu), siêu tham số điều chuẩn C của mô hình, tỷ lệ oversampling SMOTE và trọng số lớp At-risk được tinh chỉnh đồng thời bằng Optuna (30 lượt thử nghiệm, kiểm định chéo phân tầng 3-fold), sau đó huấn luyện lại trên toàn bộ tập huấn luyện của mốc đó và đánh giá trên tập kiểm tra giữ nguyên.

Một lưu ý về mặt phương pháp: ở lần thử đầu tiên, hàm mục tiêu tối ưu là *recall thuần* của lớp At-risk, nhưng cách làm này khiến mô hình suy biến về việc dự đoán **toàn bộ** sinh viên đều là At-risk (recall đạt gần tuyệt đối nhưng precision rất thấp, không có giá trị thực tiễn). Hàm mục tiêu sau đó được đổi sang **F1-score của lớp At-risk** để buộc mô hình cân bằng giữa precision và recall — đây là hàm mục tiêu được giữ nguyên xuyên suốt các thử nghiệm còn lại của báo cáo.


3.2 Kết quả theo thời gian

Bảng 2 tổng hợp hiệu suất trên tập kiểm tra của tám mô hình, mỗi mô hình ứng với một mốc dự đoán.

Bảng 2: Kết quả sơ bộ của mô hình Logistic Regression — một mô hình riêng cho mỗi mốc dự đoán T — trên tập kiểm tra. Precision/Recall/F1 tính riêng cho lớp At-risk.

T (ngày)	Train	Test	Accuracy	Precision	Recall	F1
30	19,988	5,043	0.6488	0.5750	0.8013	0.6695
60	19,123	4,835	0.7231	0.6429	0.7666	0.6993
90	18,508	4,680	0.7402	0.6442	0.7857	0.7080
120	17,917	4,518	0.7915	0.7123	0.7555	0.7333
150	17,386	4,363	0.8263	0.7524	0.7659	0.7591
180	16,786	4,215	0.8451	0.7533	0.7987	0.7754
210	16,486	4,162	0.8659	0.7976	0.7894	0.7935
240	16,190	4,094	0.8796	0.8269	0.7814	0.8035

Hình 1 trực quan hoá xu hướng của bốn chỉ số theo mốc thời gian.




Hình 1: Xu hướng hiệu suất mô hình theo từng mốc dự đoán (mỗi mốc một mô hình riêng).

- **Accuracy** và **precision At-risk** tăng **đơn điệu tuyệt đối** theo thời gian — không có mốc nào sụt giảm so với mốc liền trước (accuracy từ 0.6488 ở $T = 30$ lên 0.8796 ở $T = 240$; precision từ 0.5750 lên 0.8269) — phù hợp với trực giác: sinh viên càng tích lũy nhiều hành vi học tập, tín hiệu dự báo càng rõ ràng và đáng tin cậy hơn.
- **Recall At-risk** lại dao động trong một biên độ hẹp (0.7555–0.8013) mà không theo xu hướng rõ ràng, thậm chí đạt giá trị cao nhất ngay ở mốc sớm nhất

$T = 30$ (0.8013) — khi độ chính xác tổng thể còn rất thấp (accuracy 0.6488, precision 0.5750). Điều này cho thấy ở giai đoạn đầu khoá, khi tín hiệu hành vi còn thừa thớt, ranh giới tuyến tính của Logistic Regression có xu hướng dự báo At-risk khá rộng rãi — bắt được phần lớn sinh viên có nguy cơ nhưng đánh đổi bằng rất nhiều cảnh báo nhầm.

- **F1 At-risk** — chỉ số tổng hợp được dùng làm mục tiêu tối ưu — vì vậy cũng tăng đơn điệu tuyệt đối theo thời gian, từ 0.6695 ($T = 30$) lên 0.8035 ($T = 240$), nhưng động lực tăng chủ yếu đến từ **precision** chứ không phải recall, vốn gần như đi ngang xuyên suốt khoá học.

Mã trận nhầm lẫn của cả tám mô hình được thể hiện ở Hình 2.



Hình 2: Ma trận nhầm lẫn trên tập kiểm tra tại từng mốc dự đoán.

Bảng 3 cho thấy siêu tham số xử lý mất cân bằng nhãn mà Optuna lựa chọn theo từng mốc thời gian.

Bảng 3: Siêu tham số xử lý mất cân bằng nhãn được Optuna lựa chọn cho từng mốc dự đoán, cùng F1 At-risk trung bình qua 3-fold cross-validation.

T (ngày)	F1 At-risk (CV)	Tỷ lệ SMOTE	Trọng số At-risk
30	0.6734	+0.67x	1.12
60	0.7065	+0.56x	1.24
90	0.7160	+0.57x	1.33
120	0.7486	+0.69x	1.01
150	0.7767	+0.55x	1.05
180	0.7918	+0.90x	1.01
210	0.8047	+0.51x	1.03
240	0.8182	+0.42x	1.01

Trọng số At-risk tối ưu hầu như luôn hội tụ gần giá trị 1 (1.01–1.33) ở mọi mốc thời gian, trong khi tỷ lệ SMOTE dao động ở mức khá cao và không theo xu hướng rõ rệt (0.42–0.90x). Nói cách khác, với Logistic Regression, việc bổ sung mẫu tổng hợp qua SMOTE đóng vai trò chủ đạo trong xử lý mất cân bằng nhãn, hơn là điều chỉnh trọng số lớp — đây là đặc điểm nhất quán của thuật toán này, cũng sẽ được quan sát lại khi so sánh với ba thuật toán còn lại ở Bảng 9.

3.3 Lựa chọn mốc dự đoán cho phân tích chuyên sâu

Kết quả khảo sát cho thấy một sự đánh đổi rõ ràng giữa **độ tin cậy của dự báo** và **thời gian còn lại để can thiệp**: các mốc càng muộn cho hiệu suất càng cao, nhưng đồng thời càng gần thời điểm kết thúc khoá học, làm giảm giá trị thực tiễn của một cảnh báo sớm. Với khoá học OULAD kéo dài khoảng 240–270 ngày, hai mốc cho F1 cao nhất ($T = 210$ và $T = 240$, lần lượt 0.7935 và 0.8035) chỉ còn lại khoảng 10–20% thời lượng khoá học — quá muộn để nhà trường triển khai các biện pháp hỗ trợ có ý nghĩa.

Mốc $T = 180$ **ngày** được chọn làm đại diện cho các thử nghiệm chuyên sâu ở phần còn lại của báo cáo, vì đạt được điểm cân bằng hợp lý nhất: hiệu suất đã ở mức khá cao (accuracy 0.8451, F1 At-risk 0.7754 — chỉ thấp hơn khoảng 0.02 so với mốc $T = 210$ liền sau), trong khi vẫn còn khoảng 60–90 ngày (25–35% thời lượng khoá học) để nhà trường can thiệp trước khi khoá học kết thúc.

Bảng 4 tóm tắt quy mô và phân phối nhãn tại mốc $T = 180$ sau khi gộp nhãn, được dùng thống nhất cho toàn bộ các thử nghiệm từ Mục 4 trở đi.

Bảng 4: Quy mô và phân phối nhãn nhị phân tại mốc dự đoán $T = 180$, sau khi gộp Fail và Withdrawn thành At-risk.

	Tập	Pass	At-risk	Tổng
	Train	11,067 (65.9%)	5,719 (34.1%)	16,786
	Test	2,804 (66.5%)	1,411 (33.5%)	4,215

Tỷ lệ At-risk chiếm khoảng **1/3** tổng số sinh viên ở cả hai tập, tương đồng giữa train và test — xác nhận việc chia dữ liệu theo sinh viên không gây lệch phân phối nhãn. Đây vẫn là một bài toán **mất cân bằng nhãn vừa phải**, cần được xử lý ở bước huấn luyện mô hình.

4 Phương pháp xây dựng mô hình

Kế thừa kết luận ở Mục 3.3, các thử nghiệm từ đây trở đi tập trung vào mốc $T = 180$, mở rộng từ một mô hình cơ sở duy nhất (đã dùng để khảo sát xu hướng theo thời gian ở Mục 3) sang so sánh trực tiếp **bốn thuật toán học máy** khác nhau.

4.1 Các thuật toán sử dụng

Bốn thuật toán được đề xuất từ giai đoạn EDA — Logistic Regression, Random Forest, CatBoost và LightGBM — được đưa vào huấn luyện và so sánh trực tiếp. Thuật toán **SVM (kernel RBF)** được loại khỏi phạm vi thử nghiệm do độ phức tạp huấn luyện tăng theo bậc hai với số lượng mẫu, không khả thi với quy mô dữ liệu ở mốc $T = 180$ (hơn 16 nghìn bản ghi huấn luyện) trong khuôn khổ tài nguyên tính toán của nghiên cứu.

4.2 Xử lý mất cân bằng nhãn

Hai kỹ thuật được kết hợp đồng thời để xử lý mất cân bằng nhãn:

- **SMOTE** (Synthetic Minority Over-sampling Technique): sinh thêm mẫu tổng hợp cho lớp At-risk, với tỷ lệ oversampling là một siêu tham số được tinh chỉnh riêng cho từng mô hình.
- **Trọng số lớp** (`class_weight`): tăng chi phí phân loại sai đối với lớp At-risk trong hàm mất mát của mô hình, cũng được tinh chỉnh như một siêu tham

số.

Để tránh rò rỉ dữ liệu, **SMOTE chỉ được áp dụng trên từng fold huấn luyện** trong quá trình kiểm định chéo, không áp dụng lên fold kiểm định. Tương tự, với Logistic Regression — mô hình duy nhất cần chuẩn hoá dữ liệu số (**StandardScaler**) — bước chuẩn hoá cũng chỉ được ước lượng (fit) trên fold huấn luyện.

4.3 Thiết lập thực nghiệm

Với mỗi mô hình, siêu tham số của thuật toán được tinh chỉnh **đồng thời** với tỷ lệ SMOTE và trọng số lớp At-risk, thông qua khung tối ưu Bayesian **Optuna** (thuật toán lấy mẫu TPE), với 30 lượt thử nghiệm cho mỗi mô hình. Hàm mục tiêu được tối ưu là **F1-score của lớp At-risk**, đánh giá qua kiểm định chéo phân tầng 3-fold (StratifiedKFold) nhằm giữ nguyên tỷ lệ lớp ở mỗi fold. Sau khi xác định bộ siêu tham số tốt nhất, mô hình được huấn luyện lại trên toàn bộ tập huấn luyện và đánh giá lần cuối trên tập kiểm tra giữ nguyên (holdout), độc lập hoàn toàn với quá trình tinh chỉnh.

Các chỉ số đánh giá trên tập kiểm tra gồm: accuracy, precision, recall, F1 (tính riêng cho lớp At-risk) và ROC-AUC.

5 Kết quả trên bộ đặc trưng đầy đủ

Bảng 5 tổng hợp hiệu suất của bốn mô hình trên tập kiểm tra, sử dụng đầy đủ 15 đặc trưng.


Bảng 5: So sánh các mô hình trên bộ 15 đặc trưng đầy đủ (T=180). Chỉ số Precision/Recall/F1 tính riêng cho lớp **At-risk**.

Model	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.8451	0.7533	0.7987	0.7754	0.9163
Random Forest	0.8681	0.8251	0.7690	0.7960	0.9248
CatBoost	0.8728	0.8464	0.7576	0.7996	0.9304
LightGBM	0.8686	0.8076	0.7973	0.8024	0.9292


- **CatBoost** đạt accuracy (0.8728) và precision At-risk (0.8464) cao nhất, đồng thời có ROC-AUC cao nhất (0.9304) — mô hình phân biệt tốt nhất giữa hai lớp trên toàn dải ngưỡng.

- **LightGBM** đạt F1 At-risk cao nhất (0.8024), nhờ cân bằng tốt giữa precision (0.8076) và recall (0.7973) — ít bỏ sót sinh viên có nguy cơ hơn CatBoost (recall 0.7576) trong khi độ chính xác dự báo vẫn ở mức cao.
- **Random Forest** cho kết quả khá tương đồng với hai mô hình boosting, nhưng không vượt trội ở bất kỳ chỉ số nào.
- **Logistic Regression** có hiệu suất thấp nhất ở mọi chỉ số, phù hợp với kỳ vọng đặt ra từ giai đoạn EDA: dữ liệu tồn tại quan hệ phi tuyến và đa cộng tuyến giữa các đặc trưng hành vi trực tuyến, là những đặc điểm mà mô hình tuyến tính khó nắm bắt đầy đủ.


Ma trận nhầm lẫn (confusion matrix) của từng mô hình trên tập kiểm tra được thể hiện ở Hình 3.




(a) Logistic Regression



(b) Random Forest



(c) CatBoost




(d) LightGBM

Hình 3: Ma trận nhầm lẫn trên tập kiểm tra — bộ đặc trưng đầy đủ ($T=180$).

Nhìn chung, phần lớn sai số của cả bốn mô hình đều nằm ở việc **bỏ sót sinh viên At-risk** (dự báo Pass trong khi thực tế At-risk) nhiều hơn là cảnh báo nhầm (dự báo At-risk trong khi thực tế Pass). Đây là điểm cần lưu ý khi triển khai thực tế: có thể cân nhắc hạ ngưỡng phân loại để tăng recall, chấp nhận đánh đổi thêm một số cảnh báo nhầm nhằm giảm thiểu rủi ro bỏ sót sinh viên cần hỗ trợ.

6 Độ quan trọng của đặc trưng

Hình 4 thể hiện độ quan trọng đặc trưng theo định nghĩa riêng của từng thuật toán (hệ số hồi quy tuyệt đối với Logistic Regression, độ giảm tạp chất Gini với Random Forest, PredictionValuesChange với CatBoost, và số lần được dùng để phân tách với LightGBM) — các giá trị này **không cùng đơn vị** nên chỉ so sánh được thứ hạng, không so sánh trực tiếp độ lớn giữa các mô hình.



Hình 4: Độ quan trọng đặc trưng (theo định nghĩa riêng của từng mô hình) tại T=180.

Để tổng hợp một thứ hạng chung, mỗi đặc trưng được xếp hạng riêng trong từng mô hình rồi lấy trung bình cộng bốn hạng. Bảng 6 trình bày kết quả, sắp xếp tăng dần theo hạng trung bình.

Bảng 6: Thứ hạng độ quan trọng của từng đặc trưng theo mỗi mô hình (1 = quan trọng nhất) và hạng trung bình, sắp xếp tăng dần theo hạng trung bình.

Đặc trưng	LogReg	RF	CatBoost	LightGBM	Hạng TB
num_submitted_filled	1	1	1	3	1.50
avg_score_filled	5	2	4	1	3.00
num_due	4	7	3	7	5.25
total_clicks_filled	2	4	10	6	5.50
active_weeks_filled	9	3	6	4	5.50
highest_education	7	8	2	9	6.50
avg_days_early_filled	11	6	8	2	6.75
avg_weekly_clicks_filled	3	9	11	5	7.00
num_failed_filled	8	5	7	12	8.00
imd_band_filled	10	11	9	8	9.50
num_of_prev_attempts	13	12	5	11	10.25
no_submission_despite_due	6	10	15	15	11.50
studied_credits	15	13	13	10	12.75
disability	14	14	12	14	13.50
imd_missing	12	15	14	13	13.50

- **Nhóm dẫn đầu** — `num_submitted_filled` (số bài đã nộp) đứng hạng 1 ở cả ba mô hình cây và hạng 3 ở Logistic Regression, khẳng định đây là tín hiệu dự báo mạnh và nhất quán nhất. Theo sau là `avg_score_filled` (điểm trung bình) và `num_due` (số bài đến hạn) — cả ba đều là đặc trưng **động**, phản ánh trực tiếp mức độ tham gia và kết quả học tập tích lũy.
- **Nhóm giữa** gồm các đặc trưng tương tác VLE (`total_clicks_filled`, `active_weeks_filled`) và `highest_education` — đóng góp bổ sung nhưng không mang tính quyết định.
- **Nhóm cuối** — `studied_credits`, `disability`, `imd_missing` có hạng trung bình cao nhất (ít quan trọng nhất), cho thấy các đặc trưng tĩnh mang tính nhân khẩu học có vai trò dự báo khiêm tốn hơn nhiều so với các đặc trưng hành vi động.

7 Rút gọn đặc trưng: Top-10 và Top-5

Dựa trên thứ hạng ở Bảng 6, mười đặc trưng quan trọng nhất (Top-10) và năm đặc trưng quan trọng nhất (Top-5) được chọn ra để huấn luyện lại theo đúng quy trình tinh chỉnh đã mô tả ở Mục 3, nhằm kiểm tra hiệu suất mô hình có **ổn định** hay không khi giảm số lượng đặc trưng đầu vào — một yếu tố quan trọng khi triển khai hệ thống cảnh báo thực tế, nơi việc thu thập và duy trì ít đặc trưng hơn giúp đơn giản hoá quy trình vận hành.

Bảng 7 và Bảng 8 trình bày kết quả tương ứng với hai bộ đặc trưng rút gọn.


Bảng 7: So sánh các mô hình sau khi rút gọn về 10 đặc trưng quan trọng nhất (Top-10).

Model	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.8536	0.7873	0.7711	0.7791	0.9157
Random Forest	0.8631	0.7966	0.7938	0.7952	0.9260
CatBoost	0.8614	0.7762	0.8235	0.7992	0.9303
LightGBM	0.8655	0.7972	0.8023	0.7997	0.9304

Bảng 8: So sánh các mô hình sau khi rút gọn về 5 đặc trưng quan trọng nhất (Top-5).


Model	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.8529	0.7876	0.7675	0.7775	0.9148
Random Forest	0.8700	0.8116	0.7966	0.8040	0.9279
CatBoost	0.8667	0.7979	0.8058	0.8018	0.9302
LightGBM	0.8626	0.7950	0.7945	0.7948	0.9286

Hình 5 tổng hợp ma trận nhầm lẫn của toàn bộ 8 tổ hợp (bộ đặc trưng $\times$ mô hình) trên cùng một lưới để tiện đối chiếu.



Hình 5: Ma trận nhầm lẫn của bốn mô hình trên hai bộ đặc trưng rút gọn Top-10 và Top-5 (T=180).


Hình 6 theo dõi sự biến động của cả năm chỉ số khi số lượng đặc trưng giảm dần từ 15 xuống 10 rồi 5.



Hình 6: Biến động các chỉ số hiệu suất khi giảm số lượng đặc trưng: Full(15) → Top-10 → Top-5 (T=180).

- Hiệu suất của cả bốn mô hình **rất ổn định** qua ba bộ đặc trưng — không có chỉ số nào sụt giảm đáng kể khi giảm từ 15 xuống chỉ còn 5 đặc trưng. Điều này khẳng định thêm kết luận ở Mục 5: phần lớn sức mạnh dự báo tập trung ở một nhóm nhỏ đặc trưng hành vi động.
- Đáng chú ý, **Random Forest ở bộ Top-5 đạt F1 At-risk cao nhất trong toàn bộ thực nghiệm** (0.8040), nhỉnh hơn cả LightGBM ở bộ đặc trưng đầy đủ (0.8024). CatBoost cũng cải thiện nhẹ recall khi giảm đặc trưng (từ 0.7576 ở Full lên 0.8058 ở Top-5).
- **Logistic Regression** là mô hình duy nhất có xu hướng giảm nhẹ ở hầu hết chỉ số khi giảm đặc trưng — phù hợp với đặc tính tuyến tính: mô hình này hưởng lợi từ việc có nhiều biến hơn để bù đắp cho khả năng nắm bắt tương tác hạn chế.

Hình 7 so sánh trực tiếp F1 At-risk giữa Top-10 và Top-5 cho từng mô hình.



Hình 7: So sánh F1 At-risk giữa bộ Top-10 và Top-5 theo từng mô hình.

Chênh lệch F1 giữa hai bộ đặc trưng rút gọn đều nhỏ hơn 0.01 ở mọi mô hình, củng cố nhận định rằng **bộ Top-5 là lựa chọn hợp lý cho triển khai thực tế**, cân bằng tốt giữa hiệu suất và chi phí thu thập/duy trì đặc trưng.

Cuối cùng, Bảng 9 tổng hợp siêu tham số liên quan đến xử lý mất cân bằng nhân mà Optuna lựa chọn cho từng mô hình, ở cả ba bộ đặc trưng.

Bảng 9: Siêu tham số tối ưu liên quan đến xử lý mất cân bằng nhân — tỷ lệ oversampling SMOTE và trọng số lớp At-risk — được Optuna lựa chọn cho từng mô hình và từng bộ đặc trưng, cùng F1 At-risk trung bình qua 3-fold cross-validation.

Bộ đặc trưng	Model	F1 At-risk (CV)	Tỷ lệ SMOTE	Trọng số At-risk
Full (15)	Logistic Regression	0.7918	+0.90x	1.01
	Random Forest	0.7986	+0.51x	1.10
	CatBoost	0.8074	+0.62x	1.04
	LightGBM	0.8043	+0.10x	1.46
Top-10	Logistic Regression	0.7927	+0.55x	1.05
	Random Forest	0.8008	+0.50x	1.27
	CatBoost	0.8060	+0.47x	1.79
	LightGBM	0.8042	+0.18x	1.58
Top-5	Logistic Regression	0.7887	+0.51x	1.03
	Random Forest	0.8021	+0.66x	1.03
	CatBoost	0.8069	+0.57x	1.33
	LightGBM	0.8043	+0.10x	1.46

Xu hướng chung: các mô hình cây (Random Forest, CatBoost, LightGBM) có trọng số At-risk tối ưu dao động rộng (1.03–1.79) tùy mô hình và bộ đặc trưng, trong khi Logistic Regression luôn hội tụ về trọng số gần 1.0 và tỷ lệ


SMOTE tương đối cao (0.51–0.90x) — mô hình tuyến tính dựa nhiều hơn vào việc tạo thêm mẫu tổng hợp thay vì điều chỉnh trọng số lớp để xử lý mất cân bằng.

8 Diễn giải mô hình bằng SHAP

Để hiểu sâu hơn cơ chế ra quyết định của mô hình, phương pháp **SHAP** (SHapley Additive exPlanations) được áp dụng cho mô hình có F1 At-risk cao nhất trên bộ đặc trưng đầy đủ — **LightGBM** — trên cả ba bộ đặc trưng (Full, Top-10, Top-5) để đối chiếu mức độ nhất quán của các diễn giải khi số lượng đặc trưng thay đổi.

8.1 Biểu đồ tổng quan (beeswarm và mean|SHAP|)

Hình 8 trình bày kết quả SHAP trên bộ đặc trưng đầy đủ: biểu đồ beeswarm cho biết chiều và độ phân tán ảnh hưởng của từng đặc trưng lên từng sinh viên cụ thể, trong khi biểu đồ cột thể hiện mức độ quan trọng trung bình.




Hình 8: Diễn giải SHAP của LightGBM trên bộ đặc trưng đầy đủ (15 đặc trưng).


Kết quả SHAP đồng thuận cao với thứ hạng độ quan trọng đặc trưng gốc ở Bảng 6: `num_submitted_filled`, `avg_score_filled` và `active_weeks_filled` là ba đặc trưng có ảnh hưởng lớn nhất. Chiều tác động phù hợp với trực giác nghiệp vụ: giá trị `num_submitted_filled` và `avg_score_filled` **thấp** (màu xanh) đẩy dự báo về phía **At-risk** (SHAP dương), trong khi giá trị **cao** (màu đỏ/tím) kéo dự báo về phía Pass. Riêng `num_due` (số bài đến hạn) thể hiện chiều

ngược lại: giá trị cao (màu đỏ) lại đẩy về phía At-risk — hợp lý vì số bài đến hạn cao đồng nghĩa với khối lượng công việc dồn lại lớn, thường đi kèm nguy cơ trễ hạn hoặc bỏ bài cao hơn.

Hình 9 và Hình 10 lặp lại phân tích trên với hai bộ đặc trưng rút gọn.



Hình 9: Diễn giải SHAP của LightGBM trên bộ đặc trưng Top-10.




Hình 10: Diễn giải SHAP của LightGBM trên bộ đặc trưng Top-5.

Thứ tự và chiều ảnh hưởng của các đặc trưng còn lại hầu như **không đổi** khi loại bỏ dần các đặc trưng ít quan trọng — một bằng chứng bổ sung cho tính ổn định của mô hình đã quan sát ở Hình 6, đồng thời cho thấy các đặc trưng bị loại bỏ đóng góp thông tin trùng lặp hoặc không đáng kể.

8.2 Diễn giải cục bộ: hai trường hợp minh họa

Để minh họa cách mô hình đưa ra quyết định ở cấp độ từng cá nhân, Hình 11 trình bày biểu đồ waterfall của hai sinh viên đại diện, sử dụng mô hình LightGBM trên bộ đặc trưng đầy đủ: một trường hợp bị đẩy mạnh về phía At-risk và một trường hợp bị đẩy mạnh về phía Pass.



(a) Trường hợp đẩy mạnh về At-risk

(b) Trường hợp đẩy mạnh về Pass

Hình 11: Diễn giải cục bộ (waterfall) cho hai sinh viên đại diện.

- **Trường hợp At-risk:** sinh viên chưa nộp bài nào (`num_submitted_filled` = 0) trong khi đã có 11 bài đến hạn (`num_due` = 11) — hai yếu tố này đóng góp lần lượt +3.05 và +1.31 vào điểm số dự báo, đẩy tổng điểm lên 7.71 (rất cao so với giá trị nền -0.447), tương ứng xác suất At-risk gần như tuyệt đối.
- **Trường hợp Pass:** sinh viên có điểm trung bình cao (`avg_score_filled` = 94.68) và số tuần hoạt động nhiều (`active_weeks_filled` = 28), mỗi yếu tố kéo điểm số dự báo giảm gần 1 đơn vị, tổng hợp lại cho điểm số rất thấp (-5.92) — tương ứng xác suất Pass gần như tuyệt đối.

Hai ví dụ trên cho thấy mô hình đưa ra quyết định dựa trên những tín hiệu phù hợp với trực giác sư phạm: mức độ hoàn thành bài tập và điểm số tích lũy là yếu tố quyết định, đúng như đã được xác nhận qua phân tích độ quan trọng đặc trưng ở quy mô toàn cục.

9 Kết luận

Từ toàn bộ quá trình xây dựng và so sánh mô hình, có thể rút ra các kết luận chính sau:

- Việc gộp nhãn Fail và Withdrawn thành nhóm At-risk và giới hạn dữ liệu về mốc dự đoán $T = 180$ đưa bài toán về dạng phân loại nhị phân, mất cân bằng nhãn ở mức vừa phải (khoảng 1 At-risk trên 2 Pass) — được xử lý hiệu quả bằng cách kết hợp SMOTE và trọng số lớp, đồng thời tinh chỉnh cả hai kỹ thuật này cùng với siêu tham số của từng mô hình thông qua Optuna.

- Trong số bốn thuật toán thử nghiệm, **LightGBM** đạt F1 At-risk cao nhất trên bộ đặc trưng đầy đủ (0.8024), trong khi **CatBoost** có ROC-AUC và precision cao nhất — hai mô hình boosting này đều vượt trội hơn Random Forest và Logistic Regression một cách nhất quán trên mọi bộ đặc trưng.
- Hiệu suất mô hình **ổn định cao** khi giảm số lượng đặc trưng từ 15 xuống chỉ còn 5 — thậm chí Random Forest trên bộ Top-5 đạt F1 At-risk cao nhất toàn thực nghiệm (0.8040). Kết quả này gợi ý một bộ **5 đặc trưng** (`num_submitted_filled`, `avg_score_filled`, `num_due`, `total_clicks_filled`, `active_weeks_filled`) — toàn bộ đều là đặc trưng hành vi học tập, không yêu cầu thông tin nhân khẩu học — là đủ để xây dựng một hệ thống cảnh báo sớm gọn nhẹ, dễ triển khai và duy trì.
- Phân tích SHAP xác nhận các dự báo của mô hình dựa trên những tín hiệu phù hợp với trực giác sư phạm — mức độ hoàn thành bài tập, điểm số tích lũy và khối lượng công việc còn tồn đọng — và các diễn giải này giữ nguyên tính nhất quán qua cả ba bộ đặc trưng.

Hạn chế và hướng phát triển. Nghiên cứu hiện chỉ đánh giá tại một mốc thời gian duy nhất ($T = 180$); một hướng mở rộng tự nhiên là huấn luyện và so sánh mô hình tại **nhiều mốc dự đoán** khác nhau để xác định thời điểm cảnh báo sớm nhất mà mô hình vẫn đạt độ tin cậy chấp nhận được, đồng thời theo dõi cách các dự báo về cùng một sinh viên thay đổi theo thời gian. Bên cạnh đó, việc **hiệu chỉnh ngưỡng phân loại** theo chi phí thực tế của việc bỏ sót so với cảnh báo nhầm, cũng như thử nghiệm mô hình trên dữ liệu của các cơ sở đào tạo khác, là những bước cần thiết trước khi đưa hệ thống vào vận hành thực tế.