

TRƯỜNG ĐẠI HỌC QUY NHƠN
KHOA TOÁN & THỐNG KÊ



TIỂU LUẬN MÔN HỌC:
PHÂN TÍCH DỮ LIỆU KHOA HỌC CHUYÊN NGÀNH

PHÂN TÍCH KHÁM PHÁ DỮ LIỆU
HỆ THỐNG CẢNH BÁO SỚM
RỦI RO HỌC TẬP

Trình độ đào tạo: Thạc sĩ

Học viên thực hiện: Nguyễn Hồ Bảo Thiên

Mã số sinh viên: 8282548017

Lớp: Khoa học dữ liệu K28B

Giảng viên hướng dẫn: TS. Hồ Văn Lâm

Gia Lai, 2026

Mục lục

1	Giới thiệu	1
2	Tổng quan bộ dữ liệu OULAD	1
3	Phân tích dữ liệu đánh giá (Assessment)	3
3.1	Cấu trúc chung	3
3.2	Phân tích trọng số và phát hiện bất thường	5
3.3	Giá trị thiếu ở biến ngày thi	6
4	Phân tích hành vi tương tác VLE	6
4.1	Đặc điểm phân phối	6
5	Xây dựng tập dữ liệu dạng snapshot	8
5.1	Thiết kế panel theo thời gian	8
5.2	Quy mô và giá trị thiếu	8
5.3	Phân phối nhân mục tiêu	9
5.4	Chia tập huấn luyện và kiểm tra	11
6	Phân tích khám phá các đặc trưng tĩnh	12
6.1	Chỉ số thiếu thốn kinh tế (imd_band)	12
6.2	Tình trạng khuyết tật và lịch sử học lại (disability, num_of_prev_attempts)	15
6.3	Phân tích theo nhân mục tiêu	18
6.3.1	Đặc điểm ba nhóm kết quả	18
6.3.2	Kết quả theo trình độ học vấn	19
6.3.3	Kết quả theo chỉ số thiếu thốn kinh tế	20
7	Phân tích khám phá các đặc trưng động	21
7.1	Thống kê mô tả	21
7.2	Số sinh viên còn học theo thời gian	21
7.3	Phân tích tương quan	22
7.4	Đặc trưng động theo nhân mục tiêu	24
8	Đề xuất các mô hình học máy	26
8.1	Logistic Regression	27
8.2	Random Forest	28
8.3	CatBoost	28

8.4	LightGBM	29
-----	--------------------	----

Danh sách hình vẽ

1	Sơ đồ quan hệ thực thể (ERD) của bộ dữ liệu OULAD.	2
2	Phân phối số bài đánh giá theo học phần (code module).	4
3	Tỷ lệ các loại bài đánh giá (TMA, CMA, Exam).	5
4	Giá trị <code>weekly_clicks</code> theo các phân vị (percentile).	7
5	Phân phối nhãn <code>final_result</code> (4 lớp).	10
6	Phân phối nhãn sau khi gộp Distinction vào Pass (3 lớp).	11
7	Phân phối <code>imd_band</code> trong tập huấn luyện (nhóm '?' được tô màu cam).	12
8	Tỷ lệ <code>imd_band</code> theo trình độ học vấn — nhóm band cực trị (0–20% và 80–100%).	15
9	Tỷ lệ <code>imd_band</code> theo trình độ học vấn — nhóm band trung gian (20–80%).	15
10	Phân phối tình trạng khuyết tật (<code>disability</code>).	16
11	Phân phối số lần đăng ký học phần trước đó.	16
12	Phân phối biến <code>is_retake_the_course</code>	17
13	Tỷ lệ học lại theo tình trạng khuyết tật.	17
14	Biểu đồ radar các đặc trưng tĩnh theo nhóm kết quả.	18
15	Tỷ lệ kết quả học tập theo trình độ học vấn.	19
16	Tỷ lệ kết quả học tập theo nhóm <code>imd_band</code>	20
17	Số sinh viên còn hoạt động theo mốc dự đoán (mỗi 30 ngày).	22
18	Ma trận tương quan giữa các đặc trưng động.	23
19	Biểu đồ bong bóng: <code>avg_score</code> theo <code>num_failed</code>	24
20	Biểu đồ radar các đặc trưng động theo nhóm kết quả.	25
21	Giá trị trung bình <code>avg_days_early</code> theo nhóm kết quả.	26

Danh sách bảng

1	Thống kê tổng quan bộ dữ liệu OULAD.	2
2	Thống kê mô tả các biến phân loại của dữ liệu đánh giá.	4
3	Thống kê mô tả dữ liệu tương tác VLE theo tuần.	6
4	Các biến có giá trị thiếu trong tập dữ liệu (tổng 178,294 dòng), sắp xếp theo tỷ lệ thiếu giảm dần.	9

5	Kết quả chia tập train/test theo sinh viên.	11
6	Phân phối <code>imd_band</code> (%) theo Region (chuẩn hoá theo hàng, sắp xếp giảm dần theo cột '?'). Màu đậm hơn = tỷ trọng cao hơn trong hàng.	13
7	Phân phối <code>imd_band</code> (%) theo trình độ học vấn (chuẩn hoá theo hàng). Màu đậm hơn = tỷ trọng cao hơn trong hàng.	14
8	Giá trị trung bình các đặc trưng tĩnh theo nhóm kết quả.	18
9	Thống kê mô tả các đặc trưng động (tính trên tập huấn luyện).	21
10	Giá trị trung bình các đặc trưng động theo nhóm kết quả.	25

1 Giới thiệu

Báo cáo này trình bày quá trình phân tích khám phá dữ liệu (Exploratory Data Analysis – EDA) phục vụ bài toán *cảnh báo sớm rủi ro học tập* (early academic risk warning). Mục tiêu của bài toán là nhận diện sớm những sinh viên có nguy cơ **trượt môn** (Fail) hoặc **bỏ học** (Withdrawn) tại nhiều thời điểm trong suốt khoá học, từ đó giúp nhà trường can thiệp kịp thời.

Dữ liệu sử dụng là bộ **Open University Learning Analytics Dataset (OULAD)** do The Open University (Vương quốc Anh) công bố tháng 12 năm 2015. Bộ dữ liệu ghi lại thông tin về các học phần, sinh viên và toàn bộ tương tác của họ với Môi trường học tập trực tuyến (Virtual Learning Environment – VLE) trên bảy học phần được lựa chọn.

Quá trình phân tích hướng đến bốn mục tiêu chính:


1. Hiểu cấu trúc, quy mô và chất lượng của các bảng dữ liệu gốc; phát hiện các giá trị thiếu và điểm bất thường.
2. Xây dựng tập dữ liệu dạng *panel* (snapshot theo thời gian) phù hợp với bài toán dự báo sớm.
3. Khám phá mối quan hệ giữa các đặc trưng nhân khẩu học, hành vi học tập và kết quả cuối khoá.
4. Rút ra các định hướng cho bước xây dựng mô hình: lựa chọn đặc trưng, xử lý mất cân bằng nhãn và đa cộng tuyến.

2 Tổng quan bộ dữ liệu OULAD

Bộ dữ liệu OULAD được tổ chức thành bảy bảng dữ liệu liên kết với nhau qua các định danh duy nhất, bao gồm các nhóm thông tin: bài đánh giá, học phần, thông tin sinh viên, đăng ký học, kết quả bài đánh giá và nhật ký tương tác của sinh viên với hệ thống học trực tuyến (VLE). Sơ đồ quan hệ giữa các bảng được minh hoạ ở Hình 1.

Open University Learning Analytics Dataset (OULAD)

Entity Relationship Diagram — 7 bảng



Hình 1: Sơ đồ quan hệ thực thể (ERD) của bộ dữ liệu OULAD.

Quy mô tổng thể của bộ dữ liệu được tóm tắt trong Bảng 1.

Bảng 1: Thống kê tổng quan bộ dữ liệu OULAD.

Thực thể	Số lượng
Sinh viên tham gia khóa học	32,953
Đợt mở học phần	22
Trang/tài nguyên VLE	6,364
Nhật ký tương tác VLE	10,655,280
Bản ghi đăng ký học	32,953
Bài đánh giá	206
Bản ghi kết quả đánh giá	173,912
Tổng số thuộc tính	43

Mỗi đợt mở học phần được định danh bằng mã `code_presentation` gồm **năm khai giảng** kèm **một chữ cái chỉ tháng khai giảng**. Chữ cái này mã hoá tháng theo **vị trí của nó trong bảng chữ cái**: A là chữ thứ 1 ứng với tháng 1, B là chữ thứ 2 ứng với tháng 2, ..., J là chữ thứ 10 ứng với tháng 10. Trong bộ dữ liệu chỉ xuất hiện hai giá trị: B (**tháng 2**) và J (**tháng 10**). Ví dụ, mã 2013J là đợt khai giảng tháng 10 năm 2013, còn 2014B là đợt khai giảng tháng 2 năm 2014. Mọi mốc thời gian trong dữ liệu (ngày nộp bài, ngày đăng ký, ngày tương tác VLE...) đều được tính tương đối so với ngày bắt đầu khoá học (ngày 0), cho phép so sánh nhất quán giữa các đợt học khác nhau.

3 Phân tích dữ liệu đánh giá (Assessment)

3.1 Cấu trúc chung

Dữ liệu đánh giá được ghép với thông tin học phần để bổ sung độ dài của từng đợt học. Sau khi làm sạch, dữ liệu có các đặc điểm sau:


- Bộ dữ liệu gồm **7 học phần**: AAA, BBB, CCC, DDD, EEE, FFF và GGG. Trong đó FFF có nhiều bài đánh giá nhất với 52 bài.
- Có **4 đợt mở học phần**: 2013B, 2013J, 2014B và 2014J.
- Có **3 loại bài đánh giá**, trong đó TMA chiếm nhiều nhất với 106/206 bài ($\approx 51\%$):
 - **TMA** (*Tutor Marked Assessment*) — bài đánh giá do giảng viên hoặc trợ giảng chấm thủ công, thường là bài tập tự luận nộp theo từng mốc trong khoá học.
 - **CMA** (*Computer Marked Assessment*) — bài đánh giá được hệ thống chấm tự động bằng máy tính, thường ở dạng trắc nghiệm.
 - **Exam** (*bài thi cuối kỳ*) — bài thi tổng kết, quyết định phần lớn hoặc toàn bộ kết quả học phần.
- Toàn bộ 206 bài đánh giá đều có mã định danh duy nhất — **không có bài đánh giá nào bị trùng lặp**.

Bảng 2 tóm tắt thống kê mô tả các biến phân loại của dữ liệu đánh giá.

Bảng 2: Thống kê mô tả các biến phân loại của dữ liệu đánh giá.


Biến	N	Số nhóm	Giá trị phổ biến	Tần suất
code_module	206	7	FFF	52
code_presentation	206	4	2014J	57
assessment_type	206	3	TMA	106

Phân phối số bài đánh giá theo học phần và tỷ lệ các loại bài đánh giá lần lượt được thể hiện ở Hình 2 và Hình 3.



Hình 2: Phân phối số bài đánh giá theo học phần (code module).

Percentage of Assessment Types



Hình 3: Tỷ lệ các loại bài đánh giá (TMA, CMA, Exam).

3.2 Phân tích trọng số và phát hiện bất thường

Tổng trọng số (**weight**) của các bài đánh giá được tính theo từng cặp (học phần, đợt học), qua đó ghi nhận một số điểm đáng chú ý:

- Phần lớn học phần (AAA, BBB, DDD, EEE, FFF) có tổng trọng số = 200 theo quy ước chung: 100% cho nhóm bài TMA/CMA và 100% cho bài thi cuối kỳ. Ngoài ra, không phải học phần nào cũng được mở đủ cả 4 đợt — ví dụ AAA chỉ có 2013J và 2014J.
- **GGG có tổng trọng số = 100**: tất cả bài TMA và CMA của GGG đều có **weight** = 0, chỉ bài Exam mới có **weight** = 100. Nói cách khác, kết quả học phần GGG phụ thuộc **hoàn toàn** vào bài thi cuối kỳ.
- **CCC có tổng trọng số = 300**: học phần CCC có 2 bài Exam trong mỗi đợt (mỗi bài **weight** = 100), cộng với TMA + CMA = 100, dẫn đến tổng bằng 300.

- Ở học phần CCC, giá trị ngày thi bị thiếu (ký hiệu '?') ở các bài thuộc loại Exam.

3.3 Giá trị thiếu ở biến ngày thi

Kiểm tra các bài có giá trị ngày thi bị thiếu cho thấy:

- Giá trị '?' chỉ xuất hiện ở loại Exam, không có ở TMA hay CMA — đây là dạng **thiếu có tính hệ thống**, không ngẫu nhiên.
- Có 11/24 bản ghi Exam bị thiếu ngày, chiếm gần một nửa ($\approx 45.8\%$).
- Mức độ thiếu theo học phần:
 - AAA, BBB, CCC: thiếu hoàn toàn — không đợt học nào có ngày thi chính xác.
 - DDD: chỉ thiếu 1 đợt (2014J), 3 đợt còn lại đầy đủ.
 - EEE, FFF, GGG: đầy đủ ngày thi cho tất cả các đợt.
- Nhiều khả năng các học phần này có lịch thi linh hoạt nên ngày thi không được ấn định sẵn trong hệ thống. Do bài thi cuối kỳ thường nằm ngoài khoảng thời gian dự báo, ảnh hưởng thực tế của việc thiếu này là **không đáng kể**.

4 Phân tích hành vi tương tác VLE

Dữ liệu tương tác VLE được tổng hợp về mức **tuần**: với mỗi sinh viên, số lần click được cộng dồn theo tuần, trong đó tuần được tính bằng $\lfloor \text{ngày}/7 \rfloor$ kể từ ngày bắt đầu học phần. Sau khi tổng hợp, dữ liệu tương tác theo tuần còn **627,031** bản ghi — giảm khoảng 4 lần so với dữ liệu chi tiết ban đầu (2,518,170 dòng); mỗi bản ghi là tổng số click của một sinh viên trong một tuần.

4.1 Đặc điểm phân phối


Bảng 3 trình bày thống kê mô tả của số tuần (**week**) và số click theo tuần (**weekly_clicks**).

Bảng 3: Thống kê mô tả dữ liệu tương tác VLE theo tuần.

Biến	N	Trung bình	Độ lệch chuẩn	Min	Q1	Trung vị	Q3	Max
week	627,031	14.06	11.02	-4.00	4.00	13.00	23.00	38.00
weekly_clicks	627,031	63.16	96.59	1.00	9.00	30.00	78.00	6,999.00

- **Biến week:** giá trị nhỏ nhất = -4 cho thấy một số sinh viên đã truy cập VLE *trước* khi khoá học chính thức bắt đầu. 50% số bản ghi nằm trong khoảng tuần 4–23 (giai đoạn giữa khoá). Giá trị lớn nhất = 38 (≈ 9.5 tháng) phù hợp với độ dài các học phần trong OULAD (≈ 240 –270 ngày).
- **Biến weekly_clicks:** phân phối lệch phải nặng — trung vị chỉ bằng 30 trong khi trung bình lên tới 63.16, chứng tỏ giá trị trung bình bị đẩy lên bởi các giá trị ngoại lai; cá biệt có giá trị lớn nhất bằng 6,999 trong khi $Q_3 = 78$. Độ lệch chuẩn (96.59) còn lớn hơn cả giá trị trung bình, cho thấy mức độ phân tán rất lớn.

Để mô tả rõ hơn đuôi phải của phân phối, Hình 4 biểu diễn giá trị `weekly_clicks` theo các phân vị.



Hình 4: Giá trị `weekly_clicks` theo các phân vị (percentile).

- Từ P0 đến P75, `weekly_clicks` tăng chậm từ 1 đến khoảng 80 — phần lớn sinh viên tương tác ở mức vừa phải mỗi tuần.
- Từ P75 trở đi, đường cong dốc lên nhanh — dấu hiệu của phân phối lệch phải với đuôi dài.
- $P_{90} = 159$ và $P_{95} = 232$: nhóm 10% sinh viên tích cực nhất có lượng click gấp ≈ 2.5 lần mức trung bình chung (63.16).

5 Xây dựng tập dữ liệu dạng snapshot

5.1 Thiết kế panel theo thời gian

Để phù hợp với mục tiêu *dự báo sớm*, dữ liệu được tái cấu trúc thành dạng panel (dữ liệu bảng theo thời gian). Với mỗi mốc thời gian $T \in \{30, 60, 90, 120, 150, 180, 210, 240\}$ (ngày kể từ đầu khoá), ta tạo một *snapshot* thể hiện trạng thái của từng sinh viên tại thời điểm đó. Mỗi sinh viên xuất hiện tối đa 8 lần (8 snapshot).

Tại mỗi mốc T , quy trình tính đặc trưng như sau:

- **Lọc sinh viên còn hoạt động:** loại bỏ những sinh viên đã hủy đăng ký trước ngày T .
- **Đặc trưng VLE** (chỉ lấy dữ liệu đến tuần tương ứng với T): `total_clicks` (tổng click tích lũy), `active_weeks` (số tuần có tương tác), `avg_weekly_clicks` (click trung bình mỗi tuần).
- **Đặc trưng đánh giá** (chỉ lấy bài có hạn nộp $\leq T$ và đã nộp trước T): `num_submitted`, `avg_score` (điểm trung bình có trọng số), `avg_days_early` (độ sớm/trễ khi nộp), `num_failed` (số bài trượt, điểm < 40).
- **Đặc trưng tĩnh và nhãn:** thông tin nhân khẩu học của sinh viên và nhãn `final_result`.

Lưu ý: học phần GGG được loại khỏi tập dữ liệu do đặc thù trọng số bất thường đã phân tích ở trên — kết quả của học phần này phụ thuộc hoàn toàn vào bài thi cuối kỳ nên không phù hợp với cách dự báo dựa trên hành vi tích lũy.

5.2 Quy mô và giá trị thiếu

Tập dữ liệu thu được gồm **178,294 dòng** và **22 biến**, bao gồm thông tin nhân khẩu học, hành vi học tập (VLE), kết quả bài tập và kết quả cuối kỳ, với nhiều kiểu dữ liệu: 10 biến dạng phân loại, 10 biến số thực và 2 biến số nguyên.

Bảng 4 liệt kê các biến có giá trị thiếu cùng tỷ lệ tương ứng.

Bảng 4: Các biến có giá trị thiếu trong tập dữ liệu (tổng 178,294 dòng), sắp xếp theo tỷ lệ thiếu giảm dần.

Biến	Số dòng thiếu	Tỷ lệ thiếu (%)
<code>date_unregistration</code>	162,208	90.98
<code>avg_score</code>	18,532	10.39
<code>num_submitted</code>	16,183	9.08
<code>avg_days_early</code>	16,183	9.08
<code>num_failed</code>	16,183	9.08
<code>total_clicks</code>	3,035	1.70
<code>active_weeks</code>	3,035	1.70
<code>avg_weekly_clicks</code>	3,035	1.70


Nhận xét về giá trị thiếu:

- Biến **ngày hủy đăng ký** thiếu nhiều nhất ($\approx 91.0\%$) vì phần lớn sinh viên theo học đến hết khoá nên không có ngày hủy đăng ký — đây là dạng thiếu mang ý nghĩa tích cực.
- Các biến VLE (`total_clicks`, `active_weeks`, `avg_weekly_clicks`) thiếu $\approx 1.7\%$, nhiều khả năng do một số sinh viên chưa từng truy cập hệ thống.
- Các biến đánh giá (`avg_score`, `num_submitted`...) thiếu đáng kể ($\approx 9\text{--}10\%$), do một số sinh viên chưa nộp bài tại thời điểm dự báo.

Ngoài dạng thiếu thông thường (giá trị rỗng) nêu trên, biến `imd_band` còn có một dạng thiếu **được mã hoá bằng ký hiệu '?'** (khoảng 4% số sinh viên). Dạng thiếu này không xuất hiện khi thống kê giá trị rỗng nên cần được nhận diện và xử lý riêng; phân bố cụ thể sẽ được phân tích ở Mục 6.1.

5.3 Phân phối nhãn mục tiêu


Phân phối nhãn `final_result` ban đầu gồm bốn lớp (Hình 5):



Hình 5: Phân phối nhãn `final_result` (4 lớp).

- **Pass** chiếm tỷ lệ cao nhất với 89,944 bản ghi (50.4%).
- **Fail** đứng thứ hai với 50,525 bản ghi (28.3%) — gần 1/3 lượt đăng ký không đạt, là nhóm quan trọng nhất cần được dự báo sớm.
- **Distinction** chiếm 11.8% (21,024 bản ghi) — nhóm sinh viên xuất sắc.
- **Withdrawn** chiếm 9.4% (16,801 bản ghi) — lượt đăng ký bị hủy giữa chừng; nhóm này thường bộc lộ dấu hiệu sớm qua mức tương tác thấp.

Mỗi bản ghi là một bộ ba (sinh viên, học phần, đợt học) tại một snapshot T ; một sinh viên có thể xuất hiện nhiều lần nếu đăng ký nhiều học phần hoặc nhiều đợt. Với bài toán cảnh báo sớm, việc phân biệt Distinction với Pass là không cần thiết — mục tiêu là phát hiện sinh viên có nguy cơ trượt hoặc bỏ học. Do đó, **Distinction được gộp vào Pass** (Hình 6).



Hình 6: Phân phối nhãn sau khi gộp Distinction vào Pass (3 lớp).

Sau khi gộp, tỷ lệ Pass : Fail : Withdrawn = 62.2% : 28.3% : 9.4%, cho thấy tập dữ liệu có mức **mất cân bằng nhãn vừa phải** — cần lưu ý ở bước xây dựng mô hình.

5.4 Chia tập huấn luyện và kiểm tra

Tập dữ liệu được chia thành tập huấn luyện (train) và kiểm tra (test) theo **từng sinh viên**, đảm bảo toàn bộ lịch sử của một sinh viên chỉ nằm trong một tập duy nhất. Nếu chia theo từng dòng, cùng một sinh viên có thể xuất hiện ở cả train lẫn test với các snapshot khác nhau. Khi đó, mô hình được huấn luyện trên chính hành vi của sinh viên có mặt trong tập kiểm tra, dẫn đến hiện tượng rò rỉ dữ liệu (data leakage) và làm sai lệch kết quả đánh giá.

Với tỷ lệ train:test = 80 : 20, kết quả chia được tóm tắt ở Bảng 5.

Bảng 5: Kết quả chia tập train/test theo sinh viên.

Tập	Số sinh viên	Số snapshot
Train	17,921	142,384
Test	4,481	35,910


6 Phân tích khám phá các đặc trưng tĩnh

Thông tin tĩnh của sinh viên được xem xét theo hai nhóm phục vụ phân tích:

- **Thông tin nhân khẩu học** (`gender`, `region`, `age_band`, `imd_band`, `highest_education`, `disability`), xét mỗi sinh viên một lần (loại bỏ trùng lặp).
- **Đặc trưng hành vi tĩnh** (`num_of_prev_attempts`, `studied_credits`) gắn với từng lượt đăng ký học phần, kèm nhãn kết quả `final_result`.

6.1 Chỉ số thiếu thốn kinh tế (`imd_band`)

Biến `imd_band` đo mức độ thiếu thốn kinh tế theo khu vực địa lý (Index of Multiple Deprivation), được kỳ vọng có liên quan đến kết quả học tập. Hình 7 thể hiện phân phối của biến này.



Hình 7: Phân phối `imd_band` trong tập huấn luyện (nhóm '?' được tô màu cam).

Phân phối `imd_band` tập trung cao nhất ở band 30–40% (1,925 sinh viên) và giảm dần về hai phía. Nhìn chung, phần lớn sinh viên đến từ các khu vực có mức độ thiếu thốn trung bình đến cao, trong khi số sinh viên ở các khu vực khá giả ít hơn. Đáng chú ý, có 720 sinh viên ($\approx 4.2\%$) mang giá trị '?', cần được xử lý trước khi đưa vào mô hình.

Giá trị thiếu theo vùng. Giá trị '?' trong `imd_band` tập trung gần như hoàn toàn ở hai vùng: North Region (64.86%) và Ireland (25.42%) — cộng lại

chiếm $\approx 90.3\%$ tổng số giá trị thiếu; các vùng còn lại chỉ đóng góp $\approx 9.7\%$. Xét theo chiều ngược lại (tỷ lệ '?' trong mỗi vùng):

- North Region (45.65%) và Ireland (23.40%) có tỷ lệ '?' vượt trội so với tất cả các vùng còn lại (đều $\leq 2\%$), cho thấy tình trạng thiếu dữ liệu này gắn với đặc thù của từng vùng địa lý.
- North Western (0–10%: 23.09%), Yorkshire (0–10%: 19.42%) và West Midlands (0–10%: 17.52%) là những vùng tập trung nhiều sinh viên thuộc band IMD thấp nhất. London cũng nghiêng về các mức IMD thấp (10–20%: 19.30%; 20–30%: 18.37%).
- South Region (90–100%: 21.74%; 80–90%: 15.55%) và South East Region tập trung ở các band cao. East Anglian Region có xu hướng tương tự.
- Scotland, East Midlands, Wales và South West Region không lệch rõ về phía nào, các band dao động tương đối đều trong khoảng 7–13%.

Bảng 6 trình bày đầy đủ phân phối `imd_band` theo từng vùng (chuẩn hoá theo hàng), làm rõ các nhận xét trên.

Bảng 6: Phân phối `imd_band` (%) theo Region (chuẩn hoá theo hàng, sắp xếp giảm dần theo cột '?'). Màu đậm hơn = tỷ trọng cao hơn trong hàng.

Region	0-10	10-20	20-30	30-40	40-50	50-60	60-70	70-80	80-90	90-100	?
North Region	8.11	10.85	6.74	5.96	5.87	3.71	3.52	4.69	4.50	0.39	45.65
Ireland	9.72	10.10	6.91	7.80	5.75	8.82	7.80	6.65	6.65	6.39	23.40
South Region	1.05	4.50	5.73	6.55	10.93	10.40	8.88	12.62	15.55	21.74	2.05
West Midlands Region	17.52	14.43	11.03	8.99	10.35	7.48	8.61	8.99	5.74	4.98	1.89
South West Region	3.99	7.29	10.74	15.57	12.65	12.19	10.20	12.58	7.90	6.67	0.23
Yorkshire Region	19.42	12.21	12.31	10.48	9.62	9.62	7.31	10.48	5.00	3.37	0.19
Scotland	8.14	7.76	10.29	11.27	10.80	12.21	10.38	9.49	9.92	9.54	0.19
North Western Region	23.09	12.23	13.46	12.23	7.79	7.72	7.10	7.31	5.67	3.35	0.07
East Anglian Region	3.25	4.60	8.36	10.38	12.17	11.33	12.06	12.73	11.89	13.24	0.00
London Region	10.59	19.30	18.37	14.63	10.21	8.66	5.98	4.92	4.55	2.80	0.00
East Midlands Region	7.43	12.54	11.06	10.64	10.64	9.74	10.40	8.42	10.64	8.50	0.00
South East Region	2.58	7.49	8.61	11.46	10.85	11.02	13.95	10.42	11.20	12.40	0.00
Wales	11.87	10.71	12.67	11.51	9.40	9.98	8.96	8.81	8.89	7.21	0.00

Giá trị thiếu theo trình độ học vấn. Xét quan hệ giữa `imd_band` và `highest_education`:


- *No Formal quals* tập trung mạnh ở các band thấp (20–30%: 22.50%; 0–10%: 18.75%...), gần như không xuất hiện ở band 80–90%. Tỷ lệ '?' = 9.38% (cao thứ hai).
- *Lower Than A Level* giảm dần từ band thấp đến band cao, từ 11.43% xuống còn 6.39%. Tỷ lệ '?' = 3.72%.
- *A Level or Equivalent* phân phối tương đối đồng đều (8–11%). Tỷ lệ '?' = 2.34%.
- *HE Qualification* phân bố đồng đều chủ yếu ở các band trung bình đến cao, nhóm 90–100% chiếm tỷ lệ lớn nhất (10.95%). Tỷ lệ '?' = 6.68%.
- *Post Graduate Qualification* có tỷ lệ '?' cao nhất (41.85%), gần như không có sinh viên ở band 0–10%, tập trung rõ ở band 90–100% (25%).

Bảng 7 trình bày đầy đủ các con số này.


Bảng 7: Phân phối *imd_band* (%) theo trình độ học vấn (chuẩn hoá theo hàng). Màu đậm hơn = tỷ trọng cao hơn trong hàng.

Highest education	0-10	10-20	20-30	30-40	40-50	50-60	60-70	70-80	80-90	90-100	?
No Formal quals	18.75	16.25	22.50	18.12	1.88	5.00	5.62	1.25	0.00	1.25	9.38
Lower Than A Level	11.43	11.37	11.55	10.70	10.05	9.56	8.59	8.67	7.95	6.39	3.72
A Level or Equivalent	8.72	9.90	9.97	10.89	10.65	10.16	9.62	10.02	8.93	8.80	2.34
HE Qualification	6.65	7.45	9.86	10.60	9.48	9.48	8.92	9.76	10.18	10.95	6.68
Post Graduate Qualification	0.00	4.35	6.52	1.63	1.63	3.80	4.89	1.63	8.70	25.00	41.85

Hình 8 và Hình 9 trực quan hoá xu hướng này. Ở nhóm band cực trị (Hình 8), hai band thấp (0–10%, 10–20%) và hai band cao (80–90%, 90–100%) biến động ngược chiều nhau theo trình độ học vấn: tỷ trọng band thấp giảm mạnh còn band cao tăng dần khi học vấn tăng — đặc biệt band 90–100% tăng vọt ở nhóm Post Graduate Qualification. Bốn đường gần như giao nhau quanh mức *A Level or Equivalent*, cho thấy đây là ngưỡng học vấn mà mối liên hệ với *imd_band* bắt đầu đảo chiều. Ở nhóm band trung gian (20–80%, Hình 9), các đường biến động khá tương đồng và không band nào nổi bật hẳn.




Hình 8: Tỷ lệ imd_band theo trình độ học vấn — nhóm band cực trị (0–20% và 80–100%).



Hình 9: Tỷ lệ imd_band theo trình độ học vấn — nhóm band trung gian (20–80%).


6.2 Tình trạng khuyết tật và lịch sử học lại (disability, num_of_prev_attempts)

Phân phối disability trong tập huấn luyện được thể hiện ở Hình 10: phần lớn sinh viên không khai báo khuyết tật (91.1%), nhóm có khuyết tật chỉ chiếm 8.9%.




Hình 10: Phân phối tình trạng khuyết tật (*disability*).

Bên cạnh khuyết tật, biến `num_of_prev_attempts` cho biết số lần sinh viên đã đăng ký học phần này trước đây, qua đó phân biệt sinh viên học lần đầu với sinh viên học lại (*retake*). Phân phối được thể hiện ở Hình 11.



Hình 11: Phân phối số lần đăng ký học phần trước đó.


Từ biến này, ta tạo biến nhị phân `is_retake_the_course`: nhận giá trị 1 nếu sinh viên đã từng đăng ký học phần trước đó và 0 nếu học lần đầu. Các mức học lại (1, 2, 3...) được gộp thành một nhóm duy nhất, vì điều quan trọng là sinh viên *đã từng* phải học lại hay chưa, chứ không phải học lại bao nhiêu lần (Hình 12).



Hình 12: Phân phối biến `is_retake_the_course`.

Phần lớn sinh viên (86.5%) đăng ký học phần lần đầu, 13.5% còn lại là các trường hợp học lại. Tỷ lệ này giảm rất nhanh theo số lần học lại: học lại lần đầu chiếm 10.8%, lần hai chỉ còn 2.1%, và từ ba lần trở lên rất hiếm ($< 0.5\%$). Điều này cho thấy phần lớn sinh viên không đăng ký học lại sau khi trượt học phần.

Học lại và tình trạng khuyết tật. Hình 13 cho thấy nhóm sinh viên khuyết tật có tỷ lệ học lại (20.1%) cao hơn rõ rệt so với nhóm không khuyết tật (12.9%). Kết quả này gợi ý khuyết tật là một yếu tố rủi ro trong học tập: nhóm này gặp nhiều trở ngại hơn nên phải học lại thường xuyên hơn.




Hình 13: Tỷ lệ học lại theo tình trạng khuyết tật.

6.3 Phân tích theo nhãn mục tiêu

6.3.1 Đặc điểm ba nhóm kết quả

Giá trị trung bình của các đặc trưng tính theo từng nhóm kết quả được chuẩn hoá và biểu diễn bằng biểu đồ radar (Hình 14). Từ biểu đồ, có thể nhận thấy ba nhóm mang ba đặc điểm rủi ro khác biệt:



Hình 14: Biểu đồ radar các đặc trưng tính theo nhóm kết quả.

Giá trị trung bình của từng đặc trưng theo nhóm kết quả — số liệu gốc của biểu đồ radar — được trình bày ở Bảng 8.

Bảng 8: Giá trị trung bình các đặc trưng tính theo nhóm kết quả.

Nhóm	Tỷ lệ học lại	Số tín chỉ TB	Số lần học trước TB	Tỷ lệ khuyết tật	Tỷ lệ tuổi ≤ 35
Pass	9.7%	78.23	0.12	7.4%	67.7%
Fail	20.5%	80.98	0.27	9.5%	75.4%
Withdrawn	15.5%	87.02	0.19	13.6%	71.4%

- **Pass** là nhóm an toàn nhất: đa giác của nhóm này nhỏ nhất, tức các chỉ số rủi ro đều ở mức thấp. Phần lớn sinh viên học lần đầu với khối lượng đăng ký vừa phải, tỷ lệ khuyết tật thấp nhất; tỷ lệ sinh viên trẻ cũng thấp nhất,


cho thấy nhóm lớn tuổi có xu hướng hoàn thành học phần tốt hơn.

- **Fail** nổi bật ở các đặc trưng về lịch sử học tập: số lần học trước và tỷ lệ học lại đều cao nhất, tỷ lệ sinh viên trẻ cũng cao nhất. Trong khi đó, khối lượng tín chỉ không cao hơn Pass đáng kể — vấn đề của nhóm này nằm ở việc học lại nhiều lần mà kết quả chưa cải thiện, chứ không phải do học quá tải.
- **Withdrawn** có xu hướng ngược lại: khối lượng tín chỉ và tỷ lệ khuyết tật cao nhất, trong khi các chỉ số học lại chỉ ở mức trung bình. Nguyên nhân bỏ học vì vậy thiên về quá tải học tập và các trở ngại cá nhân hoặc sức khỏe.

Như vậy, Fail và Withdrawn đại diện cho hai dạng rủi ro khác nhau: Fail gắn với lịch sử học lại và nhóm sinh viên trẻ, còn Withdrawn gắn với khối lượng đăng ký và tình trạng khuyết tật.

6.3.2 Kết quả theo trình độ học vấn

Hình 15 thể hiện tỷ lệ Pass / Fail / Withdrawn theo từng bậc học vấn khi nhập học.




Hình 15: Tỷ lệ kết quả học tập theo trình độ học vấn.

- **Pass** tăng liên tục theo trình độ học vấn: từ 38.3% (*No Formal quals*) lên 73.1% (*Post Graduate Qualification*).
- **Fail** giảm theo chiều ngược lại: từ 34.9% xuống còn 11.5% — sinh viên có nền tảng học vấn cao hơn ít trượt môn hơn.
- **Withdrawn** cũng giảm nhưng chậm hơn Fail.

Đáng chú ý, *No Formal quals* là nhóm rủi ro cao nhất: tỷ lệ Pass chỉ đạt 38.3%, trong khi Fail và Withdrawn cộng lại chiếm tới **61.7%** — đây là nhóm duy nhất có tỷ lệ không hoàn thành vượt quá tỷ lệ hoàn thành. *Post Graduate Qualification* là nhóm duy nhất có tỷ lệ Withdrawn (15.4%) cao hơn Fail (11.5%): sinh viên sau đại học ít trượt môn nhưng lại có xu hướng rút lui nhiều hơn, có thể vì lý do cá nhân hoặc công việc. Khoảng cách giữa Pass và hai nhóm còn lại mở rộng rõ rệt từ *A Level or Equivalent* trở lên, cho thấy đây có thể là ngưỡng mà nền tảng học vấn bắt đầu tạo ra lợi thế rõ ràng.

6.3.3 Kết quả theo chỉ số thiếu thôn kinh tế

Hình 16 thể hiện tỷ lệ Pass / Fail / Withdrawn theo từng nhóm IMD.



Hình 16: Tỷ lệ kết quả học tập theo nhóm imd_band.

- **Pass** tăng đều từ 43.4% (0–10%) lên 65.3% (90–100%) — sinh viên từ khu vực khá giả hơn có tỷ lệ hoàn thành cao hơn.
- **Fail** giảm từ 33.8% xuống 18.5% — nghịch biến với mức độ kinh tế, giảm tương đối đều.
- **Withdrawn** giảm nhẹ và không đều, dao động 18–23% ở các band giữa.

Đáng chú ý, mối liên hệ giữa tỷ lệ Pass và IMD **yếu hơn** rõ rệt so với mối liên hệ giữa Pass và trình độ học vấn ở mục trước: tỷ lệ Pass tăng theo học vấn với biên độ lớn hơn (từ 38.3% lên 73.1%) so với theo IMD (từ 43.4% lên 65.3%). Điều này gợi ý **nền tảng học vấn ảnh hưởng đến kết quả học tập nhiều hơn điều kiện kinh tế**. Ngoài ra, tỷ lệ Withdrawn gần như không thay đổi theo IMD, và nhóm '?' có tỷ lệ Pass cao bất thường (71.6% — cao nhất trong tất cả các nhóm).

7 Phân tích khám phá các đặc trưng động

Các đặc trưng động được tính trong khoảng thời gian $[0, T]$ tại mỗi mốc dự đoán, phản ánh mức độ tương tác VLE và kết quả bài kiểm tra tích lũy đến thời điểm đó. Bảy đặc trưng động gồm: `total_clicks`, `active_weeks`, `avg_weekly_clicks`, `num_submitted`, `avg_score`, `num_failed` và `avg_days_early`.

7.1 Thống kê mô tả

Thống kê mô tả của bảy đặc trưng động được trình bày ở Bảng 9.


Bảng 9: Thống kê mô tả các đặc trưng động (tính trên tập huấn luyện).

Đặc trưng	N	Trung bình	Độ lệch chuẩn	Min	Q1	Trung vị	Q3	Max
<code>total_clicks</code>	139,934	1,072.27	1,358.44	1.00	269.00	617.00	1,334.00	23,115.00
<code>active_weeks</code>	139,934	15.65	9.21	1.00	8.00	14.00	22.00	39.00
<code>avg_weekly_clicks</code>	139,934	60.74	56.40	1.00	25.44	44.09	76.92	1,070.50
<code>num_submitted</code>	129,388	3.81	2.68	1.00	2.00	3.00	5.00	14.00
<code>avg_score</code>	127,544	73.54	15.51	0.00	64.73	76.00	85.00	100.00
<code>num_failed</code>	129,388	0.16	0.49	0.00	0.00	0.00	0.00	8.00
<code>avg_days_early</code>	129,388	0.94	8.10	-123.00	-1.50	0.00	1.50	236.00

- Các đặc trưng VLE lệch phải mạnh: `total_clicks` có độ lệch chuẩn (1,358) lớn hơn cả giá trị trung bình (1,072), giá trị lớn nhất lên tới 23,115; `avg_weekly_clicks` cũng tương tự (trung bình 60.7 nhưng giá trị lớn nhất 1,070.5).
- `num_failed` có giá trị nhỏ nhất, trung vị và Q_3 đều bằng 0 — phần lớn sinh viên không trượt bài nào trong khoảng thời gian quan sát. Trung bình chỉ đạt 0.16 nhưng giá trị lớn nhất lên tới 8, tức vẫn có một nhóm nhỏ trượt nhiều bài.
- `avg_days_early` trải trên khoảng giá trị rất rộng: từ -123 (nộp trễ 123 ngày) đến 236 (nộp sớm 236 ngày). Trung vị bằng 0, với $Q_1 = -1.5$ và $Q_3 = 1.5$: khoảng một nửa số sinh viên nộp bài trong vòng ± 1.5 ngày quanh hạn nộp.
- `avg_score` tương đối tập trung: $Q_1 = 64.7$ và $Q_3 = 85$ — phần lớn sinh viên đạt điểm trung bình ở mức khá trở lên.

7.2 Số sinh viên còn học theo thời gian

Hình 17 thể hiện số sinh viên còn hoạt động tại mỗi mốc dự đoán.




Hình 17: Số sinh viên còn hoạt động theo mốc dự đoán (mỗi 30 ngày).

- Số sinh viên còn hoạt động giảm đều qua các mốc: từ **17,921** (ngày 30) xuống **15,171** (ngày 240) — tổng cộng **2,750 sinh viên** ($\approx 15.3\%$) rút khỏi khoá học trong 210 ngày quan sát.
- Mức giảm lớn nhất rơi vào giai đoạn đầu (từ ngày 30 sang ngày 60: -629), sau đó chậm dần và ổn định hơn về cuối khoá (từ ngày 180 sang ngày 210: -214 ; từ ngày 210 sang ngày 240: -208 — chỉ bằng khoảng $1/3$ giai đoạn đầu).
- Trung bình mỗi 30 ngày có ≈ 393 sinh viên rời khoá học; tuy nhiên con số trung bình này chưa phản ánh đúng thực tế, vì phần lớn trường hợp rút lui tập trung ở giai đoạn đầu khoá.

7.3 Phân tích tương quan

Ma trận tương quan giữa các đặc trưng động được thể hiện ở Hình 18.




Hình 18: Ma trận tương quan giữa các đặc trưng động.

- **Cụm hoạt động trực tuyến** (`total_clicks`, `active_weeks`, `avg_weekly_clicks`) tương quan chặt với nhau; đặc biệt `total_clicks` và `avg_weekly_clicks` gần như đo lường cùng một khía cạnh — đưa cả hai vào mô hình có thể gây **đa cộng tuyến** (multicollinearity). `active_weeks` có tương quan khá cao với `num_submitted`, nhưng số click mỗi tuần lại gần như không liên quan đến số bài nộp — cho thấy lượng click không phải lúc nào cũng phản ánh việc học có mục đích.
- **Cặp nghịch chiều rõ nhất** là `avg_score` và `num_failed`: điểm trung bình cao đi kèm số bài trượt thấp, do đó có thể cân nhắc chỉ giữ lại một trong hai đặc trưng.
- `avg_days_early` tương quan thấp với hầu hết các đặc trưng còn lại — đây là một tín hiệu tương đối độc lập, phản ánh thói quen quản lý thời gian của sinh viên.
- `num_failed` gần như không tương quan với các đặc trưng hoạt động — tương

tác nhiều hay học đều đặn không bảo đảm tránh được điểm kém; kết quả còn phụ thuộc vào chất lượng của việc học.

Quan hệ giữa `avg_score` và `num_failed` được thể hiện rõ hơn qua biểu đồ bong bóng ở Hình 19.




Hình 19: Biểu đồ bong bóng: `avg_score` theo `num_failed`.

Phần lớn sinh viên không trượt bài nào (`num_failed` = 0) và có `avg_score` tập trung ở mức cao, rõ nhất trong vùng 80–100 điểm. Khi số bài trượt tăng, số sinh viên giảm dần và điểm trung bình phân tán hơn. Tuy nhiên, ở các mức `num_failed` thấp (1–5) vẫn có những sinh viên đạt điểm khá cao. Đây là lý do hai đặc trưng này không thể thay thế cho nhau: `num_failed` nắm bắt được một dạng rủi ro mà điểm trung bình bỏ sót — sinh viên học ổn định nhưng bỏ hoặc trượt một vài bài, có thể do thiếu chuyên cần hoặc do hoàn cảnh cá nhân.

7.4 Đặc trưng động theo nhãn mục tiêu

Biểu đồ radar các đặc trưng động theo nhóm kết quả (Hình 20) làm rõ hơn sự khác biệt giữa các nhóm.



Hình 20: Biểu đồ radar các đặc trưng động theo nhóm kết quả.

Giá trị trung bình các đặc trưng động theo nhóm kết quả được trình bày ở Bảng 10.


Bảng 10: Giá trị trung bình các đặc trưng động theo nhóm kết quả.

Nhóm	total_clicks	active_weeks	avg_weekly_clicks	num_submitted	avg_score	num_failed	avg_days_early
Pass	1,377.99	18.48	70.24	4.27	78.21	0.09	1.59
Fail	548.59	11.06	42.49	3.08	63.48	0.33	-0.19
Withdrawn	542.78	9.93	50.11	2.29	65.47	0.27	-0.91

- **Pass** chiếm diện tích lớn nhất, vượt trội ở cả ba đặc trưng tương tác VLE (`active_weeks`, `total_clicks`, `avg_weekly_clicks`) lẫn số bài nộp. Đây là nhóm duy nhất vừa duy trì mức độ tham gia cao, vừa đạt kết quả bài đánh giá tốt.
- **Fail** nổi bật nhất ở số bài trượt (`num_failed`), cao hơn cả hai nhóm còn lại, trong khi số bài nộp tương đương nhóm Pass. Như vậy, sinh viên Fail vẫn nộp bài đầy đủ nhưng kết quả không đạt yêu cầu — dấu hiệu của khó khăn học tập kéo dài.

- **Withdrawn** thì ngược lại: số bài nộp thấp nhất trong ba nhóm, còn số bài trượt gần như bằng 0. Điều này không có nghĩa là họ làm bài tốt — họ nộp quá ít bài nên hầu như không có bài nào bị tính trượt. Đáng chú ý, những bài đã nộp vẫn đạt điểm ở mức trung bình khá, cho thấy nhóm này bỏ học không hẳn vì học kém, mà nhiều khả năng do mất dần sự gắn kết với khoá học.

Cuối cùng, xét `avg_days_early` theo nhóm kết quả (Hình 21): Pass là nhóm duy nhất có giá trị dương (+1.59 ngày, tức nộp trước hạn), thể hiện thái độ học tập chủ động. Hai nhóm còn lại đều mang giá trị âm, trong đó Withdrawn nộp trễ nhiều nhất (−0.91 ngày, gấp gần 5 lần mức −0.19 ngày của Fail) — phù hợp với xu hướng giảm dần sự gắn kết đã ghi nhận ở trên. Tuy vậy, mức chênh lệch giữa ba nhóm đều nhỏ (dưới 2 ngày), nên khi đứng một mình, `avg_days_early` có thể chưa đủ mạnh để phân biệt các nhóm.



Hình 21: Giá trị trung bình `avg_days_early` theo nhóm kết quả.

8 Đề xuất các mô hình học máy

Từ quá trình phân tích khám phá dữ liệu, có thể rút ra một số đặc điểm của dữ liệu ảnh hưởng trực tiếp đến việc lựa chọn thuật toán:

- Bài toán ở dạng **phân loại nhị phân và mất cân bằng nhãn**: gộp hai nhóm Fail và Withdrawn thành nhóm **có nguy cơ** (At-risk), nhóm Pass còn lại; nhóm có nguy cơ chiếm tỷ lệ nhỏ hơn.

- Dữ liệu gồm **nhiều kiểu đặc trưng**: vừa có biến phân loại (khu vực, trình độ học vấn, `imd_band...`) vừa có biến số (số click, điểm trung bình, số bài nộp...).
- Giữa các đặc trưng tồn tại **quan hệ phi tuyến và tương tác**, đồng thời một số nhóm đặc trưng có **đa cộng tuyến** (cụm hoạt động trực tuyến).
- Nhiều đặc trưng **lệch phải mạnh**, có **giá trị ngoại lai** và tồn tại **giá trị thiếu**.

Dựa trên các đặc điểm này, bốn thuật toán sau được đề xuất và đưa vào thử nghiệm trong nghiên cứu: Logistic Regression, Random Forest, CatBoost và LightGBM. Ưu và nhược điểm của từng thuật toán — xét trong bối cảnh dữ liệu nêu trên — được trình bày dưới đây.

8.1 Logistic Regression

Ưu điểm:

- Đơn giản, huấn luyện nhanh, phù hợp làm mô hình cơ sở (baseline) để đối chiếu với các mô hình phức tạp hơn.
- Khả năng diễn giải cao: hệ số hồi quy cho biết chiều và mức độ ảnh hưởng của từng đặc trưng đến nguy cơ — thuận lợi khi cần giải thích kết quả cho nhà trường.
- Cho ra xác suất dự báo, dễ điều chỉnh ngưỡng cảnh báo theo nhu cầu.

Nhược điểm:

- Giả định quan hệ tuyến tính nên khó nắm bắt các quan hệ phi tuyến và tương tác giữa các đặc trưng mà EDA đã chỉ ra, trừ khi tự thêm số hạng tương tác một cách thủ công.
- Nhạy cảm với đa cộng tuyến — hệ số của cụm đặc trưng hoạt động trực tuyến dễ trở nên bất ổn và khó diễn giải.
- Nhạy với đặc trưng lệch và giá trị ngoại lai; cần chuẩn hoá dữ liệu số và mã hoá biến phân loại trước khi huấn luyện.
- Không tự xử lý được giá trị thiếu; bắt buộc phải thực hiện bước điền khuyết (imputation) dữ liệu trước khi đưa vào mô hình.

8.2 Random Forest

Ưu điểm:

- Tự nắm bắt quan hệ phi tuyến và tương tác giữa các đặc trưng mà không cần khai báo thủ công.
- Bền vững với giá trị ngoại lai; hầu như không cần chuẩn hoá dữ liệu.
- Cơ chế tổng hợp nhiều cây (bagging) giúp giảm phương sai, hạn chế học vẹt (overfit); đồng thời cung cấp thước đo độ quan trọng của đặc trưng.

Nhược điểm:

- Mô hình công kênh (gồm nhiều cây), tốc độ dự báo chậm hơn và khó diễn giải chi tiết so với hồi quy.
- Với dữ liệu mất cân bằng, cần kết hợp thêm trọng số lớp hoặc kỹ thuật lấy mẫu lại mới nhận diện tốt nhóm thiểu số.
- Trên dữ liệu dạng bảng, độ chính xác thường thấp hơn một chút so với các phương pháp cây tăng cường (boosting).
- Các thư viện phổ biến (như `scikit-learn`) không hỗ trợ xử lý giá trị thiếu trực tiếp. Thêm vào đó, dù độ chính xác không bị ảnh hưởng bởi đa cộng tuyến, nhưng các biến tương quan mạnh sẽ làm sai lệch thước đo độ quan trọng của đặc trưng (Feature Importance).

8.3 CatBoost

Ưu điểm:

- Xử lý trực tiếp và hiệu quả các đặc trưng phân loại mà không cần mã hoá thủ công — rất phù hợp vì dữ liệu có nhiều biến phân loại (khu vực, trình độ học vấn, `imd_band...`).
- Có cơ chế điều chuẩn (regularization) mạnh tích hợp sẵn, giúp mô hình ổn định và ít học vẹt ngay cả khi chưa tinh chỉnh nhiều.
- Nắm bắt tốt quan hệ phi tuyến và tương tác, bền vững với ngoại lai, hỗ trợ bù đắp mất cân bằng nhãn và tự động xử lý giá trị thiếu hiệu quả.
- Tốc độ dự báo (inference) cực kỳ nhanh nhờ cấu trúc cây đối xứng (oblivious trees), thuận lợi khi triển khai hệ thống cảnh báo thời gian thực.

Nhược điểm:

- Thời gian huấn luyện thường lâu hơn và tốn tài nguyên hơn LightGBM.
- Vẫn là mô hình dạng “hộp đen”, cần công cụ hỗ trợ (như SHAP) để diễn giải chi tiết.
- Kích thước mô hình (model size) khi lưu trữ thường nặng hơn so với các thuật toán cây khác.

8.4 LightGBM

Ưu điểm:

- Huấn luyện rất nhanh và tiết kiệm bộ nhớ, phù hợp với tập dữ liệu lớn (hàng trăm nghìn bản ghi khi tính theo nhiều mốc thời gian).
- Nắm bắt tốt quan hệ phi tuyến và tương tác; bền vững với đa cộng tuyến và giá trị ngoại lai.
- Tự động xử lý được giá trị thiếu và đặc trưng phân loại; hỗ trợ trọng số lớp để bù mất cân bằng nhãn.

Nhược điểm:

- Dễ học vẹt nếu không tinh chỉnh cẩn thận — cơ chế phát triển cây theo lá (leaf-wise) có thể tạo ra cây sâu và lệch, nhất là khi dữ liệu tại một số mốc thời gian còn ít.
- Nhạy với việc chọn siêu tham số, cần tinh chỉnh kỹ để đạt hiệu quả tốt.
- Là mô hình dạng “hộp đen”, khó diễn giải trực tiếp.

Bốn thuật toán trên sẽ được huấn luyện và so sánh ở giai đoạn xây dựng mô hình nhằm lựa chọn phương án phù hợp nhất cho bài toán cảnh báo sớm.