

TRƯỜNG ĐẠI HỌC QUY NHƠN
KHOA TOÁN & THỐNG KÊ



TIỂU LUẬN MÔN HỌC:
PHÂN TÍCH DỮ LIỆU KHOA HỌC CHUYÊN NGÀNH

CẢNH BÁO SỚM RỦI RO HỌC TẬP
TỪ DỮ LIỆU TƯƠNG TÁC TRỰC TUYẾN:
XÂY DỰNG, SO SÁNH VÀ DIỄN GIẢI
CÁC MÔ HÌNH HỌC MÁY
TRÊN BỘ DỮ LIỆU OULAD

Trình độ đào tạo: Thạc sĩ

Học viên thực hiện: Nguyễn Hồ Bảo Thiên

Mã số sinh viên: 8282548017

Lớp: Khoa học dữ liệu K28B

Giảng viên hướng dẫn: TS. Hồ Văn Lâm

Gia Lai, 2026

Mục lục

Mở đầu	1
1 Cơ sở lý thuyết	3
1.1 Tổng quan nội dung lý thuyết	3
1.2 Hồi quy Logistic (Logistic Regression)	4
1.2.1 Mô hình xác suất	4
1.2.2 Hàm mất mát, regularization và trọng số lớp	5
1.3 Cây quyết định (Decision Tree) và Rừng ngẫu nhiên (Random Forest)	6
1.3.1 Decision Tree	6
1.3.2 Bagging (Bootstrap Aggregating)	7
1.3.3 Random Forest và độ quan trọng đặc trưng	7
1.4 Gradient Boosting và CatBoost	8
1.4.1 Nguyên lý Gradient Boosting	8
1.4.2 Ordered Boosting và Ordered Target Statistics	9
1.4.3 Cây đối xứng (Oblivious Trees)	10
1.5 LightGBM	11
1.5.1 Tăng trưởng cây theo lá (Leaf-wise Growth)	11
1.5.2 Tối ưu hiệu quả huấn luyện: GOSS và EFB	12
1.6 Tối ưu Bayesian (Bayesian Optimization)	13
1.7 Diễn giải mô hình bằng SHAP	14
2 Phân tích khám phá dữ liệu (EDA)	17
2.1 Tổng quan bộ dữ liệu OULAD	17
2.2 Phân tích dữ liệu đánh giá (Assessment)	19
2.2.1 Cấu trúc chung	19
2.2.2 Phân tích trọng số và phát hiện bất thường	21
2.2.3 Giá trị thiếu ở biến ngày thi	22

2.3	Phân tích hành vi tương tác VLE	22
2.3.1	Đặc điểm phân phối	22
2.4	Xây dựng tập dữ liệu dạng snapshot	24
2.4.1	Thiết kế panel theo thời gian	24
2.4.2	Quy mô và giá trị thiếu	24
2.4.3	Phân phối nhãn mục tiêu	25
2.4.4	Chia tập huấn luyện và kiểm tra	27
2.5	Phân tích khám phá các đặc trưng tĩnh	28
2.5.1	Chỉ số thiếu thốn kinh tế (<code>imd_band</code>)	28
2.5.2	Tình trạng khuyết tật và lịch sử học lại (<code>disability,</code> <code>num_of_prev_attempts</code>)	31
2.5.3	Phân tích theo nhãn mục tiêu	34
2.6	Phân tích khám phá các đặc trưng động	37
2.6.1	Thống kê mô tả	37
2.6.2	Số sinh viên còn học theo thời gian	37
2.6.3	Phân tích tương quan	38
2.6.4	Đặc trưng động theo nhãn mục tiêu	40
3	Xây dựng và so sánh mô hình	43
3.1	Tiền xử lý dữ liệu	43
3.2	Khảo sát sơ bộ theo các mốc dự đoán	45
3.2.1	Thiết lập thử nghiệm	45
3.2.2	Kết quả theo thời gian	46
3.2.3	Lựa chọn mốc dự đoán cho phân tích chuyên sâu	49
3.3	Phương pháp xây dựng mô hình	50
3.3.1	Các thuật toán sử dụng	50
3.3.2	Xử lý mất cân bằng nhãn	50
3.3.3	Thiết lập thực nghiệm	51
3.4	Kết quả trên bộ đặc trưng đầy đủ	51
3.5	Độ quan trọng của đặc trưng	53
3.6	Rút gọn đặc trưng: Top-10 và Top-5	55
3.7	Hiệu chỉnh ngưỡng và độ tin cậy của kết quả	56
3.7.1	Hiệu chỉnh ngưỡng phân loại	56
3.7.2	Khoảng tin cậy bootstrap của các chỉ số	59
3.8	Diễn giải mô hình bằng SHAP	60
3.9	Kết luận	63

Danh sách hình vẽ

1.1	Hàm sigmoid (trái) và hàm mất mát Binary Cross-Entropy theo xác suất dự báo, ứng với hai trường hợp nhãn thật $y = 1$ và $y = 0$ (phải).	4
1.2	Sơ đồ nguyên lý Bagging: B cây được huấn luyện độc lập trên các mẫu bootstrap khác nhau, kết quả được tổng hợp bằng biểu quyết đa số (phân loại) hoặc trung bình (hồi quy).	7
1.3	Sơ đồ nguyên lý Gradient Boosting. Ở mỗi vòng lặp, một cây quyết định yếu được huấn luyện để dự báo giả phần dư của mô hình hiện tại, sau đó được cộng vào mô hình với hệ số học η . . .	9
1.4	So sánh chiến lược xây dựng cây level-wise và leaf-wise với cùng số lượng lá.	11
2.1	Sơ đồ quan hệ thực thể (ERD) của bộ dữ liệu OULAD.	18
2.2	Phân phối số bài đánh giá theo học phần (code module).	20
2.3	Tỷ lệ các loại bài đánh giá (TMA, CMA, Exam).	21
2.4	Giá trị <code>weekly_clicks</code> theo các phân vị (percentile).	23
2.5	Phân phối nhãn <code>final_result</code> (4 lớp).	26
2.6	Phân phối nhãn sau khi gộp Distinction vào Pass (3 lớp).	27
2.7	Phân phối <code>imd_band</code> trong tập huấn luyện (nhóm '?' được tô màu cam).	28
2.8	Tỷ lệ <code>imd_band</code> theo trình độ học vấn — nhóm band cực trị (0–20% và 80–100%).	31
2.9	Tỷ lệ <code>imd_band</code> theo trình độ học vấn — nhóm band trung gian (20–80%).	31
2.10	Phân phối tình trạng khuyết tật (<code>disability</code>).	32
2.11	Phân phối số lần đăng ký học phần trước đó.	32
2.12	Phân phối biến <code>is_retake_the_course</code>	33
2.13	Tỷ lệ học lại theo tình trạng khuyết tật.	33

2.14	Biểu đồ radar các đặc trưng tĩnh theo nhóm kết quả.	34
2.15	Tỷ lệ kết quả học tập theo trình độ học vấn.	35
2.16	Tỷ lệ kết quả học tập theo nhóm <code>imd_band</code>	36
2.17	Số sinh viên còn hoạt động theo mốc dự đoán (mỗi 30 ngày). . .	38
2.18	Ma trận tương quan giữa các đặc trưng động.	39
2.19	Biểu đồ bong bóng: <code>avg_score</code> theo <code>num_failed</code>	40
2.20	Biểu đồ radar các đặc trưng động theo nhóm kết quả.	41
2.21	Giá trị trung bình <code>avg_days_early</code> theo nhóm kết quả.	42
3.1	Xu hướng hiệu suất mô hình theo từng mốc dự đoán (mỗi mốc một mô hình riêng).	47
3.2	Ma trận nhầm lẫn trên tập kiểm tra tại bốn mốc dự đoán tiêu biểu — 30, 90, 180 và 240 ngày.	48
3.3	Ma trận nhầm lẫn trên tập kiểm tra — bộ đặc trưng đầy đủ, tại mốc 150 ngày.	52
3.4	Độ quan trọng đặc trưng (theo định nghĩa riêng của từng mô hình) tại mốc 150 ngày.	53
3.5	Precision, recall và F1 của lớp At-risk theo ngưỡng phân loại. .	57
3.6	Ma trận nhầm lẫn trên tập kiểm tra tại bốn mức ngưỡng. . . .	58
3.7	Phân phối bootstrap của năm chỉ số đánh giá; đường liền là ước lượng điểm, hai đường đứt là biên khoảng tin cậy 95%.	59
3.8	Diễn giải SHAP của CatBoost trên bộ đặc trưng đầy đủ (15 đặc trưng).	61
3.9	Diễn giải SHAP của CatBoost trên bộ đặc trưng Top-10.	62
3.10	Diễn giải SHAP của CatBoost trên bộ đặc trưng Top-5.	62
3.11	Diễn giải cục bộ (waterfall) cho hai sinh viên đại diện.	63

Danh sách bảng

2.1	Thống kê tổng quan bộ dữ liệu OULAD.	18
2.2	Thống kê mô tả các biến phân loại của dữ liệu đánh giá.	20
2.3	Thống kê mô tả dữ liệu tương tác VLE theo tuần.	23
2.4	Các biến có giá trị thiếu trong tập dữ liệu (tổng 178,294 dòng), sắp xếp theo tỷ lệ thiếu giảm dần.	25
2.5	Kết quả chia tập train/test theo sinh viên.	27
2.6	Phân phối <code>imd_band</code> (%) theo Region (chuẩn hoá theo hàng, sắp xếp giảm dần theo cột '?'). Màu đậm hơn = tỷ trọng cao hơn trong hàng.	29
2.7	Phân phối <code>imd_band</code> (%) theo trình độ học vấn (chuẩn hoá theo hàng). Màu đậm hơn = tỷ trọng cao hơn trong hàng.	30
2.8	Giá trị trung bình các đặc trưng tĩnh theo nhóm kết quả.	34
2.9	Thống kê mô tả các đặc trưng động (tính trên tập huấn luyện).	37
2.10	Giá trị trung bình các đặc trưng động theo nhóm kết quả.	41
3.1	Phương án mã hóa các đặc trưng phân loại.	44
3.2	Kết quả sơ bộ của mô hình Logistic Regression — một mô hình riêng cho mỗi mốc dự đoán T — trên tập kiểm tra. Precision/Recall/F1 tính riêng cho lớp At-risk.	46
3.3	Siêu tham số xử lý mất cân bằng nhãn được Optuna lựa chọn cho từng mốc dự đoán, cùng F1 At-risk trung bình qua 3-fold cross-validation.	48
3.4	Quy mô và phân phối nhãn nhị phân tại mốc dự đoán 150 ngày, sau khi gộp Fail và Withdrawn thành At-risk.	49
3.5	So sánh các mô hình trên bộ 15 đặc trưng đầy đủ tại mốc 150 ngày. Chỉ số Precision/Recall/F1 tính riêng cho lớp At-risk	51

3.6	Thứ hạng độ quan trọng của từng đặc trưng theo mỗi mô hình (1 = quan trọng nhất) và hạng trung bình, sắp xếp tăng dần theo hạng trung bình.	54
3.7	Hiệu suất của CatBoost — mô hình tốt nhất ở bước so sánh thuật toán — trên ba bộ đặc trưng tại mốc 150 ngày. Chỉ số Precision/Recall/F1 tính riêng cho lớp At-risk	55
3.8	Ảnh hưởng của ngưỡng phân loại lên kết quả dự báo của CatBoost tại mốc 150 ngày. Tập kiểm tra có 1,559 sinh viên At-risk thực tế; hàng in đậm là ngưỡng mặc định.	57
3.9	Ngưỡng cần dùng để đạt các mức recall mục tiêu, và cái giá phải trả. Cột “Bắt thêm” và “Nhầm thêm” so với ngưỡng mặc định 0.5; cột cuối là số cảnh báo nhầm phát sinh trên mỗi sinh viên At-risk bắt thêm được.	58
3.10	Khoảng tin cậy 95% của các chỉ số đánh giá, ước lượng bằng bootstrap trên tập kiểm tra ($B = 2,000$ lần lấy mẫu có hoàn lại) tại ngưỡng mặc định 0.5.	59

Mở đầu

Sự phát triển mạnh mẽ của hình thức học trực tuyến và học kết hợp (blended learning) trong những năm gần đây đã tạo ra lượng lớn dữ liệu phản ánh quá trình học tập và tương tác của sinh viên trên các hệ thống quản lý học tập. Nguồn dữ liệu này không chỉ ghi nhận kết quả học tập mà còn phản ánh nhiều khía cạnh khác như mức độ tham gia, tần suất truy cập, thời gian học tập và hành vi tương tác với tài nguyên học tập. Điều đó mở ra cơ hội ứng dụng các phương pháp học máy và phân tích dữ liệu nhằm khai thác những thông tin tiềm ẩn, từ đó hỗ trợ quá trình ra quyết định trong lĩnh vực giáo dục.

Trong số các ứng dụng của Educational Data Mining (EDM), bài toán phát hiện sớm sinh viên có nguy cơ học tập kém, trượt môn hoặc bỏ học nhận được nhiều sự quan tâm do có ý nghĩa thực tiễn cao. Nếu được nhận diện ở giai đoạn đầu của học phần, các sinh viên này có thể nhận được những biện pháp hỗ trợ và can thiệp phù hợp từ giảng viên hoặc cố vấn học tập, góp phần cải thiện kết quả học tập, giảm tỷ lệ bỏ học và nâng cao chất lượng đào tạo.

Trong dự án này, dữ liệu được sử dụng là bộ **Open University Learning Analytics Dataset (OULAD)** do The Open University (Vương quốc Anh) công bố tháng 12 năm 2015. Bộ dữ liệu ghi lại thông tin về các học phần, sinh viên và toàn bộ tương tác của họ với Môi trường học tập trực tuyến (Virtual Learning Environment – VLE) trên bảy học phần được lựa chọn.

Toàn bộ nghiên cứu được tổ chức thành ba chương kế tiếp nhau:

1. **Cơ sở lý thuyết:** trình bày nguyên lý hoạt động và công thức toán học cốt lõi của bốn thuật toán học máy được sử dụng trong nghiên cứu — Logistic Regression, Random Forest, CatBoost và LightGBM — đồng thời bổ sung cơ sở cho hai phương pháp hỗ trợ thực nghiệm: Bayesian Optimization trong tinh chỉnh siêu tham số và SHAP trong diễn giải mô hình.
2. **Phân tích khám phá dữ liệu (EDA):** tìm hiểu cấu trúc, quy mô và chất lượng của bộ dữ liệu OULAD; xây dựng tập dữ liệu dạng *panel* (snapshot

theo nhiều mốc thời gian) phù hợp với bài toán dự báo sớm; khám phá mối quan hệ giữa các đặc trưng nhân khẩu học, hành vi học tập và kết quả cuối khoá.

3. **Xây dựng và so sánh mô hình:** tiền xử lý dữ liệu, khảo sát sơ bộ hiệu suất theo thời gian, huấn luyện và tinh chỉnh bốn thuật toán bằng Bayesian Optimization kết hợp kỹ thuật xử lý mất cân bằng nhãn, so sánh hiệu suất, đánh giá độ ổn định khi rút gọn đặc trưng, hiệu chỉnh ngưỡng phân loại và diễn giải mô hình bằng SHAP.

Chương 1

Cơ sở lý thuyết

1.1 Tổng quan nội dung lý thuyết

Chương này trình bày nền tảng lý thuyết cho toàn bộ quy trình thực nghiệm ở các chương sau. Nội dung không chỉ bao gồm bốn thuật toán học máy có giám sát được dùng để dự báo rủi ro học tập, mà còn bao gồm hai phương pháp hỗ trợ quan trọng: Bayesian Optimization để tinh chỉnh siêu tham số và SHAP để diễn giải dự báo của mô hình.

Bốn thuật toán được đưa vào so sánh gồm Logistic Regression, Random Forest, CatBoost và LightGBM. Các thuật toán này đại diện cho ba hướng tiếp cận tiêu biểu trong học máy có giám sát:

- **Mô hình tuyến tính** (Logistic Regression) — đơn giản, dễ diễn giải và được sử dụng làm mô hình cơ sở (baseline).
- **Học theo phương pháp bagging** (Random Forest) — kết hợp nhiều cây quyết định được huấn luyện độc lập nhằm giảm phương sai và cải thiện khả năng tổng quát hóa.
- **Học theo phương pháp boosting** (CatBoost và LightGBM) — xây dựng tuần tự các mô hình yếu, trong đó mỗi mô hình kế tiếp tập trung khắc phục sai số của các mô hình trước, với hai cơ chế hiện thực khác nhau.

Đối với mỗi thuật toán, các mục tiếp theo trình bày nguyên lý hoạt động, công thức toán học cốt lõi và những cơ chế đặc trưng trong bối cảnh bài toán cảnh báo sớm rủi ro học tập. Sau phần thuật toán, chương tiếp tục trình bày Bayesian Optimization và SHAP để làm rõ cơ sở lý thuyết cho hai bước quan trọng ở Chương 3: tinh chỉnh mô hình và diễn giải kết quả.

1.2 Hồi quy Logistic (Logistic Regression)

1.2.1 Mô hình xác suất


Logistic Regression là một mô hình **tuyến tính suy rộng** (generalized linear model) cho bài toán phân loại nhị phân. Với vector đặc trưng đầu vào $\mathbf{x} \in \mathbb{R}^p$, mô hình trước tiên tính một tổ hợp tuyến tính:

$$z = \mathbf{w}^\top \mathbf{x} + b,$$

trong đó $\mathbf{w} \in \mathbb{R}^p$ là vector trọng số và b là hệ số chặn (bias). Giá trị z sau đó được ánh xạ về khoảng $(0, 1)$ thông qua **hàm sigmoid**:

$$\hat{p} = \sigma(z) = \frac{1}{1 + e^{-z}},$$

được diễn giải là xác suất dự báo của lớp dương. Quyết định phân loại cuối cùng dựa trên một ngưỡng τ (mặc định $\tau = 0.5$): $\hat{y} = 1$ nếu $\hat{p} \geq \tau$, ngược lại $\hat{y} = 0$.



Hình 1.1: Hàm sigmoid (trái) và hàm mất mát Binary Cross-Entropy theo xác suất dự báo, ứng với hai trường hợp nhãn thật $y = 1$ và $y = 0$ (phải).

Như minh họa ở Hình 1.1 (trái), hàm sigmoid có dạng chữ S, đối xứng qua điểm $(0, 0.5)$, bão hoà dần về 0 và 1 ở hai đầu — đây chính là cơ chế giúp mô hình tuyến tính z (có thể nhận giá trị bất kỳ trên $\mathbb{R}$) được chuyển thành một xác suất hợp lệ.

1.2.2 Hàm mất mát, regularization và trọng số lớp

Tham số $(\mathbf{w}, b)$ được ước lượng bằng phương pháp **hợp lý cực đại** (Maximum Likelihood Estimation), tương đương với việc tối thiểu hoá hàm mất mát **Binary Cross-Entropy** (hay log-loss) trên tập huấn luyện gồm N mẫu:

$$\mathcal{L}(\mathbf{w}, b) = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \right].$$

Hình 1.1 (phải) minh hoạ trực quan hàm mất mát này: khi nhãn thật $y_i = 1$, mất mát giảm dần về 0 khi $\hat{p}_i \rightarrow 1$ nhưng tiến tới vô cực khi $\hat{p}_i \rightarrow 0$ — tức mô hình bị phạt rất nặng nếu dự báo sai với độ tin cậy cao. Vì $\mathcal{L}$ là hàm lồi theo $(\mathbf{w}, b)$, việc tối ưu thường dùng các phương pháp lặp dựa trên gradient (gradient descent hoặc các biến thể tựa Newton như L-BFGS), với đạo hàm riêng theo $\mathbf{w}$ có dạng tường minh:

$$\nabla_{\mathbf{w}} \mathcal{L} = \frac{1}{N} \mathbf{X}^T (\hat{\mathbf{p}} - \mathbf{y}).$$

Regularization. Để hạn chế hiện tượng overfitting khi số đặc trưng lớn hoặc các đặc trưng có tương quan mạnh, một số hạng regularization được cộng thêm vào hàm mục tiêu. Với regularization L_2 (Ridge), bài toán tối ưu trở thành:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^N \ell(y_i, \hat{p}_i),$$

trong đó ℓ là hàm mất mát log-loss của từng mẫu, và $C > 0$ là siêu tham số **ngịch đảo** của regularization: C càng nhỏ, mô hình bị ràng buộc càng chặt (trọng số $\mathbf{w}$ bị co về gần 0), giảm phương sai nhưng có thể tăng độ chệch (bias); C càng lớn, mô hình càng tự do khớp dữ liệu huấn luyện.

Trọng số lớp cho dữ liệu mất cân bằng. Với bài toán mất cân bằng nhãn, hàm mất mát có thể được điều chỉnh bằng cách gán trọng số khác nhau cho từng lớp:

$$\mathcal{L}_w(\mathbf{w}, b) = -\frac{1}{N} \sum_{i=1}^N w_{y_i} \left[y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \right],$$

trong đó w_{y_i} là trọng số ứng với lớp của mẫu i . Việc tăng w_1 khiến mô hình phải trả giá mất mát lớn hơn khi phân loại sai một sinh viên At-risk, làm mô hình dịch chuyển ngưỡng quyết định để bắt được nhiều trường hợp At-risk hơn.

1.3 Cây quyết định (Decision Tree) và Rừng ngẫu nhiên (Random Forest)

1.3.1 Decision Tree

Decision Tree trong nghiên cứu này được xây dựng theo thuật toán CART (Classification and Regression Tree). Thuật toán hoạt động bằng cách chia đệ quy không gian đặc trưng thành các vùng ngày càng nhỏ, trong đó mỗi vùng tương ứng với một **lá** (leaf) và đưa ra một dự báo cụ thể. Tại mỗi nút, thuật toán lựa chọn một đặc trưng j và một ngưỡng s sao cho phép phân chia dữ liệu thành hai nhánh $\{\mathbf{x} : x_j \leq s\}$ và $\{\mathbf{x} : x_j > s\}$ làm giảm độ đo **tạp chất** (impurity) nhiều nhất. Đối với bài toán phân loại, độ đo được sử dụng phổ biến là chỉ số **Gini**:

$$\text{Gini}(t) = 1 - \sum_k p_k(t)^2,$$

trong đó $p_k(t)$ là tỷ lệ mẫu thuộc lớp k tại nút t . Chỉ số Gini bằng 0 khi nút t hoàn toàn thuần nhất (chỉ chứa các mẫu thuộc cùng một lớp), và đạt giá trị lớn nhất khi các lớp được phân bố đồng đều. Độ giảm tạp chất khi chia nút t thành hai nút con t_L, t_R được tính như sau:


$$\Delta\text{Gini} = \text{Gini}(t) - \frac{N_L}{N_t} \text{Gini}(t_L) - \frac{N_R}{N_t} \text{Gini}(t_R),$$

Thuật toán sẽ lựa chọn cặp (j, s) sao cho ΔGini đạt giá trị lớn nhất tại mỗi nút. Quá trình phân chia kết thúc khi thỏa mãn một trong các điều kiện dừng, chẳng hạn như đạt độ sâu tối đa, số lượng mẫu tối thiểu tại mỗi lá hoặc độ tạp chất bằng 0.

Cây quyết định đơn lẻ có ưu điểm là cấu trúc trực quan, dễ diễn giải và có khả năng xử lý hiệu quả cả đặc trưng số lẫn đặc trưng phân loại. Tuy nhiên, mô hình này có **phương sai cao**: chỉ cần những thay đổi nhỏ trong dữ liệu huấn luyện cũng có thể tạo ra một cấu trúc cây khác biệt đáng kể. Khi cây phát triển quá sâu, mô hình dễ dẫn đến hiện tượng overfitting, làm giảm khả năng tổng quát hóa trên dữ liệu chưa quan sát.

1.3.2 Bagging (Bootstrap Aggregating)

Để khắc phục nhược điểm về phương sai của cây quyết định, phương pháp **bagging** xây dựng nhiều cây quyết định độc lập trên các tập dữ liệu bootstrap được lấy mẫu lại từ tập huấn luyện ban đầu. Dự báo cuối cùng được xác định bằng cách tổng hợp kết quả từ toàn bộ các cây.



Hình 1.2: Sơ đồ nguyên lý Bagging: B cây được huấn luyện độc lập trên các mẫu bootstrap khác nhau, kết quả được tổng hợp bằng biểu quyết đa số (phân loại) hoặc trung bình (hồi quy).

Mỗi mẫu bootstrap D_b ($b = 1, \dots, B$) có cùng kích thước với tập dữ liệu gốc D nhưng được lấy mẫu **có hoàn lại**. Do đó, trung bình khoảng 63.2% số mẫu gốc xuất hiện trong mỗi tập bootstrap, trong khi một số mẫu có thể được chọn nhiều lần và một số mẫu khác không được chọn. Đối với bài toán phân loại, dự báo cuối cùng được xác định bằng lớp xuất hiện nhiều nhất trong B dự báo:

$$\hat{y}(\mathbf{x}) = \text{mode}\{T_1(\mathbf{x}), T_2(\mathbf{x}), \dots, T_B(\mathbf{x})\}.$$

Do mỗi cây được huấn luyện trên một mẫu bootstrap khác nhau nên sai số giữa các cây thường không hoàn toàn tương quan. Việc kết hợp dự báo từ nhiều cây giúp giảm ảnh hưởng của nhiễu ngẫu nhiên, từ đó làm giảm phương sai của mô hình tổng thể trong khi chỉ làm tăng độ chệch ở mức không đáng kể.

1.3.3 Random Forest và độ quan trọng đặc trưng

Random Forest được xây dựng dựa trên phương pháp bagging nhưng bổ sung thêm một cơ chế lựa chọn đặc trưng ngẫu nhiên trong quá trình xây dựng từng cây quyết định. Cụ thể, tại mỗi nút của mỗi cây, thay vì xem xét toàn bộ p đặc trưng để tìm phép phân chia tối ưu, thuật toán chỉ lựa chọn ngẫu nhiên một tập

con gồm $m < p$ đặc trưng (thường $m \approx \sqrt{p}$ đối với bài toán phân loại), sau đó tìm phép phân chia tốt nhất trên tập đặc trưng này.

Việc mỗi cây được xây dựng từ những tập đặc trưng khác nhau làm giảm mức độ tương đồng giữa các cây quyết định. Nếu tất cả các cây đều luôn lựa chọn những đặc trưng có khả năng phân chia tốt nhất tại các nút gần gốc, cấu trúc của chúng sẽ trở nên rất giống nhau và hiệu quả của phương pháp bagging bị hạn chế. Bằng cách giới hạn số đặc trưng được xem xét tại mỗi nút, Random Forest tạo ra những cây đa dạng hơn, từ đó giảm phương sai của mô hình và cải thiện khả năng tổng quát hóa trên dữ liệu chưa quan sát.

Ngoài khả năng dự báo, Random Forest còn cung cấp một thước đo để đánh giá mức độ đóng góp của từng đặc trưng trong quá trình xây dựng mô hình. Một trong những thước đo được sử dụng phổ biến là *Mean Decrease in Impurity* (MDI), được tính dựa trên tổng mức giảm chỉ số Gini tại các nút sử dụng đặc trưng đó để phân chia dữ liệu:

$$\text{Importance}(x_j) = \frac{1}{B} \sum_{b=1}^B \sum_{t \in T_b: \text{split trên } x_j} \frac{N_t}{N} \Delta \text{Gini}(t).$$

Trong đó, $\Delta \text{Gini}(t)$ là mức giảm chỉ số Gini tại nút t , N_t là số mẫu đi qua nút đó và N là tổng số mẫu trong tập huấn luyện. Giá trị Importance của một đặc trưng được tính bằng tổng mức giảm Gini do đặc trưng đó tạo ra trên toàn bộ các cây trong rừng, có xét đến tỷ lệ mẫu đi qua từng nút, sau đó lấy trung bình trên B cây. Đặc trưng có giá trị Importance càng lớn được xem là càng đóng góp nhiều vào khả năng phân loại của mô hình.

1.4 Gradient Boosting và CatBoost

1.4.1 Nguyên lý Gradient Boosting

Gradient Boosting là một phương pháp học tập hợp xây dựng mô hình theo cách **tuần tự**. Khác với bagging, trong đó các cây quyết định được huấn luyện độc lập rồi kết hợp kết quả dự báo, Gradient Boosting xây dựng từng cây mới dựa trên những sai số mà mô hình hiện tại vẫn chưa khắc phục được. Sau mỗi vòng lặp, mô hình được cập nhật theo công thức

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta h_m(\mathbf{x}),$$


trong đó $\eta \in (0, 1]$ là tốc độ học (learning rate) và h_m là một cây quyết định yếu (thường có độ sâu nhỏ). Thay vì dự báo trực tiếp nhãn, cây h_m được huấn luyện để xấp xỉ **gradient âm** của hàm mất mát tại mô hình hiện tại F_{m-1} . Đại lượng này được gọi là **giả phần dư** (pseudo-residual):

$$r_i^{(m)} = - \left[\frac{\partial \ell(y_i, F(\mathbf{x}_i))}{\partial F(\mathbf{x}_i)} \right]_{F=F_{m-1}}.$$

Đối với hàm mất mát log-loss trong bài toán phân loại nhị phân, giả phần dư có dạng

$$r_i^{(m)} = y_i - \hat{p}_i^{(m-1)},$$

tức là sai khác giữa nhãn thực tế và xác suất dự báo của mô hình ở vòng trước. Sau khi cây h_m được huấn luyện để dự báo các giả phần dư này, dự báo của cây được cộng vào mô hình hiện tại nhằm giảm giá trị của hàm mất mát. Quá trình được lặp lại nhiều lần cho đến khi đạt số vòng boosting hoặc thỏa mãn tiêu chí dừng.



Hình 1.3: Sơ đồ nguyên lý Gradient Boosting. Ở mỗi vòng lặp, một cây quyết định yếu được huấn luyện để dự báo giả phần dư của mô hình hiện tại, sau đó được cộng vào mô hình với hệ số học η .

CatBoost và LightGBM đều thuộc họ **Gradient Boosted Decision Trees** (GBDT), trong đó cây quyết định được sử dụng làm bộ học yếu. Hai thuật toán đều dựa trên nguyên lý Gradient Boosting nhưng khác nhau ở cách xây dựng cây và xử lý dữ liệu nhằm cải thiện độ chính xác cũng như khả năng tổng quát hóa của mô hình.

1.4.2 Ordered Boosting và Ordered Target Statistics

Một hạn chế của Gradient Boosting truyền thống là hiện tượng **prediction shift**. Trong quá trình huấn luyện, giả phần dư của một mẫu được tính từ mô hình đã từng sử dụng chính mẫu đó ở các vòng boosting trước. Điều này khiến sai số ước lượng trở nên lạc quan hơn so với khi mô hình được áp dụng trên dữ liệu mới, từ đó làm giảm khả năng tổng quát hóa.

Để khắc phục hiện tượng này, CatBoost sử dụng cơ chế **Ordered Boosting**. Trước tiên, dữ liệu được sắp xếp theo một hoán vị ngẫu nhiên. Khi tính giả phần dư của một mẫu, mô hình chỉ được phép sử dụng thông tin từ các mẫu xuất hiện trước mẫu đó trong hoán vị. Nhờ vậy, dự báo của mỗi mẫu luôn được tạo ra bởi một mô hình chưa từng quan sát nhãn của chính mẫu đó, giúp giảm hiện tượng prediction shift và hạn chế rò rỉ thông tin trong quá trình huấn luyện.

Ordered Target Statistics cho đặc trưng phân loại.

Đối với các đặc trưng phân loại có nhiều mức giá trị, CatBoost biểu diễn mỗi mức giá trị bằng một **thống kê mục tiêu** (target statistic), phản ánh mối quan hệ giữa mức giá trị đó và biến mục tiêu. Để tránh rò rỉ thông tin, thống kê này cũng được tính theo nguyên tắc *ordered*, nghĩa là chỉ sử dụng các mẫu xuất hiện trước trong cùng một hoán vị ngẫu nhiên:

$$\text{TS}(\mathbf{x}_i^{(k)}) = \frac{\sum_{j: \pi(j) < \pi(i), x_j^{(k)} = x_i^{(k)}} y_j + aP}{\sum_{j: \pi(j) < \pi(i), x_j^{(k)} = x_i^{(k)}} 1 + a}.$$

Trong đó, $x_i^{(k)}$ là giá trị của đặc trưng phân loại thứ k tại mẫu i , P là giá trị tiên nghiệm của biến mục tiêu và $a > 0$ là hệ số làm trơn (smoothing). Thành phần làm trơn giúp hạn chế các ước lượng cực đoan khi một mức giá trị chỉ xuất hiện ở rất ít mẫu.

1.4.3 Cây đối xứng (Oblivious Trees)

CatBoost sử dụng **cây đối xứng** (oblivious trees) làm bộ học yếu. Trong loại cây này, tất cả các nút nằm trên cùng một tầng đều sử dụng cùng một đặc trưng và cùng một ngưỡng để phân chia dữ liệu. Nhờ cấu trúc đối xứng, đường đi từ nút gốc đến một lá chỉ phụ thuộc vào chuỗi kết quả của các phép so sánh tại từng tầng của cây.

So với cây quyết định thông thường, cây đối xứng có cấu trúc đơn giản và đồng nhất hơn, giúp tăng tốc độ dự báo cũng như giảm chi phí tính toán. Đồng thời, việc hạn chế mức độ phức tạp của cây cũng góp phần giảm nguy cơ quá khớp và cải thiện khả năng tổng quát hóa của mô hình.


1.5 LightGBM

LightGBM là một thuật toán thuộc họ Gradient Boosted Decision Trees (GBDT), được thiết kế nhằm nâng cao hiệu quả huấn luyện trên các tập dữ liệu có kích thước lớn. So với GBDT truyền thống, LightGBM tập trung tối ưu tốc độ huấn luyện và mức sử dụng bộ nhớ thông qua ba cải tiến chính: chiến lược xây dựng cây, phương pháp lấy mẫu dữ liệu và kỹ thuật giảm số lượng đặc trưng cần xử lý.


1.5.1 Tăng trưởng cây theo lá (Leaf-wise Growth)

Phần lớn các thuật toán GBDT xây dựng cây theo chiến lược **level-wise** (hoặc **depth-wise**), trong đó tất cả các lá ở cùng một tầng được mở rộng trước khi chuyển sang tầng tiếp theo. Cách xây dựng này tạo ra các cây có cấu trúc tương đối cân bằng.

Ngược lại, LightGBM sử dụng chiến lược **leaf-wise** (hay *best-first*). Ở mỗi bước, thuật toán chỉ mở rộng một lá duy nhất, đó là lá mang lại mức giảm hàm mất mát lớn nhất trong số tất cả các lá hiện có, bất kể lá đó nằm ở độ sâu nào của cây.



(a) Level-wise: mở rộng đồng thời tất cả các lá trên cùng một tầng.



(b) Leaf-wise: luôn mở rộng lá mang lại mức giảm mất mát lớn nhất.

Hình 1.4: So sánh chiến lược xây dựng cây level-wise và leaf-wise với cùng số lượng lá.

Như minh họa ở Hình 1.4, với cùng số lượng lá, chiến lược leaf-wise thường đạt giá trị hàm mất mát thấp hơn do luôn ưu tiên mở rộng lá có khả năng cải thiện mô hình nhiều nhất. Tuy nhiên, cách xây dựng này cũng tạo ra những cây sâu và mất cân bằng hơn, làm tăng nguy cơ quá khớp trên các tập dữ liệu nhỏ. Vì vậy, LightGBM thường kết hợp các siêu tham số như `num_leaves`, `max_depth` và `min_child_samples` để kiểm soát độ phức tạp của cây.

1.5.2 Tối ưu hiệu quả huấn luyện: GOSS và EFB

Trong Gradient Boosting, các mẫu có giá trị gradient lớn thường là những mẫu mà mô hình dự báo chưa tốt, do đó chứa nhiều thông tin hơn cho việc xây dựng cây ở vòng boosting tiếp theo. Ngược lại, các mẫu có gradient nhỏ thường đã được mô hình dự báo tương đối chính xác và đóng góp ít hơn vào quá trình tìm điểm phân chia.

Dựa trên nhận xét này, GOSS (Gradient-based One-Side Sampling) giảm số lượng mẫu cần xử lý bằng cách:

- Giữ lại toàn bộ $a\%$ số mẫu có giá trị gradient lớn nhất.
- Lấy mẫu ngẫu nhiên $b\%$ trong nhóm các mẫu còn lại.
- Khi tính toán độ giảm hàm mất mát, các mẫu được lấy ngẫu nhiên sẽ được gán trọng số $\frac{1-a}{b}$ nhằm bù lại ảnh hưởng của các mẫu đã bị loại bỏ.

Nhờ chỉ xử lý một phần dữ liệu nhưng vẫn giữ lại hầu hết các mẫu quan trọng, GOSS giúp giảm đáng kể thời gian huấn luyện trong khi chỉ ảnh hưởng rất nhỏ đến chất lượng của điểm phân chia được lựa chọn.

Exclusive Feature Bundling (EFB).

Đối với các tập dữ liệu có số lượng lớn đặc trưng thưa (sparse features), nhiều đặc trưng gần như không đồng thời nhận giá trị khác 0, chẳng hạn các đặc trưng được tạo ra từ one-hot encoding. LightGBM khai thác đặc điểm này thông qua kỹ thuật **Exclusive Feature Bundling** (EFB).

Ý tưởng của EFB là gộp nhiều đặc trưng gần như loại trừ lẫn nhau thành một đặc trưng mới mà vẫn bảo toàn thông tin của từng đặc trưng ban đầu. Để thực hiện điều này, mỗi đặc trưng được ánh xạ vào một khoảng giá trị riêng trong đặc trưng tổng hợp. Việc xác định những đặc trưng nào có thể gộp chung được mô hình hóa thành bài toán tô màu đồ thị (graph coloring) trên đồ thị xung đột giữa các đặc trưng và được giải bằng thuật toán tham lam.

Nhờ giảm số lượng đặc trưng cần xem xét khi xây dựng histogram để tìm điểm phân chia, EFB giúp rút ngắn thời gian huấn luyện và giảm yêu cầu bộ nhớ, đồng thời vẫn duy trì độ chính xác của mô hình trong hầu hết các trường hợp.

1.6 Tối ưu Bayesian (Bayesian Optimization)

Trong các mô hình học máy, hiệu suất dự báo phụ thuộc đáng kể vào lựa chọn **siêu tham số** (hyperparameters), chẳng hạn hệ số regularization của Logistic Regression, số cây và độ sâu của Random Forest, learning rate của CatBoost hoặc số lá của LightGBM.

Bayesian Optimization là một phương pháp tối ưu hóa phù hợp cho các bài toán trong đó việc đánh giá hàm mục tiêu có chi phí tính toán cao và không thể biểu diễn trực tiếp dưới dạng công thức hoặc đạo hàm. Trong bài toán tinh chỉnh siêu tham số mô hình học máy, hàm mục tiêu thường là một chỉ số đánh giá được tính trên tập validation hoặc thông qua cross-validation, chẳng hạn như F1-score của lớp At-risk.

Khác với các phương pháp tìm kiếm đơn giản như Grid Search hoặc Random Search, Bayesian Optimization xây dựng một mô hình xấp xỉ cho hàm mục tiêu dựa trên các lần đánh giá trước đó, sau đó lựa chọn những bộ siêu tham số có khả năng mang lại hiệu quả cao để tiếp tục thử nghiệm. Do mỗi lần đánh giá tương ứng với việc huấn luyện và kiểm định lại mô hình, phương pháp này giúp giảm số lần thử nghiệm cần thiết trong khi vẫn có khả năng tìm kiếm được cấu hình tốt.

Giả sử λ là một cấu hình siêu tham số cần tối ưu và f là hàm mục tiêu cần cực đại, bài toán có thể viết dưới dạng:

$$\lambda^* = \arg \max_{\lambda \in \Lambda} f(\lambda).$$

Bayesian Optimization không chọn các điểm thử nghiệm một cách độc lập. Thay vào đó, phương pháp này xây dựng một mô hình xác suất thay thế (*surrogate model*) để xấp xỉ quan hệ giữa siêu tham số và giá trị hàm mục tiêu dựa trên các lần thử trước đó. Tại mỗi vòng lặp, một **hàm thu nhận** (acquisition function) được sử dụng để quyết định điểm thử tiếp theo, cân bằng giữa hai mục tiêu:

- **Khai thác** (exploitation): thử các vùng đã có dấu hiệu cho kết quả tốt.
- **Khám phá** (exploration): thử các vùng còn nhiều bất định, có khả năng chứa nghiệm tốt hơn.

Trong Bayesian Optimization, hàm thu nhận *Expected Improvement* (EI) đo mức cải thiện kỳ vọng của một cấu hình siêu tham số mới so với giá trị tốt nhất

hiện tại f_{best} :

$$\text{EI}(\lambda) = \mathbb{E} [\max(f(\lambda) - f_{\text{best}}, 0)].$$

EI cân bằng giữa hai yếu tố: khai thác các vùng có khả năng cho kết quả tốt và khám phá các vùng chưa được đánh giá đầy đủ. Nhờ tận dụng thông tin từ những lần thử nghiệm trước, Bayesian Optimization có thể tìm kiếm cấu hình siêu tham số hiệu quả với ít lần đánh giá hơn so với các phương pháp tìm kiếm trực tiếp.

Trong thực nghiệm, nghiên cứu sử dụng **Optuna** với bộ lấy mẫu **TPE** (Tree-structured Parzen Estimator), một biến thể của Bayesian Optimization. Thay vì mô hình hóa trực tiếp giá trị mục tiêu, TPE ước lượng phân phối của các bộ siêu tham số dựa trên kết quả quan sát được, ưu tiên những cấu hình có khả năng thuộc nhóm cho hiệu quả tốt. Cơ chế này giúp giảm số lần huấn luyện cần thiết khi tìm kiếm trong không gian siêu tham số.

Do bài toán cảnh báo sớm có dữ liệu mất cân bằng giữa hai lớp, tiêu chí tối ưu cần phản ánh khả năng phát hiện sinh viên có nguy cơ. Vì vậy, nghiên cứu sử dụng F1-score của lớp At-risk làm hàm mục tiêu, nhằm cân bằng giữa precision và recall thay vì chỉ tối ưu độ chính xác tổng thể.

1.7 Diễn giải mô hình bằng SHAP

Trong bài toán cảnh báo sớm rủi ro học tập, khả năng diễn giải mô hình có ý nghĩa đặc biệt quan trọng. Một hệ thống dự báo không chỉ cần xác định những sinh viên có nguy cơ mà còn cần cung cấp thông tin về các yếu tố liên quan đến kết quả dự báo, qua đó hỗ trợ giảng viên và cố vấn học tập lựa chọn phương án can thiệp phù hợp.

SHAP (SHapley Additive exPlanations) là một phương pháp diễn giải mô hình dựa trên lý thuyết giá trị Shapley trong lý thuyết trò chơi. Ý tưởng chính của SHAP là phân bổ đóng góp của từng đặc trưng vào kết quả dự báo, từ đó giải thích cách mô hình đưa ra quyết định đối với từng quan sát cụ thể.

Với một mô hình dự báo f và một quan sát $\mathbf{x}$, SHAP biểu diễn đầu ra của mô hình dưới dạng một mô hình cộng tính:

$$f(\mathbf{x}) = \phi_0 + \sum_{j=1}^p \phi_j,$$

trong đó ϕ_0 là giá trị nền (baseline value), thường tương ứng với giá trị kỳ vọng của mô hình trên tập dữ liệu tham chiếu, còn ϕ_j biểu diễn mức đóng góp của đặc trưng thứ j đối với dự báo của mẫu đang xét. Nếu $\phi_j > 0$, đặc trưng đó làm tăng giá trị đầu ra của mô hình; ngược lại, $\phi_j < 0$ cho thấy đặc trưng đó làm giảm giá trị dự báo. Đối với bài toán phân loại nhị phân, giá trị SHAP có thể được tính trên các không gian đầu ra khác nhau của mô hình, phổ biến là log-odds hoặc xác suất dự báo.

Giá trị SHAP của một đặc trưng được xây dựng dựa trên giá trị Shapley, tức là mức đóng góp biên trung bình của đặc trưng đó trên tất cả các tập hợp đặc trưng có thể có:

$$\phi_j = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|!(p - |S| - 1)!}{p!} [f_{S \cup \{j\}}(\mathbf{x}_{S \cup \{j\}}) - f_S(\mathbf{x}_S)],$$

trong đó F là tập hợp toàn bộ đặc trưng, S là một tập con không chứa đặc trưng j . Thành phần trong ngoặc vuông biểu diễn mức thay đổi của dự báo khi bổ sung đặc trưng j vào tập S . Hệ số

$$\frac{|S|!(p - |S| - 1)!}{p!}$$

đảm bảo rằng mọi thứ tự kết hợp các đặc trưng đều được xem xét với trọng số công bằng.

SHAP có ba tính chất quan trọng giúp nó trở thành một phương pháp diễn giải phổ biến:

- **Tính cộng tính:** tổng các giá trị SHAP của tất cả đặc trưng cộng với giá trị nền bằng đúng đầu ra của mô hình.
- **Tính nhất quán:** nếu mức đóng góp biên của một đặc trưng tăng lên khi mô hình thay đổi, giá trị SHAP của đặc trưng đó cũng không giảm.
- **Tính cục bộ:** mỗi dự báo riêng lẻ có thể được phân rã thành đóng góp của từng đặc trưng, cho phép giải thích quyết định của mô hình đối với từng sinh viên.

Trong thực tế, việc tính trực tiếp giá trị Shapley theo công thức trên là không khả thi khi số lượng đặc trưng lớn, do cần xét toàn bộ 2^p tập con đặc trưng. Đối với các mô hình dựa trên cây quyết định, thuật toán **TreeSHAP** khai thác cấu trúc của cây để tính toán chính xác giá trị SHAP với chi phí thấp hơn đáng kể.

Vì vậy, SHAP đặc biệt phù hợp để phân tích các mô hình như Random Forest, CatBoost và LightGBM được sử dụng trong nghiên cứu này.

Kết quả SHAP có thể được phân tích ở hai mức độ. Ở mức độ toàn cục (global interpretation), giá trị trung bình của $|\phi_j|$ trên nhiều mẫu cho biết mức độ quan trọng tương đối của từng đặc trưng trong toàn bộ mô hình. Ở mức độ cục bộ (local interpretation), các biểu đồ như waterfall plot hoặc force plot cho thấy cách từng đặc trưng tác động đến dự báo của một sinh viên cụ thể, theo hướng làm tăng nguy cơ At-risk hoặc hướng về nhóm Pass.

Nhờ khả năng kết hợp giữa đánh giá độ quan trọng đặc trưng và giải thích dự báo ở cấp độ cá nhân, SHAP không chỉ giúp phân tích cách mô hình hoạt động mà còn hỗ trợ kiểm tra liệu các quyết định của mô hình có phù hợp với kiến thức chuyên môn trong lĩnh vực giáo dục hay không.

Chương 2

Phân tích khám phá dữ liệu (EDA)


Sau khi trình bày cơ sở lý thuyết của các thuật toán và phương pháp hỗ trợ ở Chương 1, phần này phân tích khám phá bộ dữ liệu OULAD nhằm rút ra các định hướng tiền xử lý, thiết kế đặc trưng và đánh giá phù hợp cho bước xây dựng, tinh chỉnh và diễn giải mô hình ở Chương 3.

2.1 Tổng quan bộ dữ liệu OULAD

Bộ dữ liệu OULAD được tổ chức thành bảy bảng dữ liệu liên kết với nhau qua các định danh duy nhất, bao gồm các nhóm thông tin: bài đánh giá, học phần, thông tin sinh viên, đăng ký học, kết quả bài đánh giá và nhật ký tương tác của sinh viên với hệ thống học trực tuyến (VLE). Sơ đồ quan hệ giữa các bảng được minh họa ở Hình 2.1.

Open University Learning Analytics Dataset (OULAD)

Entity Relationship Diagram — 7 bảng



Hình 2.1: Sơ đồ quan hệ thực thể (ERD) của bộ dữ liệu OULAD.

Quy mô tổng thể của bộ dữ liệu được tóm tắt trong Bảng 2.1.

Bảng 2.1: Thống kê tổng quan bộ dữ liệu OULAD.

Bảng gốc	Thực thể	Số lượng
studentInfo	Sinh viên tham gia khóa học	32,953
courses	Đợt mở học phần	22
vle	Trang/tài nguyên VLE	6,364
studentVle	Nhật ký tương tác VLE	10,655,280
studentRegistration	Bản ghi đăng ký học	32,953
assessments	Bài đánh giá	206
studentAssessment	Bản ghi kết quả đánh giá	173,912
—	Tổng số thuộc tính	43

Mỗi đợt mở học phần được định danh bằng mã `code_presentation` gồm **năm khai giảng** kèm **một chữ cái chỉ tháng khai giảng**. Chữ cái này mã hoá tháng theo **vị trí của nó trong bảng chữ cái**: A là chữ thứ 1 ứng với tháng 1, B là chữ thứ 2 ứng với tháng 2, ..., J là chữ thứ 10 ứng với tháng 10. Trong bộ dữ liệu chỉ xuất hiện hai giá trị: B (**tháng 2**) và J (**tháng 10**). Ví dụ, mã 2013J là đợt khai giảng tháng 10 năm 2013, còn 2014B là đợt khai giảng tháng 2 năm 2014. Mọi mốc thời gian trong dữ liệu (ngày nộp bài, ngày đăng ký, ngày tương tác VLE...) đều được tính tương đối so với ngày bắt đầu khoá học (ngày 0), cho phép so sánh nhất quán giữa các đợt học khác nhau.

2.2 Phân tích dữ liệu đánh giá (Assessment)

2.2.1 Cấu trúc chung

Dữ liệu đánh giá được ghép với thông tin học phần để bổ sung độ dài của từng đợt học. Sau khi làm sạch, dữ liệu có các đặc điểm sau:


- Bộ dữ liệu gồm **7 học phần**: AAA, BBB, CCC, DDD, EEE, FFF và GGG. Trong đó FFF có nhiều bài đánh giá nhất với 52 bài.
- Có **4 đợt mở học phần**: 2013B, 2013J, 2014B và 2014J.
- Có **3 loại bài đánh giá**, trong đó TMA chiếm nhiều nhất với 106/206 bài ($\approx 51\%$):
 - **TMA** (*Tutor Marked Assessment*) — bài đánh giá do giảng viên hoặc trợ giảng chấm thủ công, thường là bài tập tự luận nộp theo từng mốc trong khoá học.
 - **CMA** (*Computer Marked Assessment*) — bài đánh giá được hệ thống chấm tự động bằng máy tính, thường ở dạng trắc nghiệm.
 - **Exam** (*bài thi cuối kỳ*) — bài thi tổng kết, quyết định phần lớn hoặc toàn bộ kết quả học phần.
- Toàn bộ 206 bài đánh giá đều có mã định danh duy nhất — **không có bài đánh giá nào bị trùng lặp**.

Bảng 2.2 tóm tắt thống kê mô tả các biến phân loại của dữ liệu đánh giá.

Bảng 2.2: Thống kê mô tả các biến phân loại của dữ liệu đánh giá.


Biến	N	Số nhóm	Giá trị phổ biến	Tần suất
code_module	206	7	FFF	52
code_presentation	206	4	2014J	57
assessment_type	206	3	TMA	106

Phân phối số bài đánh giá theo học phần và tỷ lệ các loại bài đánh giá lần lượt được thể hiện ở Hình 2.2 và Hình 2.3.



Hình 2.2: Phân phối số bài đánh giá theo học phần (code module).

Percentage of Assessment Types



Hình 2.3: Tỷ lệ các loại bài đánh giá (TMA, CMA, Exam).

2.2.2 Phân tích trọng số và phát hiện bất thường

Tổng trọng số (**weight**) của các bài đánh giá được tính theo từng cặp (học phần, đợt học), qua đó ghi nhận một số điểm đáng chú ý:

- Phần lớn học phần (AAA, BBB, DDD, EEE, FFF) có tổng trọng số = 200 theo quy ước chung: 100% cho nhóm bài TMA/CMA và 100% cho bài thi cuối kỳ. Ngoài ra, không phải học phần nào cũng được mở đủ cả 4 đợt — ví dụ AAA chỉ có 2013J và 2014J.
- **GGG có tổng trọng số = 100**: tất cả bài TMA và CMA của GGG đều có **weight** = 0, chỉ bài Exam mới có **weight** = 100. Nói cách khác, kết quả học phần GGG phụ thuộc **hoàn toàn** vào bài thi cuối kỳ.
- **CCC có tổng trọng số = 300**: học phần CCC có 2 bài Exam trong mỗi đợt (mỗi bài **weight** = 100), cộng với TMA + CMA = 100, dẫn đến tổng bằng 300.

- Ở học phần CCC, giá trị ngày thi bị thiếu (ký hiệu '?') ở các bài thuộc loại Exam.

2.2.3 Giá trị thiếu ở biên ngày thi

Kiểm tra các bài có giá trị ngày thi bị thiếu cho thấy:

- Giá trị '?' chỉ xuất hiện ở loại Exam, không có ở TMA hay CMA — đây là dạng **thiếu có tính hệ thống**, không ngẫu nhiên.
- Có 11/24 bản ghi Exam bị thiếu ngày, chiếm gần một nửa ($\approx 45.8\%$).
- Mức độ thiếu theo học phần:
 - AAA, BBB, CCC: thiếu hoàn toàn — không đợt học nào có ngày thi chính xác.
 - DDD: chỉ thiếu 1 đợt (2014J), 3 đợt còn lại đầy đủ.
 - EEE, FFF, GGG: đầy đủ ngày thi cho tất cả các đợt.
- Nhiều khả năng các học phần này có lịch thi linh hoạt nên ngày thi không được ấn định sẵn trong hệ thống. Do bài thi cuối kỳ thường nằm ngoài khoảng thời gian dự báo, ảnh hưởng thực tế của việc thiếu này là **không đáng kể**.

2.3 Phân tích hành vi tương tác VLE

Dữ liệu tương tác VLE được tổng hợp về mức **tuần**: với mỗi sinh viên, số lần click được cộng dồn theo tuần, trong đó tuần được tính bằng $\lfloor \text{ngày}/7 \rfloor$ kể từ ngày bắt đầu học phần. Sau khi tổng hợp, dữ liệu tương tác theo tuần còn **627,031** bản ghi — giảm khoảng 4 lần so với dữ liệu chi tiết ban đầu (2,518,170 dòng); mỗi bản ghi là tổng số click của một sinh viên trong một tuần.

2.3.1 Đặc điểm phân phối


Bảng 2.3 trình bày thống kê mô tả của số tuần (**week**) và số click theo tuần (**weekly_clicks**).

Bảng 2.3: Thống kê mô tả dữ liệu tương tác VLE theo tuần.

Biến	N	Trung bình	Độ lệch chuẩn	Min	Q1	Trung vị	Q3	Max
week	627,031	14.06	11.02	-4.00	4.00	13.00	23.00	38.00
weekly_clicks	627,031	63.16	96.59	1.00	9.00	30.00	78.00	6,999.00

- **Biến week:** giá trị nhỏ nhất = -4 cho thấy một số sinh viên đã truy cập VLE *trước* khi khoá học chính thức bắt đầu. 50% số bản ghi nằm trong khoảng tuần 4–23 (giai đoạn giữa khoá). Giá trị lớn nhất = 38 (≈ 9.5 tháng) phù hợp với độ dài các học phần trong OULAD (≈ 240 –270 ngày).
- **Biến weekly_clicks:** phân phối lệch phải nặng — trung vị chỉ bằng 30 trong khi trung bình lên tới 63.16, chứng tỏ giá trị trung bình bị đẩy lên bởi các giá trị ngoại lai; cá biệt có giá trị lớn nhất bằng 6,999 trong khi $Q_3 = 78$. Độ lệch chuẩn (96.59) còn lớn hơn cả giá trị trung bình, cho thấy mức độ phân tán rất lớn.

Để mô tả rõ hơn đuôi phải của phân phối, Hình 2.4 biểu diễn giá trị `weekly_clicks` theo các phân vị.



Hình 2.4: Giá trị `weekly_clicks` theo các phân vị (percentile).

- Từ P0 đến P75, `weekly_clicks` tăng chậm từ 1 đến khoảng 80 — phần lớn sinh viên tương tác ở mức vừa phải mỗi tuần.
- Từ P75 trở đi, đường cong dốc lên nhanh — dấu hiệu của phân phối lệch phải với đuôi dài.

- $P_{90} = 159$ và $P_{95} = 232$: nhóm 10% sinh viên tích cực nhất có lượng click gấp ≈ 2.5 lần mức trung bình chung (63.16).

2.4 Xây dựng tập dữ liệu dạng snapshot

2.4.1 Thiết kế panel theo thời gian

Để phù hợp với mục tiêu *dự báo sớm*, dữ liệu được tái cấu trúc thành dạng panel (dữ liệu bảng theo thời gian). Với mỗi mốc thời gian $T \in \{30, 60, 90, 120, 150, 180, 210, 240\}$ (ngày kể từ đầu khoá), ta tạo một *snapshot* thể hiện trạng thái của từng sinh viên tại thời điểm đó. Mỗi sinh viên xuất hiện tối đa 8 lần (8 snapshot).

Tại mỗi mốc T , quy trình tính đặc trưng như sau:

- **Lọc sinh viên còn hoạt động:** loại bỏ những sinh viên đã hủy đăng ký trước ngày T .
- **Đặc trưng VLE** (chỉ lấy dữ liệu đến tuần tương ứng với T): `total_clicks` (tổng click tích lũy), `active_weeks` (số tuần có tương tác), `avg_weekly_clicks` (click trung bình mỗi tuần).
- **Đặc trưng đánh giá** (chỉ lấy bài có hạn nộp $\leq T$ và đã nộp trước T): `num_submitted`, `avg_score` (điểm trung bình có trọng số), `avg_days_early` (độ sớm/trễ khi nộp), `num_failed` (số bài trượt, điểm < 40).
- **Đặc trưng tĩnh và nhãn:** thông tin nhân khẩu học của sinh viên và nhãn `final_result`.

Lưu ý: học phần GGG được loại khỏi tập dữ liệu do đặc thù trọng số bất thường đã phân tích ở trên — kết quả của học phần này phụ thuộc hoàn toàn vào bài thi cuối kỳ nên không phù hợp với cách dự báo dựa trên hành vi tích lũy.

2.4.2 Quy mô và giá trị thiếu

Tập dữ liệu thu được gồm **178,294 dòng** và **22 biến**, bao gồm thông tin nhân khẩu học, hành vi học tập (VLE), kết quả bài tập và kết quả cuối kỳ, với nhiều kiểu dữ liệu: 10 biến dạng phân loại, 10 biến số thực và 2 biến số nguyên.

Bảng 2.4 liệt kê các biến có giá trị thiếu cùng tỷ lệ tương ứng.

Bảng 2.4: Các biến có giá trị thiếu trong tập dữ liệu (tổng 178,294 dòng), sắp xếp theo tỷ lệ thiếu giảm dần.

Biến	Số dòng thiếu	Tỷ lệ thiếu (%)
<code>date_unregistration</code>	162,208	90.98
<code>avg_score</code>	18,532	10.39
<code>num_submitted</code>	16,183	9.08
<code>avg_days_early</code>	16,183	9.08
<code>num_failed</code>	16,183	9.08
<code>total_clicks</code>	3,035	1.70
<code>active_weeks</code>	3,035	1.70
<code>avg_weekly_clicks</code>	3,035	1.70


Nhận xét về giá trị thiếu:

- Biến **ngày hủy đăng ký** thiếu nhiều nhất ($\approx 91.0\%$) vì phần lớn sinh viên theo học đến hết khoá nên không có ngày hủy đăng ký — đây là dạng thiếu mang ý nghĩa tích cực.
- Các biến VLE (`total_clicks`, `active_weeks`, `avg_weekly_clicks`) thiếu $\approx 1.7\%$, nhiều khả năng do một số sinh viên chưa từng truy cập hệ thống.
- Các biến đánh giá (`avg_score`, `num_submitted`...) thiếu đáng kể ($\approx 9\text{--}10\%$), do một số sinh viên chưa nộp bài tại thời điểm dự báo.

Ngoài dạng thiếu thông thường (giá trị rỗng) nêu trên, biến `imd_band` còn có một dạng thiếu **được mã hoá bằng ký hiệu '?'** (khoảng 4% số sinh viên). Dạng thiếu này không xuất hiện khi thống kê giá trị rỗng nên cần được nhận diện và xử lý riêng; phân bố cụ thể sẽ được phân tích ở Mục 2.5.1.

2.4.3 Phân phối nhãn mục tiêu


Phân phối nhãn `final_result` ban đầu gồm bốn lớp (Hình 2.5):



Hình 2.5: Phân phối nhãn `final_result` (4 lớp).

- **Pass** chiếm tỷ lệ cao nhất với 89,944 bản ghi (50.4%).
- **Fail** đứng thứ hai với 50,525 bản ghi (28.3%) — gần 1/3 lượt đăng ký không đạt, là nhóm quan trọng nhất cần được dự báo sớm.
- **Distinction** chiếm 11.8% (21,024 bản ghi) — nhóm sinh viên xuất sắc.
- **Withdrawn** chiếm 9.4% (16,801 bản ghi) — lượt đăng ký bị hủy giữa chừng; nhóm này thường bộc lộ dấu hiệu sớm qua mức tương tác thấp.

Mỗi bản ghi là một bộ ba (sinh viên, học phần, đợt học) tại một snapshot T ; một sinh viên có thể xuất hiện nhiều lần nếu đăng ký nhiều học phần hoặc nhiều đợt. Với bài toán cảnh báo sớm, việc phân biệt Distinction với Pass là không cần thiết — mục tiêu là phát hiện sinh viên có nguy cơ trượt hoặc bỏ học. Do đó, **Distinction được gộp vào Pass** (Hình 2.6).



Hình 2.6: Phân phối nhãn sau khi gộp Distinction vào Pass (3 lớp).

Sau khi gộp, tỷ lệ Pass : Fail : Withdrawn = 62.2% : 28.3% : 9.4%, cho thấy tập dữ liệu có mức **mất cân bằng nhãn vừa phải** — cần lưu ý ở bước xây dựng mô hình.

2.4.4 Chia tập huấn luyện và kiểm tra

Tập dữ liệu được chia thành tập huấn luyện (train) và kiểm tra (test) theo **từng sinh viên**, đảm bảo toàn bộ lịch sử của một sinh viên chỉ nằm trong một tập duy nhất. Nếu chia theo từng dòng, cùng một sinh viên có thể xuất hiện ở cả train lẫn test với các snapshot khác nhau. Khi đó, mô hình được huấn luyện trên chính hành vi của sinh viên có mặt trong tập kiểm tra, dẫn đến hiện tượng rò rỉ dữ liệu (data leakage) và làm sai lệch kết quả đánh giá.

Với tỷ lệ train:test = 80 : 20, kết quả chia được tóm tắt ở Bảng 2.5.

Bảng 2.5: Kết quả chia tập train/test theo sinh viên.

Tập	Số sinh viên	Số snapshot
Train	17,921	142,384
Test	4,481	35,910


2.5 Phân tích khám phá các đặc trưng tĩnh

Thông tin tĩnh của sinh viên được xem xét theo hai nhóm phục vụ phân tích:

- **Thông tin nhân khẩu học** (`gender`, `region`, `age_band`, `imd_band`, `highest_education`, `disability`), xét mỗi sinh viên một lần (loại bỏ trùng lặp).
- **Đặc trưng hành vi tĩnh** (`num_of_prev_attempts`, `studied_credits`) gắn với từng lượt đăng ký học phần, kèm nhãn kết quả `final_result`.

2.5.1 Chỉ số thiếu thốn kinh tế (`imd_band`)

Biến `imd_band` đo mức độ thiếu thốn kinh tế theo khu vực địa lý (Index of Multiple Deprivation), được kỳ vọng có liên quan đến kết quả học tập. Hình 2.7 thể hiện phân phối của biến này.



Hình 2.7: Phân phối `imd_band` trong tập huấn luyện (nhóm '?' được tô màu cam).

Phân phối `imd_band` tập trung cao nhất ở band 30–40% (1,925 sinh viên) và giảm dần về hai phía. Nhìn chung, phần lớn sinh viên đến từ các khu vực có mức độ thiếu thốn trung bình đến cao, trong khi số sinh viên ở các khu vực khá giả ít hơn. Đáng chú ý, có 720 sinh viên ($\approx 4.2\%$) mang giá trị '?', cần được xử lý trước khi đưa vào mô hình.

Giá trị thiếu theo vùng. Giá trị '?' trong `imd_band` tập trung gần như hoàn toàn ở hai vùng: North Region (64.86%) và Ireland (25.42%) — cộng lại

chiếm $\approx 90.3\%$ tổng số giá trị thiếu; các vùng còn lại chỉ đóng góp $\approx 9.7\%$. Xét theo chiều ngược lại (tỷ lệ '?' trong mỗi vùng):

- North Region (45.65%) và Ireland (23.40%) có tỷ lệ '?' vượt trội so với tất cả các vùng còn lại (đều $\leq 2\%$), cho thấy tình trạng thiếu dữ liệu này gắn với đặc thù của từng vùng địa lý.
- North Western (0–10%: 23.09%), Yorkshire (0–10%: 19.42%) và West Midlands (0–10%: 17.52%) là những vùng tập trung nhiều sinh viên thuộc band IMD thấp nhất. London cũng nghiêng về các mức IMD thấp (10–20%: 19.30%; 20–30%: 18.37%).
- South Region (90–100%: 21.74%; 80–90%: 15.55%) và South East Region tập trung ở các band cao. East Anglian Region có xu hướng tương tự.
- Scotland, East Midlands, Wales và South West Region không lệch rõ về phía nào, các band dao động tương đối đều trong khoảng 7–13%.

Bảng 2.6 trình bày đầy đủ phân phối `imd_band` theo từng vùng (chuẩn hoá theo hàng), làm rõ các nhận xét trên.

Bảng 2.6: Phân phối `imd_band` (%) theo Region (chuẩn hoá theo hàng, sắp xếp giảm dần theo cột '?'). Màu đậm hơn = tỷ trọng cao hơn trong hàng.

Region	0-10	10-20	20-30	30-40	40-50	50-60	60-70	70-80	80-90	90-100	?
North Region	8.11	10.85	6.74	5.96	5.87	3.71	3.52	4.69	4.50	0.39	45.65
Ireland	9.72	10.10	6.91	7.80	5.75	8.82	7.80	6.65	6.65	6.39	23.40
South Region	1.05	4.50	5.73	6.55	10.93	10.40	8.88	12.62	15.55	21.74	2.05
West Midlands Region	17.52	14.43	11.03	8.99	10.35	7.48	8.61	8.99	5.74	4.98	1.89
South West Region	3.99	7.29	10.74	15.57	12.65	12.19	10.20	12.58	7.90	6.67	0.23
Yorkshire Region	19.42	12.21	12.31	10.48	9.62	9.62	7.31	10.48	5.00	3.37	0.19
Scotland	8.14	7.76	10.29	11.27	10.80	12.21	10.38	9.49	9.92	9.54	0.19
North Western Region	23.09	12.23	13.46	12.23	7.79	7.72	7.10	7.31	5.67	3.35	0.07
East Anglian Region	3.25	4.60	8.36	10.38	12.17	11.33	12.06	12.73	11.89	13.24	0.00
London Region	10.59	19.30	18.37	14.63	10.21	8.66	5.98	4.92	4.55	2.80	0.00
East Midlands Region	7.43	12.54	11.06	10.64	10.64	9.74	10.40	8.42	10.64	8.50	0.00
South East Region	2.58	7.49	8.61	11.46	10.85	11.02	13.95	10.42	11.20	12.40	0.00
Wales	11.87	10.71	12.67	11.51	9.40	9.98	8.96	8.81	8.89	7.21	0.00

Giá trị thiếu theo trình độ học vấn. Xét quan hệ giữa `imd_band` và `highest_education`:


- *No Formal quals* tập trung mạnh ở các band thấp (20–30%: 22.50%; 0–10%: 18.75%...), gần như không xuất hiện ở band 80–90%. Tỷ lệ '?' = 9.38% (cao thứ hai).
- *Lower Than A Level* giảm dần từ band thấp đến band cao, từ 11.43% xuống còn 6.39%. Tỷ lệ '?' = 3.72%.
- *A Level or Equivalent* phân phối tương đối đồng đều (8–11%). Tỷ lệ '?' = 2.34%.
- *HE Qualification* phân bố đồng đều chủ yếu ở các band trung bình đến cao, nhóm 90–100% chiếm tỷ lệ lớn nhất (10.95%). Tỷ lệ '?' = 6.68%.
- *Post Graduate Qualification* có tỷ lệ '?' cao nhất (41.85%), gần như không có sinh viên ở band 0–10%, tập trung rõ ở band 90–100% (25%).

Bảng 2.7 trình bày đầy đủ các con số này.


Bảng 2.7: Phân phối *imd_band* (%) theo trình độ học vấn (chuẩn hoá theo hàng). Màu đậm hơn = tỷ trọng cao hơn trong hàng.

Highest education	0-10	10-20	20-30	30-40	40-50	50-60	60-70	70-80	80-90	90-100	?
No Formal quals	18.75	16.25	22.50	18.12	1.88	5.00	5.62	1.25	0.00	1.25	9.38
Lower Than A Level	11.43	11.37	11.55	10.70	10.05	9.56	8.59	8.67	7.95	6.39	3.72
A Level or Equivalent	8.72	9.90	9.97	10.89	10.65	10.16	9.62	10.02	8.93	8.80	2.34
HE Qualification	6.65	7.45	9.86	10.60	9.48	9.48	8.92	9.76	10.18	10.95	6.68
Post Graduate Qualification	0.00	4.35	6.52	1.63	1.63	3.80	4.89	1.63	8.70	25.00	41.85

Hình 2.8 và Hình 2.9 trực quan hoá xu hướng này. Ở nhóm band cực trị (Hình 2.8), hai band thấp (0–10%, 10–20%) và hai band cao (80–90%, 90–100%) biến động ngược chiều nhau theo trình độ học vấn: tỷ trọng band thấp giảm mạnh còn band cao tăng dần khi học vấn tăng — đặc biệt band 90–100% tăng vọt ở nhóm Post Graduate Qualification. Bốn đường gần như giao nhau quanh mức *A Level or Equivalent*, cho thấy đây là ngưỡng học vấn mà mối liên hệ với *imd_band* bắt đầu đảo chiều. Ở nhóm band trung gian (20–80%, Hình 2.9), các đường biến động khá tương đồng và không band nào nổi bật hẳn.




Hình 2.8: Tỷ lệ imd_band theo trình độ học vấn — nhóm band cực trị (0–20% và 80–100%).



Hình 2.9: Tỷ lệ imd_band theo trình độ học vấn — nhóm band trung gian (20–80%).


2.5.2 Tình trạng khuyết tật và lịch sử học lại (disability, num_of_prev_attempts)

Phân phối `disability` trong tập huấn luyện được thể hiện ở Hình 2.10: phần lớn sinh viên không khai báo khuyết tật (91.1%), nhóm có khuyết tật chỉ chiếm 8.9%.




Hình 2.10: Phân phối tình trạng khuyết tật (disability).

Bên cạnh khuyết tật, biến `num_of_prev_attempts` cho biết số lần sinh viên đã đăng ký học phần này trước đây, qua đó phân biệt sinh viên học lần đầu với sinh viên học lại (retake). Phân phối được thể hiện ở Hình 2.11.



Hình 2.11: Phân phối số lần đăng ký học phần trước đó.


Từ biến này, ta tạo biến nhị phân `is_retake_the_course`: nhận giá trị 1 nếu sinh viên đã từng đăng ký học phần trước đó và 0 nếu học lần đầu. Các mức học lại (1, 2, 3...) được gộp thành một nhóm duy nhất, vì điều quan trọng là sinh viên *đã từng* phải học lại hay chưa, chứ không phải học lại bao nhiêu lần (Hình 2.12).



Hình 2.12: Phân phối biến `is_retake_the_course`.

Phần lớn sinh viên (86.5%) đăng ký học phần lần đầu, 13.5% còn lại là các trường hợp học lại. Tỷ lệ này giảm rất nhanh theo số lần học lại: học lại lần đầu chiếm 10.8%, lần hai chỉ còn 2.1%, và từ ba lần trở lên rất hiếm ($< 0.5\%$). Điều này cho thấy phần lớn sinh viên không đăng ký học lại sau khi trượt học phần.

Học lại và tình trạng khuyết tật. Hình 2.13 cho thấy nhóm sinh viên khuyết tật có tỷ lệ học lại (20.1%) cao hơn rõ rệt so với nhóm không khuyết tật (12.9%). Kết quả này gợi ý khuyết tật là một yếu tố rủi ro trong học tập: nhóm này gặp nhiều trở ngại hơn nên phải học lại thường xuyên hơn.




Hình 2.13: Tỷ lệ học lại theo tình trạng khuyết tật.

2.5.3 Phân tích theo nhãn mục tiêu

Đặc điểm ba nhóm kết quả

Giá trị trung bình của các đặc trưng tính theo từng nhóm kết quả được chuẩn hoá và biểu diễn bằng biểu đồ radar (Hình 2.14). Từ biểu đồ, có thể nhận thấy ba nhóm mang ba đặc điểm rủi ro khác biệt:



Hình 2.14: Biểu đồ radar các đặc trưng tính theo nhóm kết quả.

Giá trị trung bình của từng đặc trưng theo nhóm kết quả — số liệu gốc của biểu đồ radar — được trình bày ở Bảng 2.8.

Bảng 2.8: Giá trị trung bình các đặc trưng tính theo nhóm kết quả.

Nhóm	Tỷ lệ học lại	Số tín chỉ TB	Số lần học trước TB	Tỷ lệ khuyết tật	Tỷ lệ tuổi ≤ 35
Pass	9.7%	78.23	0.12	7.4%	67.7%
Fail	20.5%	80.98	0.27	9.5%	75.4%
Withdrawn	15.5%	87.02	0.19	13.6%	71.4%

- **Pass** là nhóm an toàn nhất: đa giác của nhóm này nhỏ nhất, tức các chỉ số rủi ro đều ở mức thấp. Phần lớn sinh viên học lần đầu với khối lượng đăng ký vừa phải, tỷ lệ khuyết tật thấp nhất; tỷ lệ sinh viên trẻ cũng thấp nhất,


cho thấy nhóm lớn tuổi có xu hướng hoàn thành học phần tốt hơn.

- **Fail** nổi bật ở các đặc trưng về lịch sử học tập: số lần học trước và tỷ lệ học lại đều cao nhất, tỷ lệ sinh viên trẻ cũng cao nhất. Trong khi đó, khối lượng tín chỉ không cao hơn Pass đáng kể — vấn đề của nhóm này nằm ở việc học lại nhiều lần mà kết quả chưa cải thiện, chứ không phải do học quá tải.
- **Withdrawn** có xu hướng ngược lại: khối lượng tín chỉ và tỷ lệ khuyết tật cao nhất, trong khi các chỉ số học lại chỉ ở mức trung bình. Nguyên nhân bỏ học vì vậy thiên về quá tải học tập và các trở ngại cá nhân hoặc sức khỏe.

Như vậy, Fail và Withdrawn đại diện cho hai dạng rủi ro khác nhau: Fail gắn với lịch sử học lại và nhóm sinh viên trẻ, còn Withdrawn gắn với khối lượng đăng ký và tình trạng khuyết tật.

Kết quả theo trình độ học vấn

Hình 2.15 thể hiện tỷ lệ Pass / Fail / Withdrawn theo từng bậc học vấn khi nhập học.




Hình 2.15: Tỷ lệ kết quả học tập theo trình độ học vấn.

- **Pass** tăng liên tục theo trình độ học vấn: từ 38.3% (*No Formal quals*) lên 73.1% (*Post Graduate Qualification*).
- **Fail** giảm theo chiều ngược lại: từ 34.9% xuống còn 11.5% — sinh viên có nền tảng học vấn cao hơn ít trượt môn hơn.
- **Withdrawn** cũng giảm nhưng chậm hơn Fail.

Đáng chú ý, *No Formal quals* là nhóm rủi ro cao nhất: tỷ lệ Pass chỉ đạt 38.3%, trong khi Fail và Withdrawn cộng lại chiếm tới **61.7%** — đây là nhóm duy nhất có tỷ lệ không hoàn thành vượt quá tỷ lệ hoàn thành. *Post Graduate Qualification* là nhóm duy nhất có tỷ lệ Withdrawn (15.4%) cao hơn Fail (11.5%): sinh viên sau đại học ít trượt môn nhưng lại có xu hướng rút lui nhiều hơn, có thể vì lý do cá nhân hoặc công việc. Khoảng cách giữa Pass và hai nhóm còn lại mở rộng rõ rệt từ *A Level or Equivalent* trở lên, cho thấy đây có thể là ngưỡng mà nền tảng học vấn bắt đầu tạo ra lợi thế rõ ràng.

Kết quả theo chỉ số thiếu thôn kinh tế

Hình 2.16 thể hiện tỷ lệ Pass / Fail / Withdrawn theo từng nhóm IMD.



Hình 2.16: Tỷ lệ kết quả học tập theo nhóm imd_band.

- **Pass** tăng đều từ 43.4% (0–10%) lên 65.3% (90–100%) — sinh viên từ khu vực khá giả hơn có tỷ lệ hoàn thành cao hơn.
- **Fail** giảm từ 33.8% xuống 18.5% — nghịch biến với mức độ kinh tế, giảm tương đối đều.
- **Withdrawn** giảm nhẹ và không đều, dao động 18–23% ở các band giữa.

Đáng chú ý, mối liên hệ giữa tỷ lệ Pass và IMD **yếu hơn** rõ rệt so với mối liên hệ giữa Pass và trình độ học vấn ở mục trước: tỷ lệ Pass tăng theo học vấn với biên độ lớn hơn (từ 38.3% lên 73.1%) so với theo IMD (từ 43.4% lên 65.3%). Điều này gợi ý **nền tảng học vấn ảnh hưởng đến kết quả học tập nhiều hơn điều kiện kinh tế**. Ngoài ra, tỷ lệ Withdrawn gần như không thay đổi theo IMD, và nhóm '?' có tỷ lệ Pass cao bất thường (71.6% — cao nhất trong tất cả các nhóm).

2.6 Phân tích khám phá các đặc trưng động

Các đặc trưng động được tính trong khoảng thời gian $[0, T]$ tại mỗi mốc dự đoán, phản ánh mức độ tương tác VLE và kết quả bài kiểm tra tích lũy đến thời điểm đó. Bảy đặc trưng động gồm: `total_clicks`, `active_weeks`, `avg_weekly_clicks`, `num_submitted`, `avg_score`, `num_failed` và `avg_days_early`.

2.6.1 Thống kê mô tả

Thống kê mô tả của bảy đặc trưng động được trình bày ở Bảng 2.9.


Bảng 2.9: Thống kê mô tả các đặc trưng động (tính trên tập huấn luyện).

Đặc trưng	N	Trung bình	Độ lệch chuẩn	Min	Q1	Trung vị	Q3	Max
<code>total_clicks</code>	139,934	1,072.27	1,358.44	1.00	269.00	617.00	1,334.00	23,115.00
<code>active_weeks</code>	139,934	15.65	9.21	1.00	8.00	14.00	22.00	39.00
<code>avg_weekly_clicks</code>	139,934	60.74	56.40	1.00	25.44	44.09	76.92	1,070.50
<code>num_submitted</code>	129,388	3.81	2.68	1.00	2.00	3.00	5.00	14.00
<code>avg_score</code>	127,544	73.54	15.51	0.00	64.73	76.00	85.00	100.00
<code>num_failed</code>	129,388	0.16	0.49	0.00	0.00	0.00	0.00	8.00
<code>avg_days_early</code>	129,388	0.94	8.10	-123.00	-1.50	0.00	1.50	236.00

- Các đặc trưng VLE lệch phải mạnh: `total_clicks` có độ lệch chuẩn (1,358) lớn hơn cả giá trị trung bình (1,072), giá trị lớn nhất lên tới 23,115; `avg_weekly_clicks` cũng tương tự (trung bình 60.7 nhưng giá trị lớn nhất 1,070.5).
- `num_failed` có giá trị nhỏ nhất, trung vị và Q_3 đều bằng 0 — phần lớn sinh viên không trượt bài nào trong khoảng thời gian quan sát. Trung bình chỉ đạt 0.16 nhưng giá trị lớn nhất lên tới 8, tức vẫn có một nhóm nhỏ trượt nhiều bài.
- `avg_days_early` trải trên khoảng giá trị rất rộng: từ -123 (nộp trễ 123 ngày) đến 236 (nộp sớm 236 ngày). Trung vị bằng 0, với $Q_1 = -1.5$ và $Q_3 = 1.5$: khoảng một nửa số sinh viên nộp bài trong vòng ± 1.5 ngày quanh hạn nộp.
- `avg_score` tương đối tập trung: $Q_1 = 64.7$ và $Q_3 = 85$ — phần lớn sinh viên đạt điểm trung bình ở mức khá trở lên.

2.6.2 Số sinh viên còn học theo thời gian

Hình 2.17 thể hiện số sinh viên còn hoạt động tại mỗi mốc dự đoán.




Hình 2.17: Số sinh viên còn hoạt động theo mốc dự đoán (mỗi 30 ngày).

- Số sinh viên còn hoạt động giảm đều qua các mốc: từ **17,921** (ngày 30) xuống **15,171** (ngày 240) — tổng cộng **2,750 sinh viên** ($\approx 15.3\%$) rút khỏi khoá học trong 210 ngày quan sát.
- Mức giảm lớn nhất rơi vào giai đoạn đầu (từ ngày 30 sang ngày 60: -629), sau đó chậm dần và ổn định hơn về cuối khoá (từ ngày 180 sang ngày 210: -214 ; từ ngày 210 sang ngày 240: -208 — chỉ bằng khoảng $1/3$ giai đoạn đầu).
- Trung bình mỗi 30 ngày có ≈ 393 sinh viên rời khoá học; tuy nhiên con số trung bình này chưa phản ánh đúng thực tế, vì phần lớn trường hợp rút lui tập trung ở giai đoạn đầu khoá.

2.6.3 Phân tích tương quan

Ma trận tương quan giữa các đặc trưng động được thể hiện ở Hình 2.18.




Hình 2.18: Ma trận tương quan giữa các đặc trưng động.

- **Cụm hoạt động trực tuyến** (`total_clicks`, `active_weeks`, `avg_weekly_clicks`) tương quan chặt với nhau; đặc biệt `total_clicks` và `avg_weekly_clicks` gần như đo lường cùng một khía cạnh — đưa cả hai vào mô hình có thể gây **đa cộng tuyến** (multicollinearity). `active_weeks` có tương quan khá cao với `num_submitted`, nhưng số click mỗi tuần lại gần như không liên quan đến số bài nộp — cho thấy lượng click không phải lúc nào cũng phản ánh việc học có mục đích.
- **Cặp nghịch chiều rõ nhất** là `avg_score` và `num_failed`: điểm trung bình cao đi kèm số bài trượt thấp, do đó có thể cân nhắc chỉ giữ lại một trong hai đặc trưng.
- `avg_days_early` tương quan thấp với hầu hết các đặc trưng còn lại — đây là một tín hiệu tương đối độc lập, phản ánh thói quen quản lý thời gian của sinh viên.
- `num_failed` gần như không tương quan với các đặc trưng hoạt động — tương

tác nhiều hay học đều đặn không bảo đảm tránh được điểm kém; kết quả còn phụ thuộc vào chất lượng của việc học.

Quan hệ giữa `avg_score` và `num_failed` được thể hiện rõ hơn qua biểu đồ bong bóng ở Hình 2.19.




Hình 2.19: Biểu đồ bong bóng: `avg_score` theo `num_failed`.

Phần lớn sinh viên không trượt bài nào (`num_failed` = 0) và có `avg_score` tập trung ở mức cao, rõ nhất trong vùng 80–100 điểm. Khi số bài trượt tăng, số sinh viên giảm dần và điểm trung bình phân tán hơn. Tuy nhiên, ở các mức `num_failed` thấp (1–5) vẫn có những sinh viên đạt điểm khá cao. Đây là lý do hai đặc trưng này không thể thay thế cho nhau: `num_failed` nắm bắt được một dạng rủi ro mà điểm trung bình bỏ sót — sinh viên học ổn định nhưng bỏ hoặc trượt một vài bài, có thể do thiếu chuyên cần hoặc do hoàn cảnh cá nhân.

2.6.4 Đặc trưng động theo nhãn mục tiêu

Biểu đồ radar các đặc trưng động theo nhóm kết quả (Hình 2.20) làm rõ hơn sự khác biệt giữa các nhóm.



Hình 2.20: Biểu đồ radar các đặc trưng động theo nhóm kết quả.

Giá trị trung bình các đặc trưng động theo nhóm kết quả được trình bày ở Bảng 2.10.


Bảng 2.10: Giá trị trung bình các đặc trưng động theo nhóm kết quả.

Nhóm	total_clicks	active_weeks	avg_weekly_clicks	num_submitted	avg_score	num_failed	avg_days_early
Pass	1,377.99	18.48	70.24	4.27	78.21	0.09	1.59
Fail	548.59	11.06	42.49	3.08	63.48	0.33	-0.19
Withdrawn	542.78	9.93	50.11	2.29	65.47	0.27	-0.91

- **Pass** chiếm diện tích lớn nhất, vượt trội ở cả ba đặc trưng tương tác VLE (`active_weeks`, `total_clicks`, `avg_weekly_clicks`) lẫn số bài nộp. Đây là nhóm duy nhất vừa duy trì mức độ tham gia cao, vừa đạt kết quả bài đánh giá tốt.
- **Fail** nổi bật nhất ở số bài trượt (`num_failed`), cao hơn cả hai nhóm còn lại, trong khi số bài nộp tương đương nhóm Pass. Như vậy, sinh viên Fail vẫn nộp bài đầy đủ nhưng kết quả không đạt yêu cầu — dấu hiệu của khó khăn học tập kéo dài.

- **Withdrawn** thì ngược lại: số bài nộp thấp nhất trong ba nhóm, còn số bài trượt gần như bằng 0. Điều này không có nghĩa là họ làm bài tốt — họ nộp quá ít bài nên hầu như không có bài nào bị tính trượt. Đáng chú ý, những bài đã nộp vẫn đạt điểm ở mức trung bình khá, cho thấy nhóm này bỏ học không hẳn vì học kém, mà nhiều khả năng do mất dần sự gắn kết với khoá học.

Cuối cùng, xét `avg_days_early` theo nhóm kết quả (Hình 2.21): Pass là nhóm duy nhất có giá trị dương (+1.59 ngày, tức nộp trước hạn), thể hiện thái độ học tập chủ động. Hai nhóm còn lại đều mang giá trị âm, trong đó Withdrawn nộp trễ nhiều nhất (−0.91 ngày, gấp gần 5 lần mức −0.19 ngày của Fail) — phù hợp với xu hướng giảm dần sự gắn kết đã ghi nhận ở trên. Tuy vậy, mức chênh lệch giữa ba nhóm đều nhỏ (dưới 2 ngày), nên khi đứng một mình, `avg_days_early` có thể chưa đủ mạnh để phân biệt các nhóm.



Hình 2.21: Giá trị trung bình `avg_days_early` theo nhóm kết quả.

Chương 3

Xây dựng và so sánh mô hình

3.1 Tiền xử lý dữ liệu

Dựa trên cơ sở lý thuyết ở Chương 1 và các kết quả phân tích khám phá dữ liệu ở Chương 2, chương này trình bày quy trình tiền xử lý dữ liệu, xây dựng đặc trưng, huấn luyện và đánh giá mô hình cho bài toán cảnh báo sớm rủi ro học tập. Bài toán được chuẩn hóa thành **phân loại nhị phân**: nhóm **có nguy cơ** (At-risk) được hình thành bằng cách gộp hai kết cục **trượt môn** (Fail) và **bỏ học** (Withdrawn), đối lập với nhóm **hoàn thành học phần** (Pass). Dự báo được thực hiện dựa trên các đặc trưng nhân khẩu học và hành vi học tập tích lũy đến từng mốc quan sát trong khóa học.

Điền giá trị thiếu ở các đặc trưng động. Các đặc trưng phản ánh hành vi học tập tích lũy, gồm tương tác với hệ thống học trực tuyến và kết quả bài đánh giá, có thể bị thiếu khi sinh viên chưa phát sinh hoạt động hoặc chưa nộp bài tại thời điểm quan sát. Vì ý nghĩa của giá trị thiếu khác nhau giữa các nhóm biến, quá trình điền khuyết được thực hiện theo từng trường hợp:

- **Đặc trưng tương tác VLE** (`total_clicks`, `active_weeks`, `avg_weekly_clicks`) và **đặc trưng bài đánh giá** (`num_submitted`, `num_failed`) được điền bằng 0, vì giá trị thiếu trong trường hợp này biểu thị việc sinh viên chưa phát sinh hoạt động tương ứng.
- `avg_score` được điền bằng giá trị **-1**, nằm ngoài miền điểm hợp lệ $[0, 100]$, để phân biệt với trường hợp sinh viên đã nộp bài nhưng đạt 0 điểm.

- `avg_days_early` được điền bằng 0. Việc sinh viên chưa nộp bài dù đã đến hạn đã được phản ánh bởi biến nhị phân `no_submission_despite_due`, do đó cách điền này không làm mất thông tin.

Sau bước điền khuyết, toàn bộ đặc trưng động không còn giá trị thiếu. Tuy nhiên, dữ liệu nhân khẩu học vẫn có một dạng thiếu đặc biệt cần được xử lý riêng.

Xử lý giá trị thiếu của `imd_band`. Như đã nêu ở Mục 2.5.1 (Chương 2), biến `imd_band` (chỉ số thiếu thốn kinh tế theo khu vực) sử dụng ký hiệu '?' để biểu diễn giá trị thiếu thay vì giá trị rỗng thông thường. Trước khi điền khuyết, biến chỉ báo `imd_missing` được tạo để lưu lại trạng thái thiếu dữ liệu, qua đó cho phép mô hình khai thác bản thân hiện tượng thiếu như một tín hiệu dự báo.

Giá trị thiếu của `imd_band` được điền theo phân phối của từng vùng (`region`). Phân phối này được ước lượng trên tập huấn luyện và áp dụng thống nhất cho tập kiểm tra nhằm tránh rò rỉ thông tin. Sau xử lý, biến `imd_band_filled` không còn giá trị thiếu ở cả hai tập dữ liệu.

Mã hóa đặc trưng phân loại. Sau khi hoàn tất điền khuyết, các đặc trưng phân loại được chuyển sang dạng số theo bản chất đo lường của từng biến. Phương án mã hóa cụ thể được trình bày trong Bảng 3.1.

Bảng 3.1: Phương án mã hóa các đặc trưng phân loại.

Đặc trưng	Kiểu mã hóa	Lý do
<code>disability</code>	Nhị phân	$Y \rightarrow 1, N \rightarrow 0$
<code>highest_education</code>	Thứ tự (ordinal)	Có thứ bậc học vấn rõ ràng
<code>imd_band_filled</code>	Thứ tự (ordinal)	Có thứ bậc mức độ thiếu thốn kinh tế

Ba đặc trưng nhân khẩu học còn lại trong dữ liệu gốc gồm `gender`, `region` và `age_band` không được đưa vào tập đặc trưng huấn luyện. Ngược lại, `highest_education`, `disability` và `imd_band_filled` được giữ lại vì đã thể hiện mối liên hệ rõ ràng với kết quả học tập trong Chương 2.

Tập đặc trưng cuối cùng. Sau tiền xử lý, tập dữ liệu dùng để huấn luyện mô hình gồm **15 đặc trưng**, chia thành hai nhóm:

- **Đặc trưng tĩnh (6):** `highest_education`, `disability`, `num_of_prev_attempts`, `studied_credits`, `imd_band_filled` và biến chỉ báo `imd_missing`.

- **Đặc trưng động (9):** `total_clicks_filled`, `active_weeks_filled`, `avg_weekly_clicks_filled`, `num_due`, `num_submitted_filled`, `avg_score_filled`, `num_failed_filled`, `avg_days_early_filled` và `no_submission_despite_due`.

Dữ liệu được chia thành tập huấn luyện và tập kiểm tra theo từng sinh viên, giữ nguyên thiết kế đã trình bày ở Bảng 2.5 (Chương 2) với tỷ lệ 80:20. Cách chia này bảo đảm các bản ghi của cùng một sinh viên không xuất hiện đồng thời ở cả hai tập.

Chuẩn hóa bài toán về phân loại nhị phân. Với mục tiêu cảnh báo sớm, ranh giới quan trọng nhất là giữa nhóm sinh viên hoàn thành và không hoàn thành học phần, thay vì tách riêng hai kết cục Fail và Withdrawn. Vì vậy, nhãn mục tiêu được xác định lại như sau:

$$\text{At-risk (1)} = \text{Fail} \cup \text{Withdrawn}, \quad \text{Pass (0)} = \text{Pass}.$$

Phép gộp nhãn được áp dụng thống nhất trên toàn bộ dữ liệu dạng panel, tức với tất cả bản ghi tại tám mốc dự đoán $T \in \{30, 60, \dots, 240\}$ được xây dựng ở Mục 2.4.1 (Chương 2). Sau khi hoàn tất tiền xử lý và chuẩn hóa nhãn, dữ liệu được sử dụng cho giai đoạn huấn luyện, so sánh và diễn giải các mô hình học máy ở các mục tiếp theo.

3.2 Khảo sát sơ bộ theo các mốc dự đoán

Trước khi so sánh nhiều thuật toán tại một mốc thời gian cố định, cần khảo sát sơ bộ hiệu suất mô hình **trên toàn bộ các mốc dự đoán** đã thiết kế ở Mục 2.4.1 (Chương 2). Phân tích này nhằm hai mục đích: (i) đánh giá xu hướng thay đổi hiệu suất khi sinh viên tích lũy thêm dữ liệu hành vi theo thời gian, và (ii) lựa chọn một mốc đại diện cho các thử nghiệm chuyên sâu ở phần sau.

3.2.1 Thiết lập thử nghiệm

Với mỗi mốc dự đoán T , một mô hình **Logistic Regression** được huấn luyện riêng trên dữ liệu của đúng mốc đó. Đây là thuật toán cơ sở, đơn giản và dễ diễn giải nhất trong nhóm thuật toán được trình bày ở Chương 1, phù hợp để khảo sát nhanh xu hướng hiệu suất theo thời gian trước khi mở rộng sang các mô hình phức tạp hơn. Quy trình tinh chỉnh cho từng mốc tương tự cách tiếp

cận ở giai đoạn so sánh thuật toán tại Mục 3.3: dữ liệu được chuẩn hoá bằng **StandardScaler** (fit trên train-fold để tránh rò rỉ dữ liệu), còn siêu tham số regularization C của mô hình (Mục 1.2.2), tỷ lệ oversampling SMOTE và trọng số lớp At-risk được tinh chỉnh đồng thời bằng Optuna với 30 lượt thử nghiệm và kiểm định chéo phân tầng 3-fold. Sau đó, mô hình được huấn luyện lại trên toàn bộ tập huấn luyện của mốc tương ứng và đánh giá trên tập kiểm tra giữ nguyên.

Về mặt phương pháp, thử nghiệm ban đầu sử dụng *recall thuần* của lớp At-risk làm hàm mục tiêu. Tuy nhiên, lựa chọn này khiến mô hình suy biến về phương án dự đoán **toàn bộ** sinh viên là At-risk: recall gần tuyệt đối nhưng precision rất thấp, do đó không có giá trị vận hành. Vì vậy, hàm mục tiêu được chuyển sang **F1-score của lớp At-risk**, buộc mô hình cân bằng giữa precision và recall. Hàm mục tiêu này được giữ nguyên trong toàn bộ các thử nghiệm còn lại của báo cáo.


3.2.2 Kết quả theo thời gian

Bảng 3.2 tổng hợp hiệu suất trên tập kiểm tra của tám mô hình Logistic Regression, tương ứng với tám mốc dự đoán.

Bảng 3.2: Kết quả sơ bộ của mô hình Logistic Regression — một mô hình riêng cho mỗi mốc dự đoán T — trên tập kiểm tra. Precision/Recall/F1 tính riêng cho lớp At-risk.

T (ngày)	Train	Test	Accuracy	Precision	Recall	F1
30	19,988	5,043	0.6488	0.5750	0.8013	0.6695
60	19,123	4,835	0.7231	0.6429	0.7666	0.6993
90	18,508	4,680	0.7402	0.6442	0.7857	0.7080
120	17,917	4,518	0.7915	0.7123	0.7555	0.7333
150	17,386	4,363	0.8263	0.7524	0.7659	0.7591
180	16,786	4,215	0.8451	0.7533	0.7987	0.7754
210	16,486	4,162	0.8659	0.7976	0.7894	0.7935
240	16,190	4,094	0.8796	0.8269	0.7814	0.8035


Hình 3.1 trực quan hoá xu hướng của bốn chỉ số theo thời gian.



Hình 3.1: Xu hướng hiệu suất mô hình theo từng mốc dự đoán (mỗi mốc một mô hình riêng).

- **Accuracy** và **precision At-risk** tăng **đơn điệu** theo thời gian, không có mốc nào giảm so với mốc liền trước. Accuracy tăng từ 0.6488 ở $T = 30$ lên 0.8796 ở $T = 240$, trong khi precision tăng từ 0.5750 lên 0.8269. Kết quả này phù hợp với trực giác: sinh viên càng tích lũy nhiều hành vi học tập, tín hiệu dự báo càng rõ ràng và đáng tin cậy.
- **Recall At-risk** lại dao động trong một biên độ hẹp (0.7555–0.8013) mà không theo xu hướng rõ ràng, thậm chí đạt giá trị cao nhất ngay ở mốc sớm nhất $T = 30$ (0.8013), khi độ chính xác tổng thể còn thấp (accuracy 0.6488, precision 0.5750). Điều này cho thấy ở giai đoạn đầu khoá, khi tín hiệu hành vi còn thừa thớt, ranh giới tuyến tính của Logistic Regression có xu hướng dự báo At-risk tương đối rộng: mô hình phát hiện được phần lớn sinh viên có nguy cơ nhưng phải đánh đổi bằng nhiều cảnh báo nhầm.
- **F1 At-risk** — chỉ số tổng hợp được dùng làm mục tiêu tối ưu — cũng tăng đều theo thời gian, từ 0.6695 ($T = 30$) lên 0.8035 ($T = 240$). Tuy nhiên, mức tăng này chủ yếu đến từ **precision**, trong khi recall gần như ổn định xuyên suốt khoá học.

Ma trận nhầm lẫn của bốn mốc tiêu biểu — 30, 90, 180 và 240 ngày — được thể hiện ở Hình 3.2.



Hình 3.2: Ma trận nhầm lẫn trên tập kiểm tra tại bốn mốc dự đoán tiêu biểu — 30, 90, 180 và 240 ngày.

Bảng 3.3 cho thấy siêu tham số xử lý mất cân bằng nhãn mà Optuna lựa chọn theo từng mốc thời gian.

Bảng 3.3: Siêu tham số xử lý mất cân bằng nhãn được Optuna lựa chọn cho từng mốc dự đoán, cùng F1 At-risk trung bình qua 3-fold cross-validation.

T (ngày)	F1 At-risk (CV)	Tỷ lệ SMOTE	Trọng số At-risk
30	0.6734	+0.67x	1.12
60	0.7065	+0.56x	1.24
90	0.7160	+0.57x	1.33
120	0.7486	+0.69x	1.01
150	0.7767	+0.55x	1.05
180	0.7918	+0.90x	1.01
210	0.8047	+0.51x	1.03
240	0.8182	+0.42x	1.01

Trọng số At-risk tối ưu hầu như luôn hội tụ gần giá trị 1 (1.01–1.33) ở mọi

mốc thời gian, trong khi tỷ lệ SMOTE dao động ở mức khá cao và không có xu hướng rõ rệt (0.42–0.90x). Nói cách khác, đối với Logistic Regression, việc bổ sung mẫu tổng hợp bằng SMOTE đóng vai trò chủ đạo hơn so với điều chỉnh trọng số lớp trong xử lý mất cân bằng nhãn. Đây là đặc điểm nhất quán của mô hình này trên các mốc thời gian khảo sát.

3.2.3 Lựa chọn mốc dự đoán cho phân tích chuyên sâu

Kết quả khảo sát cho thấy sự đánh đổi rõ ràng giữa **độ tin cậy của dự báo** và **thời gian còn lại để can thiệp**: mốc dự đoán càng muộn thì hiệu suất càng cao, nhưng cảnh báo cũng càng gần thời điểm kết thúc khoá học, làm giảm giá trị thực tiễn của hệ thống. Với các khoá học OULAD kéo dài khoảng 240–270 ngày, hai mốc có F1 cao nhất — 210 và 240 ngày, lần lượt 0.7935 và 0.8035 — chỉ còn khoảng 10–20% thời lượng khoá học. Đây là thời điểm quá muộn để nhà trường triển khai các biện pháp hỗ trợ có ý nghĩa.

Mốc **150 ngày** được chọn làm đại diện cho các thử nghiệm chuyên sâu ở phần còn lại của báo cáo vì đạt cân bằng hợp lý giữa hai yêu cầu trên. Về hiệu suất, mốc này cho kết quả tương đối cao (accuracy 0.8263, F1 At-risk 0.7591) và chỉ thấp hơn khoảng 0.016 so với mốc 180 ngày liền sau, một khoảng cách nhỏ so với lợi ích thu được về thời gian. Về khả năng can thiệp, cảnh báo tại ngày thứ 150 vẫn còn khoảng 90–120 ngày, tương đương 37–50% thời lượng khoá học, đủ để nhà trường tổ chức các hoạt động hỗ trợ có chiều sâu thay vì chỉ nhắc nhở gấp rút ở giai đoạn cuối.

Bảng 3.4 tóm tắt quy mô và phân phối nhãn tại mốc 150 ngày sau khi gộp nhãn, được dùng thống nhất cho toàn bộ các thử nghiệm từ Mục 3.3 trở đi.

Bảng 3.4: Quy mô và phân phối nhãn nhị phân tại mốc dự đoán 150 ngày, sau khi gộp Fail và Withdrawn thành At-risk.

Tập		Pass	At-risk	Tổng
Train	11,067 (63.7%)	6,319 (36.3%)	17,386	
Test	2,804 (64.3%)	1,559 (35.7%)	4,363	

Tỷ lệ At-risk chiếm khoảng **36%** tổng số sinh viên ở cả hai tập và gần như tương đồng giữa train và test. Điều này xác nhận rằng cách chia dữ liệu theo sinh viên không gây lệch phân phối nhãn. Tuy vậy, bài toán vẫn có **mất cân bằng nhãn ở mức vừa phải** và cần được xử lý trong quá trình huấn luyện

mô hình.

3.3 Phương pháp xây dựng mô hình

Từ kết luận ở Mục 3.2.3, các thử nghiệm tiếp theo tập trung vào mốc 150 ngày. Phân tích được mở rộng từ mô hình cơ sở Logistic Regression, đã dùng để khảo sát xu hướng theo thời gian ở Mục 3.2, sang so sánh trực tiếp **bốn thuật toán học máy** khác nhau.

3.3.1 Các thuật toán sử dụng

Bốn thuật toán đã trình bày ở Chương 1 — Logistic Regression, Random Forest, CatBoost và LightGBM — được huấn luyện và so sánh trực tiếp trên dữ liệu thực nghiệm. Thuật toán **SVM (kernel RBF)** không được đưa vào phạm vi thử nghiệm vì độ phức tạp huấn luyện tăng theo bậc hai với số lượng mẫu, không phù hợp với quy mô dữ liệu tại mốc 150 ngày (hơn 17 nghìn bản ghi huấn luyện) trong điều kiện tài nguyên tính toán của nghiên cứu.

3.3.2 Xử lý mất cân bằng nhãn

Hai kỹ thuật được kết hợp để xử lý mất cân bằng nhãn:

- **SMOTE** (Synthetic Minority Over-sampling Technique): sinh thêm mẫu tổng hợp cho lớp At-risk. Tỷ lệ oversampling được xem là một siêu tham số và được tinh chỉnh riêng cho từng mô hình.
- **Trọng số lớp** (`class_weight`): tăng chi phí phân loại sai đối với lớp At-risk trong hàm mất mát của mô hình. Đại lượng này cũng được tinh chỉnh như một siêu tham số và tương ứng về mặt toán học với hàm mất mát có trọng số đã trình bày ở Mục 1.2.2 (Chương 1) đối với Logistic Regression.

Để tránh rò rỉ dữ liệu, **SMOTE chỉ được áp dụng trên từng fold huấn luyện** trong kiểm định chéo, không áp dụng lên fold kiểm định. Tương tự, với Logistic Regression — mô hình duy nhất cần chuẩn hoá dữ liệu số (`StandardScaler`) — tham số chuẩn hoá cũng chỉ được ước lượng (fit) trên fold huấn luyện.

3.3.3 Thiết lập thực nghiệm

Với mỗi mô hình, siêu tham số của thuật toán được tinh chỉnh **đồng thời** với tỷ lệ SMOTE và trọng số lớp At-risk bằng khung tối ưu Bayesian **Optuna** (thuật toán lấy mẫu TPE), với 30 lượt thử nghiệm cho mỗi mô hình, theo nguyên lý đã trình bày ở Mục 1.6. Hàm mục tiêu là **F1-score của lớp At-risk**, được đánh giá bằng kiểm định chéo phân tầng 3-fold (StratifiedKFold) để giữ nguyên tỷ lệ lớp ở mỗi fold. Sau khi xác định bộ siêu tham số tốt nhất, mô hình được huấn luyện lại trên toàn bộ tập huấn luyện và đánh giá lần cuối trên tập kiểm tra giữ nguyên (holdout), độc lập với quá trình tinh chỉnh.

Các chỉ số đánh giá trên tập kiểm tra gồm accuracy, precision, recall, F1 (tính riêng cho lớp At-risk) và ROC-AUC.

3.4 Kết quả trên bộ đặc trưng đầy đủ

Bảng 3.5 tổng hợp hiệu suất của bốn mô hình trên tập kiểm tra khi sử dụng đầy đủ 15 đặc trưng.


Bảng 3.5: So sánh các mô hình trên bộ 15 đặc trưng đầy đủ tại mốc 150 ngày. Chỉ số Precision/Recall/F1 tính riêng cho lớp **At-risk**.

Model	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.8263	0.7524	0.7659	0.7591	0.8972
Random Forest	0.8435	0.7804	0.7819	0.7812	0.9076
CatBoost	0.8501	0.8055	0.7652	0.7849	0.9114
LightGBM	0.8455	0.7868	0.7787	0.7827	0.9116

- **CatBoost** dẫn đầu ở ba chỉ số: accuracy (0.8501), precision At-risk (0.8055) và F1 At-risk (0.7849). Mô hình này tạo ra cảnh báo đáng tin cậy nhất và đạt cân bằng tốt nhất giữa precision và recall.
- **LightGBM** đạt ROC-AUC cao nhất (0.9116), nhưng chênh lệch so với CatBoost (0.9114) là không đáng kể; F1 At-risk của mô hình này (0.7827) cũng chỉ thấp hơn CatBoost khoảng 0.002 điểm.
- **Random Forest** có recall At-risk cao nhất (0.7819), tức bỏ sót ít sinh viên có nguy cơ nhất, nhưng phải đánh đổi bằng precision thấp hơn CatBoost. Nhìn chung, ba mô hình cây cho kết quả rất sát nhau với F1 nằm trong khoảng hẹp 0.7812–0.7849; không mô hình nào vượt trội rõ rệt.

- **Logistic Regression** có hiệu suất thấp nhất ở mọi chỉ số, phù hợp với kỳ vọng từ Chương 1 và Chương 2: dữ liệu có quan hệ phi tuyến và đa cộng tuyến giữa các đặc trưng hành vi trực tuyến, những đặc điểm mà mô hình tuyến tính khó nắm bắt đầy đủ.

Ma trận nhầm lẫn (confusion matrix) của từng mô hình trên tập kiểm tra được thể hiện ở Hình 3.3.




Hình 3.3: Ma trận nhầm lẫn trên tập kiểm tra — bộ đặc trưng đầy đủ, tại mốc 150 ngày.

Nhìn chung, phần lớn sai số của cả bốn mô hình nằm ở việc **bỏ sót sinh viên At-risk** (dự báo Pass trong khi thực tế At-risk), nhiều hơn so với cảnh báo nhầm (dự báo At-risk trong khi thực tế Pass). Đây là điểm cần lưu ý khi

triển khai: có thể hạ ngưỡng phân loại để tăng recall, chấp nhận thêm một số cảnh báo nhằm nhằm giảm rủi ro bỏ sót sinh viên cần hỗ trợ.

3.5 Độ quan trọng của đặc trưng

Hình 3.4 thể hiện độ quan trọng đặc trưng theo định nghĩa riêng của từng thuật toán: hệ số hồi quy tuyệt đối với Logistic Regression, độ giảm tạp chất Gini với Random Forest (theo công thức ở Mục 1.3.3), PredictionValuesChange với CatBoost, và số lần được dùng để phân tách với LightGBM. Do các giá trị này **không cùng đơn vị**, chỉ nên so sánh thứ hạng đặc trưng, không so sánh trực tiếp độ lớn giữa các mô hình.



Hình 3.4: Độ quan trọng đặc trưng (theo định nghĩa riêng của từng mô hình) tại mốc 150 ngày.

Để xây dựng một thứ hạng chung, mỗi đặc trưng được xếp hạng riêng trong từng mô hình, sau đó lấy trung bình cộng bốn hạng. Bảng 3.6 trình bày kết quả, sắp xếp tăng dần theo hạng trung bình.

Bảng 3.6: Thứ hạng độ quan trọng của từng đặc trưng theo mỗi mô hình (1 = quan trọng nhất) và hạng trung bình, sắp xếp tăng dần theo hạng trung bình.

Đặc trưng	LogReg	RF	CatBoost	LightGBM	Hạng TB
num_submitted_filled	1	2	1	2	1.50
avg_score_filled	4	1	4	1	2.50
num_due	5	7	3	5	5.00
active_weeks_filled	9	3	5	3	5.00
total_clicks_filled	2	4	11	6	5.75
avg_days_early_filled	8	5	8	3	6.00
highest_education	7	8	2	9	6.50
avg_weekly_clicks_filled	3	6	12	7	7.00
imd_band_filled	11	10	7	8	9.00
num_failed_filled	10	9	9	12	10.00
num_of_prev_attempts	13	12	6	10	10.25
no_submission_despite_due	6	13	15	15	12.25
studied_credits	15	11	13	11	12.50
disability	14	14	10	14	13.00
imd_missing	12	15	14	13	13.50

- **Nhóm dẫn đầu** — num_submitted_filled (số bài đã nộp) đứng hạng 1 ở Logistic Regression và CatBoost, hạng 2 ở Random Forest và LightGBM (hạng trung bình 1.50), khẳng định đây là tín hiệu dự báo mạnh và nhất quán nhất. Theo sau là avg_score_filled (điểm trung bình, hạng trung bình 2.50 — dẫn đầu ở Random Forest và LightGBM), rồi đến num_due (số bài đến hạn) và active_weeks_filled (số tuần hoạt động) cùng ở hạng trung bình 5.00. Cả bốn đều là đặc trưng **động**, phản ánh trực tiếp mức độ tham gia và kết quả học tập tích lũy của sinh viên.
- **Nhóm giữa** gồm các đặc trưng tương tác VLE còn lại (total_clicks_filled, avg_weekly_clicks_filled), avg_days_early_filled và highest_education — đóng góp bổ sung nhưng không mang tính quyết định.
- **Nhóm cuối** — studied_credits, disability, imd_missing có hạng trung bình cao nhất (ít quan trọng nhất), cho thấy các đặc trưng tĩnh mang tính nhân khẩu học có vai trò dự báo khiêm tốn hơn đáng kể so với các đặc trưng hành vi động.

3.6 Rút gọn đặc trưng: Top-10 và Top-5

Dựa trên thứ hạng ở Bảng 3.6, mười đặc trưng quan trọng nhất (Top-10) và năm đặc trưng quan trọng nhất (Top-5) được chọn để huấn luyện lại theo đúng quy trình tinh chỉnh đã mô tả ở Mục 3.3. Mục tiêu là kiểm tra liệu hiệu suất mô hình có **ổn định** khi giảm số lượng đặc trưng đầu vào hay không. Đây là yếu tố quan trọng trong triển khai thực tế, vì một hệ thống cảnh báo sử dụng ít đặc trưng hơn sẽ đơn giản hơn trong thu thập dữ liệu, vận hành và bảo trì.

Phân tích ở phần này tập trung vào **CatBoost**, mô hình đạt hiệu suất tốt nhất trong bước so sánh thuật toán (Mục 3.4). Việc thu hẹp về một mô hình duy nhất giúp câu hỏi đánh giá trở nên cụ thể hơn: *với mô hình dự kiến triển khai, có thể giảm bao nhiêu đặc trưng mà hiệu suất vẫn gần như được duy trì?* Bảng 3.7 đặt cạnh nhau kết quả của CatBoost trên ba bộ đặc trưng.

Bảng 3.7: Hiệu suất của CatBoost — mô hình tốt nhất ở bước so sánh thuật toán — trên ba bộ đặc trưng tại mốc 150 ngày. Chỉ số Precision/Recall/F1 tính riêng cho lớp **At-risk**.

Bộ đặc trưng	Số đặc trưng	Accuracy	Precision	Recall	F1	ROC-AUC
Full (15)	15	0.8501	0.8055	0.7652	0.7849	0.9114
Top-10	10	0.8501	0.7979	0.7774	0.7875	0.9119
Top-5	5	0.8462	0.7910	0.7742	0.7825	0.9088

- Hiệu suất **gần như không đổi** trên cả ba bộ đặc trưng: F1 At-risk chỉ dao động trong khoảng 0.7825–0.7875, với biên độ 0.005; accuracy cũng chỉ chênh 0.004. Kết quả này củng cố nhận định ở Mục 3.5: phần lớn sức mạnh dự báo tập trung ở một nhóm nhỏ đặc trưng hành vi động.
- Đáng chú ý, bộ **Top-10 đạt kết quả cao hơn bộ đầy đủ** ở ba trên năm chỉ số: F1 (0.7875 so với 0.7849), recall (0.7774 so với 0.7652) và ROC-AUC (0.9119 so với 0.9114), trong khi sử dụng ít hơn một phần ba số đặc trưng. Việc loại bỏ năm đặc trưng kém quan trọng nhất không những không làm giảm hiệu suất mà còn giúp mô hình phát hiện thêm sinh viên có nguy cơ. Điều này gợi ý rằng nhóm đặc trưng bị loại chủ yếu đóng góp nhiều hoặc thông tin dư thừa.
- Khi tiếp tục rút gọn xuống **Top-5**, hiệu suất bắt đầu giảm nhẹ nhưng vẫn ở mức không đáng kể: F1 thấp hơn bộ đầy đủ đúng 0.0024 và thấp hơn Top-10 0.0050. Đổi lại, số đặc trưng cần thu thập giảm từ 15 xuống 5.

- Xu hướng chung khi giảm đặc trưng là **precision giảm, recall tăng**: precision giảm từ 0.8055 (Full) xuống 0.7910 (Top-5), trong khi recall tăng nhẹ từ 0.7652 lên 0.7742. Với bài toán cảnh báo sớm, đây là hướng đánh đổi có lợi, vì bỏ sót một sinh viên cần hỗ trợ thường gây hậu quả lớn hơn một cảnh báo nhầm.

Tổng hợp lại, **bộ Top-5 là lựa chọn hợp lý cho triển khai thực tế**. Bộ này chỉ cần năm đặc trưng — `num_submitted_filled`, `avg_score_filled`, `num_due`, `active_weeks_filled`, `total_clicks_filled` — toàn bộ đều là hành vi học tập và không yêu cầu thông tin nhân khẩu học, nhưng vẫn giữ gần như trọn vẹn hiệu suất của mô hình dùng đủ 15 đặc trưng. Nếu ưu tiên hiệu suất cao nhất và chấp nhận thu thập nhiều dữ liệu hơn, Top-10 là phương án phù hợp hơn.


3.7 Hiệu chỉnh ngưỡng và độ tin cậy của kết quả

Hai phân tích trong phần này bổ sung cho các kết quả đã trình bày và đều được thực hiện trên **CatBoost với bộ 15 đặc trưng đầy đủ**, cấu hình đạt hiệu suất tốt nhất ở Mục 3.4. Phân tích thứ nhất xem xét câu hỏi vận hành: có thể phát hiện thêm bao nhiêu sinh viên có nguy cơ nếu chấp nhận thêm cảnh báo nhầm. Phân tích thứ hai đánh giá độ tin cậy của các chỉ số hiệu suất thông qua khoảng tin cậy bootstrap.

3.7.1 Hiệu chỉnh ngưỡng phân loại

Các kết quả từ đầu chương đến thời điểm này đều sử dụng **ngưỡng mặc định 0.5**: sinh viên được gán nhãn At-risk khi xác suất dự báo vượt quá 0.5. Ngưỡng này gần với điểm tối đa hoá F1 (F1 đạt đỉnh tại 0.53), nhưng F1 mặc định xem precision và recall có tầm quan trọng ngang nhau. Giả định này chưa phù hợp hoàn toàn với bài toán cảnh báo sớm, vì bỏ sót một sinh viên đang gặp rủi ro thường nghiêm trọng hơn việc tạo ra một cảnh báo nhầm cần cố vấn học tập rà soát. Do đó, hai loại sai lầm này **không có cùng chi phí**.

Hình 3.5 theo dõi ba chỉ số khi ngưỡng thay đổi từ 0.05 đến 0.95.




Hình 3.5: Precision, recall và F1 của lớp At-risk theo ngưỡng phân loại.

Điểm đáng chú ý nhất là **F1 gần như ổn định** trong một dải ngưỡng rộng, khoảng 0.35–0.60, trong khi precision và recall thay đổi theo hai hướng ngược nhau. Nói cách khác, có thể giảm ngưỡng phân loại mà chất lượng tổng hợp của mô hình gần như không suy giảm, đổi lại hệ thống ưu tiên phát hiện nhiều sinh viên có nguy cơ hơn.

Bảng 3.8 và Hình 3.6 lượng hoá sự đánh đổi này bằng số sinh viên cụ thể.

Bảng 3.8: Ảnh hưởng của ngưỡng phân loại lên kết quả dự báo của CatBoost tại mốc 150 ngày. Tập kiểm tra có 1,559 sinh viên At-risk thực tế; hàng in đậm là ngưỡng mặc định.

Ngưỡng	Recall	Precision	F1	Bắt được	Bỏ sót	Cảnh báo nhầm
0.50	0.7652	0.8055	0.7849	1193	366	288
0.40	0.8095	0.7490	0.7781	1262	297	423
0.30	0.8647	0.6710	0.7556	1348	211	661
0.20	0.9179	0.5884	0.7171	1431	128	1001



Hình 3.6: Ma trận nhầm lẫn trên tập kiểm tra tại bốn mức ngưỡng.

Khi giảm ngưỡng từ 0.5 xuống 0.4, số sinh viên At-risk bị bỏ sót giảm từ 366 xuống 297, tức **phát hiện thêm 69 sinh viên có nguy cơ**, trong khi F1 chỉ giảm 0.0068 (từ 0.7849 xuống 0.7781). Đổi lại, hệ thống phát sinh thêm 135 cảnh báo nhầm. Nếu tiếp tục hạ ngưỡng xuống 0.2, số sinh viên bị bỏ sót chỉ còn 128, nhưng số cảnh báo nhầm tăng lên 1.001; khi đó danh sách cảnh báo trở nên quá rộng và precision chỉ còn 0.5884.

Bảng 3.9 tiếp cận theo chiều ngược lại: đặt ra mức recall mong muốn rồi tính ngưỡng cần dùng và cái giá phải trả.

Bảng 3.9: Ngưỡng cần dùng để đạt các mức recall mục tiêu, và cái giá phải trả. Cột “Bắt thêm” và “Nhầm thêm” so với ngưỡng mặc định 0.5; cột cuối là số cảnh báo nhầm phát sinh trên mỗi sinh viên At-risk bắt thêm được.

Recall mục tiêu	Ngưỡng	Recall thực tế	Precision	Bắt thêm	Nhầm thêm	Còn bỏ sót	Nhầm/1 ca
80%	0.425	0.8005	0.7656	+55	+94	311	1.7
85%	0.335	0.8525	0.7024	+136	+275	230	2.0
90%	0.230	0.9012	0.6109	+212	+607	154	2.9
95%	0.145	0.9513	0.5350	+290	+1001	76	3.5

Cột cuối cùng — số cảnh báo nhầm phát sinh trên mỗi sinh viên At-risk được phát hiện thêm — thể hiện rõ **quy luật lợi ích cận biên giảm dần**. Ở giai đoạn đầu, mỗi sinh viên được phát hiện thêm đi kèm khoảng 2 cảnh báo nhầm; khi đẩy recall lên 95%, con số này tăng lên 3,45; nếu hạ ngưỡng xuống dưới 0.2, mỗi sinh viên phát hiện thêm tương ứng gần 8 cảnh báo nhầm.

Khuyến nghị. Vùng ngưỡng **0.40–0.43** là điểm cân bằng hợp lý: recall đạt khoảng 80%, precision vẫn trên 0.75 (tức khoảng ba trong bốn cảnh báo là chính xác), F1 gần như không đổi so với ngưỡng mặc định, và chi phí đánh đổi ở mức thấp trong toàn dải. Tuy nhiên, ngưỡng vận hành cuối cùng nên phụ thuộc vào **năng lực hỗ trợ thực tế** của nhà trường. Nếu đội ngũ cố vấn có thể theo sát

khoảng 2.000 sinh viên mỗi kỳ, ngưỡng có thể được hạ thêm để tăng recall; nếu nguồn lực hạn chế, ngưỡng cao hơn sẽ giúp danh sách cảnh báo ngắn và chính xác hơn.

Về phương pháp, các ngưỡng trên được khảo sát **trực tiếp trên tập kiểm tra**; do đó, kết quả chủ yếu minh họa sự đánh đổi giữa precision và recall, chưa phải một ngưỡng đã được kiểm định độc lập. Khi triển khai thực tế, ngưỡng nên được lựa chọn bằng kiểm định chéo trên tập huấn luyện, sau đó xác nhận lại trên tập kiểm tra độc lập.


3.7.2 Khoảng tin cậy bootstrap của các chỉ số

Mọi chỉ số trong báo cáo đều là **ước lượng điểm** tính trên một tập kiểm tra hữu hạn gồm 4.363 bản ghi. Nếu đánh giá trên một tập kiểm tra khác, các chỉ số này có thể thay đổi. Vì vậy, cần ước lượng mức độ dao động có thể xảy ra quanh các giá trị đã báo cáo.

Phương pháp **bootstrap** cho phép ước lượng độ bất định này mà không cần thu thập thêm dữ liệu. Cụ thể, tập kiểm tra được lấy mẫu lại **có hoàn lại**, giữ nguyên kích thước, và lặp lại $B = 2.000$ lần; ở mỗi lần lặp, toàn bộ chỉ số được tính lại. Phân phối của 2.000 giá trị thu được xấp xỉ phân phối lấy mẫu của chỉ số, từ đó sử dụng phân vị 2,5% và 97,5% làm khoảng tin cậy 95%.

Bảng 3.10: Khoảng tin cậy 95% của các chỉ số đánh giá, ước lượng bằng bootstrap trên tập kiểm tra ($B = 2,000$ lần lấy mẫu có hoàn lại) tại ngưỡng mặc định 0.5.

Chỉ số	Ước lượng điểm	KTC 95%	Độ rộng	Sai số chuẩn
Accuracy	0.8501	[0.8398; 0.8609]	0.0211	0.0053
Precision (At-risk)	0.8055	[0.7851; 0.8258]	0.0407	0.0105
Recall (At-risk)	0.7652	[0.7442; 0.7863]	0.0421	0.0108
F1 (At-risk)	0.7849	[0.7692; 0.8012]	0.0320	0.0082
ROC-AUC	0.9114	[0.9022; 0.9206]	0.0184	0.0047



Hình 3.7: Phân phối bootstrap của năm chỉ số đánh giá; đường liền là ước lượng điểm, hai đường đứt là biên khoảng tin cậy 95%.

- Trung bình bootstrap trùng khớp với ước lượng điểm tới bốn chữ số thập phân ở cả năm chỉ số, cho thấy các ước lượng **không có dấu hiệu bị chệch** đáng kể.
- **Accuracy** và **ROC-AUC** là hai chỉ số ổn định nhất (độ rộng khoảng tin cậy lần lượt 0.0211 và 0.0184), do được tính trên toàn bộ 4.363 bản ghi.
- **Precision** và **recall** của lớp At-risk dao động mạnh gấp đôi (độ rộng 0.0407 và 0.0421), điều dễ hiểu vì chỉ dựa trên nhóm thiểu số 1.559 sinh viên At-risk.

Hệ quả quan trọng nhất của phân tích này liên quan đến việc **xếp hạng các mô hình** ở Mục 3.4. Khoảng tin cậy của F1 trải từ 0.7692 đến 0.8012, tức rộng 0.032, trong khi chênh lệch F1 giữa ba mô hình cây chỉ nằm trong khoảng 0.0022 đến 0.0037. Các chênh lệch này **nhỏ hơn nhiều so với sai số lấy mẫu**, nên không đủ cơ sở thống kê để khẳng định CatBoost thực sự vượt trội hơn LightGBM và Random Forest. Ba mô hình này nên được xem là **tương đương** về hiệu suất, còn việc CatBoost dẫn đầu có thể phản ánh dao động riêng của tập kiểm tra. Ngược lại, khoảng cách giữa Logistic Regression (0.7591) và nhóm mô hình cây lớn hơn đáng kể, nên kết luận mô hình tuyến tính yếu hơn là đáng tin cậy hơn.


Nhận xét này không phủ nhận tính hợp lý của việc chọn CatBoost để triển khai, vì vẫn cần lựa chọn một mô hình đại diện và CatBoost đạt kết quả tốt nhất trên tập kiểm tra hiện có. Tuy nhiên, không nên diễn giải quá mức các chênh lệch nhỏ ở chữ số thập phân thứ ba. Để khẳng định một mô hình thực sự vượt trội, cần đánh giá trên nhiều tập kiểm tra độc lập hoặc sử dụng kiểm định thống kê cho chênh lệch giữa từng cặp mô hình.

3.8 Diễn giải mô hình bằng SHAP

Để làm rõ cơ chế ra quyết định của mô hình, phương pháp **SHAP** (SHapley Additive exPlanations) được áp dụng cho **CatBoost**, mô hình có F1 At-risk cao nhất trên bộ đặc trưng đầy đủ. Cơ sở lý thuyết của phương pháp này đã được trình bày ở Mục 1.7. Phân tích được thực hiện trên cả ba bộ đặc trưng (Full, Top-10, Top-5) nhằm kiểm tra mức độ nhất quán của diễn giải khi số lượng đặc trưng thay đổi.

Trước hết, phân tích được thực hiện ở cấp độ toàn cục nhằm xác định những đặc trưng có ảnh hưởng lớn nhất đến mô hình. Hình 3.8 trình bày kết quả SHAP


trên bộ đặc trưng đầy đủ. Biểu đồ beeswarm cho biết chiều và độ phân tán ảnh hưởng của từng đặc trưng đối với từng sinh viên, trong khi biểu đồ cột thể hiện mức độ quan trọng trung bình.




Hình 3.8: Diễn giải SHAP của CatBoost trên bộ đặc trưng đầy đủ (15 đặc trưng).

Kết quả SHAP nhất quán cao với thứ hạng độ quan trọng đặc trưng ở Bảng 3.6: `num_submitted_filled`, `avg_score_filled` và `active_weeks_filled` là ba đặc trưng có ảnh hưởng lớn nhất. Chiều tác động phù hợp với trực giác sư phạm: giá trị `num_submitted_filled` và `avg_score_filled` **thấp** (màu xanh) đẩy dự báo về phía **At-risk** (SHAP dương), trong khi giá trị **cao** (màu đỏ/tím) kéo dự báo về phía Pass. Riêng `num_due` (số bài đến hạn) thể hiện chiều **ngược lại**: giá trị cao (màu đỏ) lại đẩy về phía At-risk. Điều này hợp lý vì số bài đến hạn cao đồng nghĩa với khối lượng công việc tích lũy lớn, thường đi kèm nguy cơ trễ hạn hoặc bỏ bài cao hơn.

Hình 3.9 và Hình 3.10 lặp lại phân tích trên với hai bộ đặc trưng rút gọn.




Hình 3.9: Diễn giải SHAP của CatBoost trên bộ đặc trưng Top-10.




Hình 3.10: Diễn giải SHAP của CatBoost trên bộ đặc trưng Top-5.

Thứ tự và chiều ảnh hưởng của các đặc trưng còn lại hầu như **không đổi** khi loại bỏ dần các đặc trưng ít quan trọng. Đây là bằng chứng bổ sung cho tính ổn định đã quan sát ở Bảng 3.7, đồng thời cho thấy các đặc trưng bị loại bỏ chủ yếu đóng góp thông tin trùng lặp hoặc không đáng kể.

Sau khi xem xét xu hướng toàn cục, phân tích tiếp tục đi vào cấp độ cục bộ để làm rõ cách mô hình đưa ra quyết định cho từng sinh viên. Hình 3.11 trình bày biểu đồ waterfall của hai sinh viên đại diện, sử dụng mô hình CatBoost trên bộ đặc trưng đầy đủ: một trường hợp được dự báo mạnh về phía At-risk và một trường hợp được dự báo mạnh về phía Pass.



(a) Trường hợp đẩy mạnh về At-risk



(b) Trường hợp đẩy mạnh về Pass

Hình 3.11: Diễn giải cục bộ (waterfall) cho hai sinh viên đại diện.

- **Trường hợp At-risk:** sinh viên chưa nộp bài nào (`num_submitted_filled` = 0, kéo theo `avg_score_filled` = -1 — giá trị đánh dấu chưa có điểm) trong khi đã có 9 bài đến hạn (`num_due` = 9). Hai yếu tố này đóng góp lần lượt +2.60 và +3.01 vào điểm số dự báo; cộng thêm số tuần hoạt động thấp (`active_weeks_filled` = 6, đóng góp +1.24), tổng điểm bị đẩy lên 8.84, cao hơn đáng kể so với giá trị nền 0.92, tương ứng với xác suất At-risk rất cao.
- **Trường hợp Pass:** sinh viên có điểm trung bình cao (`avg_score_filled` = 95.33, kéo điểm số giảm 1.97) và số tuần hoạt động nhiều (`active_weeks_filled` = 25, giảm 1.17), cộng thêm lượt truy cập cao (`total_clicks_filled` = 9115, giảm 0.67) — tổng hợp lại tạo ra điểm số rất thấp (-5.18), tương ứng với xác suất Pass rất cao.

Hai ví dụ trên cho thấy mô hình đưa ra quyết định dựa trên những tín hiệu phù hợp với trực giác sư phạm: mức độ hoàn thành bài tập và điểm số tích lũy là những yếu tố quyết định, thống nhất với phân tích độ quan trọng đặc trưng ở quy mô toàn cục.

3.9 Kết luận

Từ quá trình tiền xử lý dữ liệu, xây dựng đặc trưng, huấn luyện, so sánh và diễn giải mô hình, có thể rút ra các kết luận chính sau:

- Việc gộp nhãn Fail và Withdrawn thành nhóm At-risk, đồng thời giới hạn dữ liệu tại mốc dự đoán 150 ngày, đưa bài toán về dạng phân loại nhị phân với mức mất cân bằng nhãn vừa phải (At-risk chiếm khoảng 36%). Vấn đề này

được xử lý bằng cách kết hợp SMOTE và trọng số lớp, đồng thời tinh chỉnh hai kỹ thuật này cùng với siêu tham số của từng mô hình thông qua Optuna.

- Trong số bốn thuật toán thử nghiệm, **CatBoost** đạt F1 At-risk cao nhất trên bộ đặc trưng đầy đủ (0.7849), đồng thời dẫn đầu cả về accuracy và precision; LightGBM bám sát ngay phía sau và giữ ROC-AUC cao nhất. Hai mô hình boosting này vượt trội hơn Logistic Regression một cách nhất quán trên mọi bộ đặc trưng, phù hợp với đặc tính lý thuyết của từng thuật toán ở Chương 1; tuy nhiên, khoảng cách giữa nhóm mô hình cây là nhỏ và cần được diễn giải thận trọng.
- Hiệu suất mô hình **ổn định cao** khi giảm số lượng đặc trưng từ 15 xuống 5; thậm chí CatBoost trên bộ Top-10 đạt F1 At-risk cao nhất trong toàn bộ thực nghiệm (0.7875). Kết quả này gợi ý một bộ **5 đặc trưng** (`num_submitted_filled`, `avg_score_filled`, `num_due`, `active_weeks_filled`, `total_clicks_filled`) — toàn bộ đều là đặc trưng hành vi học tập, không yêu cầu thông tin nhân khẩu học — có thể đủ để xây dựng một hệ thống cảnh báo sớm gọn nhẹ, dễ triển khai và duy trì.
- Phân tích SHAP cho thấy dự báo của mô hình dựa trên những tín hiệu phù hợp với trực giác sư phạm, gồm mức độ hoàn thành bài tập, điểm số tích lũy và khối lượng công việc còn tồn đọng. Các diễn giải này giữ được tính nhất quán qua cả ba bộ đặc trưng.

Hạn chế và hướng phát triển. Nghiên cứu hiện tập trung đánh giá chuyên sâu tại mốc 150 ngày. Một hướng mở rộng tự nhiên là huấn luyện và so sánh mô hình tại **nhiều mốc dự đoán** khác nhau, nhằm xác định thời điểm cảnh báo sớm nhất mà mô hình vẫn đạt độ tin cậy chấp nhận được, đồng thời theo dõi cách dự báo đối với cùng một sinh viên thay đổi theo thời gian. Bên cạnh đó, việc **hiệu chỉnh ngưỡng phân loại** theo chi phí thực tế của bỏ sót và cảnh báo nhầm, cùng với thử nghiệm mô hình trên dữ liệu của các cơ sở đào tạo khác, là những bước cần thiết trước khi đưa hệ thống vào vận hành thực tế.