

TRƯỜNG ĐẠI HỌC QUY NHƠN
KHOA TOÁN & THỐNG KÊ



TIỂU LUẬN MÔN HỌC:
PHÂN TÍCH DỮ LIỆU KHOA HỌC CHUYÊN NGÀNH

ỨNG DỤNG CÁC MÔ HÌNH HỌC MÁY
TRONG CẢNH BÁO SỚM RỦI RO HỌC TẬP

Trình độ đào tạo: Thạc sĩ

Học viên thực hiện: Nguyễn Hồ Bảo Thiên

Mã số sinh viên: 8282548017

Lớp: Khoa học dữ liệu K28B

Giảng viên hướng dẫn: TS. Hồ Văn Lâm

Gia Lai, 2026

Mục lục

Mở đầu	1
1 Cơ sở lý thuyết các thuật toán học máy	2
1.1 Tổng quan bốn thuật toán	2
1.2 Hồi quy Logistic (Logistic Regression)	3
1.2.1 Mô hình xác suất	3
1.2.2 Hàm mất mát và ước lượng tham số	4
1.2.3 Điều chuẩn (Regularization)	4
1.2.4 Trọng số lớp cho dữ liệu mất cân bằng	4
1.2.5 Ưu điểm và hạn chế	5
1.3 Cây quyết định và Random Forest	6
1.3.1 Cây quyết định (Decision Tree)	6
1.3.2 Bagging (Bootstrap Aggregating)	7
1.3.3 Random Forest	7
1.3.4 Độ quan trọng đặc trưng	8
1.3.5 Ưu điểm và hạn chế	8
1.4 Gradient Boosting và CatBoost	9
1.4.1 Nguyên lý Gradient Boosting	9
1.4.2 Ordered Boosting	9
1.4.3 Ordered Target Statistics cho đặc trưng phân loại	10
1.4.4 Cây đối xứng (Oblivious Trees)	10
1.4.5 Ưu điểm và hạn chế	11
1.5 LightGBM	11
1.5.1 Tăng trưởng cây theo lá (Leaf-wise Growth)	11
1.5.2 GOSS — Gradient-based One-Side Sampling	12
1.5.3 EFB — Exclusive Feature Bundling	13
1.5.4 Ưu điểm và hạn chế	13
1.6 So sánh tổng quan bốn thuật toán	13

2	Phân tích khám phá dữ liệu (EDA)	15
2.1	Tổng quan bộ dữ liệu OULAD	15
2.2	Phân tích dữ liệu đánh giá (Assessment)	17
2.2.1	Cấu trúc chung	17
2.2.2	Phân tích trọng số và phát hiện bất thường	19
2.2.3	Giá trị thiếu ở biến ngày thi	20
2.3	Phân tích hành vi tương tác VLE	20
2.3.1	Đặc điểm phân phối	20
2.4	Xây dựng tập dữ liệu dạng snapshot	22
2.4.1	Thiết kế panel theo thời gian	22
2.4.2	Quy mô và giá trị thiếu	22
2.4.3	Phân phối nhãn mục tiêu	23
2.4.4	Chia tập huấn luyện và kiểm tra	25
2.5	Phân tích khám phá các đặc trưng tĩnh	26
2.5.1	Chỉ số thiếu thốn kinh tế (<code>imd_band</code>)	26
2.5.2	Tình trạng khuyết tật (<code>disability</code>)	29
2.5.3	Lịch sử học lại (<code>num_of_prev_attempts</code>)	30
2.5.4	Phân tích theo nhãn mục tiêu	33
2.6	Phân tích khám phá các đặc trưng động	36
2.6.1	Thống kê mô tả	37
2.6.2	Số sinh viên còn học theo thời gian	37
2.6.3	Phân tích tương quan	38
2.6.4	Đặc trưng động theo nhãn mục tiêu	40
2.7	Xác nhận sự phù hợp của các thuật toán học máy	42
3	Xây dựng và so sánh mô hình	44
3.1	Tiền xử lý dữ liệu	44
3.1.1	Điền giá trị thiếu ở đặc trưng động	44
3.1.2	Xử lý giá trị thiếu ở <code>imd_band</code>	45
3.1.3	Mã hoá đặc trưng phân loại	45
3.1.4	Tập đặc trưng cuối cùng	46
3.1.5	Chuẩn hoá bài toán về phân loại nhị phân	46
3.2	Khảo sát sơ bộ theo các mốc dự đoán	47
3.2.1	Thiết lập thử nghiệm	47
3.2.2	Kết quả theo thời gian	47
3.2.3	Lựa chọn mốc dự đoán cho phân tích chuyên sâu	50

3.3	Phương pháp xây dựng mô hình	51
3.3.1	Các thuật toán sử dụng	51
3.3.2	Xử lý mất cân bằng nhãn	51
3.3.3	Thiết lập thực nghiệm	52
3.4	Kết quả trên bộ đặc trưng đầy đủ	52
3.5	Độ quan trọng của đặc trưng	55
3.6	Rút gọn đặc trưng: Top-10 và Top-5	56
3.7	Diễn giải mô hình bằng SHAP	60
3.7.1	Biểu đồ tổng quan (beeswarm và mean SHAP)	60
3.7.2	Diễn giải cục bộ: hai trường hợp minh hoạ	62
3.8	Kết luận	63

Danh sách hình vẽ

1.1	Hàm sigmoid (trái) và hàm mất mát Binary Cross-Entropy theo xác suất dự báo, ứng với hai trường hợp nhãn thật $y = 1$ và $y = 0$ (phải).	3
1.2	Ví dụ minh họa một cây quyết định nông (2 tầng) trên các đặc trưng của bài toán cảnh báo sớm. Giá trị p trong mỗi lá là xác suất At-risk ước lượng từ tỷ lệ mẫu huấn luyện rơi vào lá đó. . .	6
1.3	Sơ đồ nguyên lý Bagging: B cây được huấn luyện độc lập trên các mẫu bootstrap khác nhau, kết quả được tổng hợp bằng biểu quyết đa số (phân loại) hoặc trung bình (hồi quy).	7
1.4	Sơ đồ boosting tuần tự: mỗi cây yếu h_m được huấn luyện để dự báo giả phần dư của mô hình tổng hợp ở vòng trước, sau đó được cộng dồn (có trọng số η) vào mô hình.	9
1.5	So sánh chiến lược tăng trưởng cây level-wise (trái) và leaf-wise (phải) với cùng số lá.	12
2.1	Sơ đồ quan hệ thực thể (ERD) của bộ dữ liệu OULAD.	16
2.2	Phân phối số bài đánh giá theo học phần (code module).	18
2.3	Tỷ lệ các loại bài đánh giá (TMA, CMA, Exam).	19
2.4	Giá trị <code>weekly_clicks</code> theo các phân vị (percentile).	21
2.5	Phân phối nhãn <code>final_result</code> (4 lớp).	24
2.6	Phân phối nhãn sau khi gộp Distinction vào Pass (3 lớp).	25
2.7	Phân phối <code>imd_band</code> trong tập huấn luyện (nhóm '?' được tô màu cam).	26
2.8	Tỷ lệ <code>imd_band</code> theo trình độ học vấn — nhóm band cực trị (0–20% và 80–100%).	29
2.9	Tỷ lệ <code>imd_band</code> theo trình độ học vấn — nhóm band trung gian (20–80%).	29
2.10	Phân phối tình trạng khuyết tật (<code>disability</code>).	30

2.11	Phân phối số lần đăng ký học phần trước đó.	31
2.12	Phân phối biến <code>is_retake_the_course</code>	31
2.13	Tỷ lệ học lại theo tình trạng khuyết tật.	32
2.14	Biểu đồ hộp: <code>studied_credits</code> theo nhóm học lần đầu / học lại.	33
2.15	Biểu đồ radar các đặc trưng tĩnh theo nhóm kết quả.	34
2.16	Tỷ lệ kết quả học tập theo trình độ học vấn.	35
2.17	Tỷ lệ kết quả học tập theo nhóm <code>imd_band</code>	36
2.18	Số sinh viên còn hoạt động theo mốc dự đoán (mỗi 30 ngày).	38
2.19	Ma trận tương quan giữa các đặc trưng động.	39
2.20	Biểu đồ bong bóng: <code>avg_score</code> theo <code>num_failed</code>	40
2.21	Biểu đồ radar các đặc trưng động theo nhóm kết quả.	41
2.22	Giá trị trung bình <code>avg_days_early</code> theo nhóm kết quả.	42
3.1	Xu hướng hiệu suất mô hình theo từng mốc dự đoán (mỗi mốc một mô hình riêng).	48
3.2	Ma trận nhầm lẫn trên tập kiểm tra tại từng mốc dự đoán.	49
3.3	Ma trận nhầm lẫn trên tập kiểm tra — bộ đặc trưng đầy đủ (T=180).	54
3.4	Độ quan trọng đặc trưng (theo định nghĩa riêng của từng mô hình) tại T=180.	55
3.5	Ma trận nhầm lẫn của bốn mô hình trên hai bộ đặc trưng rút gọn Top-10 và Top-5 (T=180).	58
3.6	Biến động các chỉ số hiệu suất khi giảm số lượng đặc trưng: Full(15) $\rightarrow$ Top-10 $\rightarrow$ Top-5 (T=180).	58
3.7	So sánh F1 At-risk giữa bộ Top-10 và Top-5 theo từng mô hình.	59
3.8	Diễn giải SHAP của LightGBM trên bộ đặc trưng đầy đủ (15 đặc trưng).	61
3.9	Diễn giải SHAP của LightGBM trên bộ đặc trưng Top-10.	61
3.10	Diễn giải SHAP của LightGBM trên bộ đặc trưng Top-5.	62
3.11	Diễn giải cục bộ (waterfall) cho hai sinh viên đại diện.	62

Danh sách bảng

1.1	So sánh đặc điểm lý thuyết của bốn thuật toán.	14
2.1	Thống kê tổng quan bộ dữ liệu OULAD.	16
2.2	Thống kê mô tả các biến phân loại của dữ liệu đánh giá.	18
2.3	Thống kê mô tả dữ liệu tương tác VLE theo tuần.	20
2.4	Các biến có giá trị thiếu trong tập dữ liệu (tổng 178,294 dòng), sắp xếp theo tỷ lệ thiếu giảm dần.	23
2.5	Kết quả chia tập train/test theo sinh viên.	25
2.6	Phân phối <code>imd_band</code> (%) theo Region (chuẩn hoá theo hàng, sắp xếp giảm dần theo cột '?'). Màu đậm hơn = tỷ trọng cao hơn trong hàng.	27
2.7	Phân phối <code>imd_band</code> (%) theo trình độ học vấn (chuẩn hoá theo hàng). Màu đậm hơn = tỷ trọng cao hơn trong hàng.	28
2.8	Thống kê mô tả số tín chỉ (<code>studied_credits</code>) theo nhóm học lần đầu / học lại.	33
2.9	Giá trị trung bình các đặc trưng tính theo nhóm kết quả.	34
2.10	Thống kê mô tả các đặc trưng động (tính trên tập huấn luyện).	37
2.11	Giá trị trung bình các đặc trưng động theo nhóm kết quả.	41
3.1	Phương án mã hoá các đặc trưng phân loại.	45
3.2	Kết quả sơ bộ của mô hình Logistic Regression — một mô hình riêng cho mỗi mốc dự đoán T — trên tập kiểm tra. Precision/Recall/F1 tính riêng cho lớp At-risk.	48
3.3	Siêu tham số xử lý mất cân bằng nhãn được Optuna lựa chọn cho từng mốc dự đoán, cùng F1 At-risk trung bình qua 3-fold cross-validation.	50
3.4	Quy mô và phân phối nhãn nhị phân tại mốc dự đoán $T = 180$, sau khi gộp Fail và Withdrawn thành At-risk.	51

3.5	So sánh các mô hình trên bộ 15 đặc trưng đầy đủ (T=180). Chỉ số Precision/Recall/F1 tính riêng cho lớp At-risk	52
3.6	Thứ hạng độ quan trọng của từng đặc trưng theo mỗi mô hình (1 = quan trọng nhất) và hạng trung bình, sắp xếp tăng dần theo hạng trung bình.	56
3.7	So sánh các mô hình sau khi rút gọn về 10 đặc trưng quan trọng nhất (Top-10).	57
3.8	So sánh các mô hình sau khi rút gọn về 5 đặc trưng quan trọng nhất (Top-5).	57
3.9	Siêu tham số tối ưu liên quan đến xử lý mất cân bằng nhãn — tỷ lệ oversampling SMOTE và trọng số lớp At-risk — được Optuna lựa chọn cho từng mô hình và từng bộ đặc trưng, cùng F1 At-risk trung bình qua 3-fold cross-validation.	60

Mở đầu

Báo cáo này trình bày toàn bộ quá trình nghiên cứu xây dựng hệ thống *cảnh báo sớm rủi ro học tập* (early academic risk warning), phục vụ mục tiêu nhận diện sớm những sinh viên có nguy cơ **trượt môn** (Fail) hoặc **bỏ học** (Withdrawn) tại nhiều thời điểm trong suốt khoá học, từ đó giúp nhà trường can thiệp kịp thời.

Dữ liệu sử dụng là bộ **Open University Learning Analytics Dataset (OULAD)** do The Open University (Vương quốc Anh) công bố tháng 12 năm 2015. Bộ dữ liệu ghi lại thông tin về các học phần, sinh viên và toàn bộ tương tác của họ với Môi trường học tập trực tuyến (Virtual Learning Environment – VLE) trên bảy học phần được lựa chọn.

Toàn bộ nghiên cứu được tổ chức thành ba chương kế tiếp nhau:

1. **Cơ sở lý thuyết:** trình bày nguyên lý hoạt động, công thức toán học cốt lõi và phân tích ưu điểm — hạn chế của bốn thuật toán học máy được sử dụng trong nghiên cứu — Logistic Regression, Random Forest, CatBoost và LightGBM.
2. **Phân tích khám phá dữ liệu (EDA):** tìm hiểu cấu trúc, quy mô và chất lượng của bộ dữ liệu OULAD; xây dựng tập dữ liệu dạng *panel* (snapshot theo nhiều mốc thời gian) phù hợp với bài toán dự báo sớm; khám phá mối quan hệ giữa các đặc trưng nhân khẩu học, hành vi học tập và kết quả cuối khoá; qua đó xác nhận sự phù hợp của bốn thuật toán đã trình bày ở phần trước với đặc điểm dữ liệu thực tế.
3. **Xây dựng và so sánh mô hình:** tiền xử lý dữ liệu, khảo sát sơ bộ hiệu suất theo thời gian, huấn luyện và tinh chỉnh bốn thuật toán kết hợp kỹ thuật xử lý mất cân bằng nhãn, so sánh hiệu suất, đánh giá độ ổn định khi rút gọn đặc trưng, và diễn giải mô hình bằng SHAP.

Chương 1

Cơ sở lý thuyết các thuật toán học máy

1.1 Tổng quan bốn thuật toán

Bốn thuật toán được trình bày trong phần này — Logistic Regression, Random Forest, CatBoost và LightGBM — là các thuật toán học máy có giám sát phổ biến, phù hợp về mặt lý thuyết với các bài toán phân loại nhị phân mất cân bằng nhãn trên dữ liệu dạng bảng, có cả đặc trưng phân loại lẫn đặc trưng số. Sự phù hợp cụ thể của từng thuật toán với đặc điểm dữ liệu thực tế của bài toán cảnh báo sớm rủi ro học tập sẽ được đối chiếu và xác nhận qua quá trình phân tích khám phá dữ liệu ở Chương 2. Bốn thuật toán này đại diện cho ba trường phái tiếp cận khác nhau trong học máy có giám sát:

- **Mô hình tuyến tính** (Logistic Regression) — đơn giản, dễ diễn giải, làm cơ sở đối chiếu (baseline).
- **Học tập hợp dạng bagging** (Random Forest) — tổng hợp nhiều cây quyết định độc lập để giảm phương sai.
- **Học tập hợp dạng boosting** (CatBoost, LightGBM) — xây dựng tuần tự nhiều mô hình yếu để giảm sai số một cách có hệ thống, với hai cách hiện thực hoá khác nhau.

Với mỗi thuật toán, các mục tiếp theo trình bày: nguyên lý hoạt động, công thức toán học cốt lõi, các cơ chế đặc trưng riêng (nếu có), và phân tích ưu điểm — hạn chế trong bối cảnh bài toán cảnh báo sớm. Mục cuối của Chương 1 tổng hợp một bảng so sánh xuyên suốt bốn thuật toán theo nhiều tiêu chí thực tiễn.

1.2 Hồi quy Logistic (Logistic Regression)

1.2.1 Mô hình xác suất


Logistic Regression là một mô hình **tuyến tính suy rộng** (generalized linear model) cho bài toán phân loại nhị phân. Với vector đặc trưng đầu vào $\mathbf{x} \in \mathbb{R}^p$, mô hình trước tiên tính một tổ hợp tuyến tính:

$$z = \mathbf{w}^\top \mathbf{x} + b,$$

trong đó $\mathbf{w} \in \mathbb{R}^p$ là vector trọng số và b là hệ số chặn (bias). Giá trị z sau đó được ánh xạ về khoảng $(0, 1)$ thông qua **hàm sigmoid**:

$$\hat{p} = \sigma(z) = \frac{1}{1 + e^{-z}},$$

được diễn giải là xác suất dự báo của lớp dương (ở đây là At-risk). Quyết định phân loại cuối cùng dựa trên một ngưỡng τ (mặc định $\tau = 0.5$): $\hat{y} = 1$ nếu $\hat{p} \geq \tau$, ngược lại $\hat{y} = 0$.



Hình 1.1: Hàm sigmoid (trái) và hàm mất mát Binary Cross-Entropy theo xác suất dự báo, ứng với hai trường hợp nhãn thật $y = 1$ và $y = 0$ (phải).

Như minh họa ở Hình 1.1 (trái), hàm sigmoid có dạng chữ S, đối xứng qua điểm $(0, 0.5)$, bão hoà dần về 0 và 1 ở hai đầu — đây chính là cơ chế giúp mô hình tuyến tính z (có thể nhận giá trị bất kỳ trên $\mathbb{R}$) được chuyển thành một xác suất hợp lệ.

1.2.2 Hàm mất mát và ước lượng tham số

Tham số $(\mathbf{w}, b)$ được ước lượng bằng phương pháp **hợp lý cực đại** (Maximum Likelihood Estimation), tương đương với việc tối thiểu hoá hàm mất mát **Binary Cross-Entropy** (hay log-loss) trên tập huấn luyện gồm N mẫu:

$$\mathcal{L}(\mathbf{w}, b) = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \right].$$

Hình 1.1 (phải) minh hoạ trực quan hàm mất mát này: khi nhãn thật $y_i = 1$, mất mát giảm dần về 0 khi $\hat{p}_i \rightarrow 1$ nhưng tiến tới vô cực khi $\hat{p}_i \rightarrow 0$ — tức mô hình bị phạt rất nặng nếu dự báo sai với độ tin cậy cao. Vì $\mathcal{L}$ là hàm lồi theo $(\mathbf{w}, b)$, việc tối ưu thường dùng các phương pháp lặp dựa trên gradient (gradient descent hoặc các biến thể tựa Newton như L-BFGS), với đạo hàm riêng theo $\mathbf{w}$ có dạng tường minh:

$$\nabla_{\mathbf{w}} \mathcal{L} = \frac{1}{N} \mathbf{X}^\top (\hat{\mathbf{p}} - \mathbf{y}).$$

1.2.3 Điều chuẩn (Regularization)

Để hạn chế hiện tượng học vẹt (overfitting) khi số đặc trưng lớn hoặc các đặc trưng có tương quan mạnh, một số hạng điều chuẩn được cộng thêm vào hàm mục tiêu. Với điều chuẩn L_2 (Ridge), bài toán tối ưu trở thành:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^N \ell(y_i, \hat{p}_i),$$

trong đó ℓ là hàm mất mát log-loss của từng mẫu, và $C > 0$ là siêu tham số **ngịch đảo** của cường độ điều chuẩn: C càng nhỏ, mô hình bị ràng buộc càng chặt (trọng số $\mathbf{w}$ bị co về gần 0), giảm phương sai nhưng có thể tăng độ chệch (bias); C càng lớn, mô hình càng tự do khớp dữ liệu huấn luyện. Đây chính là siêu tham số C được tinh chỉnh bằng Optuna ở Chương 3.

1.2.4 Trọng số lớp cho dữ liệu mất cân bằng

Với bài toán mất cân bằng nhãn, hàm mất mát có thể được điều chỉnh bằng cách gán trọng số khác nhau cho từng lớp:

$$\mathcal{L}_w(\mathbf{w}, b) = -\frac{1}{N} \sum_{i=1}^N w_{y_i} \left[y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \right],$$

trong đó w_{y_i} là trọng số ứng với lớp của mẫu i (thường $w_0 = 1$ và $w_1 > 1$ cho lớp thiểu số At-risk). Việc tăng w_1 khiến mô hình phải trả giá mất mát lớn hơn khi phân loại sai một sinh viên At-risk, thúc đẩy mô hình dịch chuyển ranh giới quyết định để bắt được nhiều trường hợp At-risk hơn — đây chính là cơ chế `class_weight` được tinh chỉnh đồng thời với C và tỷ lệ SMOTE ở Chương 3.

1.2.5 Ưu điểm và hạn chế

Ưu điểm:

- Đơn giản, huấn luyện nhanh, phù hợp làm mô hình cơ sở để đối chiếu với các mô hình phức tạp hơn.
- Khả năng diễn giải cao: dấu và độ lớn của từng trọng số w_j (trên dữ liệu đã chuẩn hoá) cho biết chiều và mức độ ảnh hưởng của đặc trưng tương ứng đến nguy cơ At-risk.
- Đầu ra là xác suất được hiệu chỉnh tốt (well-calibrated) trong nhiều trường hợp, thuận lợi cho việc điều chỉnh ngưỡng cảnh báo theo nhu cầu thực tế.

Hạn chế:

- Ranh giới quyết định về bản chất là một siêu phẳng tuyến tính trong không gian đặc trưng, nên khó nắm bắt quan hệ phi tuyến và tương tác giữa các đặc trưng, trừ khi tự thêm số hạng tương tác thủ công.
- Nhạy cảm với đa cộng tuyến — khi hai đặc trưng tương quan cao, ma trận $\mathbf{X}^\top \mathbf{X}$ gần suy biến, khiến hệ số ước lượng bất ổn và khó diễn giải.
- Nhạy với thang đo của đặc trưng, bắt buộc phải chuẩn hoá dữ liệu số trước khi huấn luyện.
- Không tự xử lý được giá trị thiếu hay đặc trưng phân loại; cần điền khuyết và mã hoá thủ công trước khi đưa vào mô hình.

1.3 Cây quyết định và Random Forest

1.3.1 Cây quyết định (Decision Tree)


Cây quyết định (cụ thể là thuật toán CART — Classification and Regression Tree) xây dựng mô hình bằng cách chia đệ quy không gian đặc trưng thành các vùng ngày càng nhỏ, mỗi vùng ứng với một **lá** (leaf) mang một dự báo cụ thể. Tại mỗi nút, thuật toán chọn một đặc trưng j và một ngưỡng s sao cho việc chia dữ liệu thành hai nhánh $\{\mathbf{x} : x_j \leq s\}$ và $\{\mathbf{x} : x_j > s\}$ làm giảm nhiều nhất một độ đo **tạp chất** (impurity). Với bài toán phân loại, độ đo phổ biến nhất là chỉ số **Gini**:

$$\text{Gini}(t) = 1 - \sum_k p_k(t)^2,$$

trong đó $p_k(t)$ là tỷ lệ mẫu thuộc lớp k tại nút t . $\text{Gini}(t) = 0$ khi nút t hoàn toàn thuần nhất (chỉ chứa một lớp), và đạt giá trị lớn nhất khi các lớp phân bố đều. Độ giảm tạp chất khi chia nút t thành hai nút con t_L, t_R là:

$$\Delta\text{Gini} = \text{Gini}(t) - \frac{N_L}{N_t}\text{Gini}(t_L) - \frac{N_R}{N_t}\text{Gini}(t_R),$$

và thuật toán chọn cặp (j, s) tối đa hoá ΔGini tại mỗi nút. Quá trình chia dừng lại khi đạt điều kiện dừng (độ sâu tối đa, số mẫu tối thiểu mỗi lá, hoặc tạp chất bằng 0).




Hình 1.2: Ví dụ minh hoạ một cây quyết định nông (2 tầng) trên các đặc trưng của bài toán cảnh báo sớm. Giá trị p trong mỗi lá là xác suất At-risk ước lượng từ tỷ lệ mẫu huấn luyện rơi vào lá đó.

Cây quyết định đơn lẻ có ưu điểm diễn giải trực quan (Hình 1.2) và tự nhiên xử lý được cả đặc trưng số lẫn phân loại, nhưng có **phương sai rất cao**: chỉ cần thay đổi nhỏ trong dữ liệu huấn luyện cũng có thể dẫn đến một cấu trúc cây hoàn toàn khác, dễ học vẹt nếu để cây phát triển quá sâu.

1.3.2 Bagging (Bootstrap Aggregating)

Để giảm phương sai của cây quyết định, **bagging** huấn luyện nhiều cây độc lập trên các tập dữ liệu được lấy mẫu lại (bootstrap) từ tập huấn luyện gốc, rồi tổng hợp kết quả dự báo.



Hình 1.3: Sơ đồ nguyên lý Bagging: B cây được huấn luyện độc lập trên các mẫu bootstrap khác nhau, kết quả được tổng hợp bằng biểu quyết đa số (phân loại) hoặc trung bình (hồi quy).

Mỗi mẫu bootstrap D_b ($b = 1, \dots, B$) có cùng kích thước với D nhưng được lấy **có hoàn lại**, nên trung bình khoảng 63.2% số mẫu gốc xuất hiện trong mỗi D_b (một số mẫu lặp lại, một số không xuất hiện). Với bài toán phân loại, dự báo cuối cùng là lớp chiếm đa số trong B dự báo:

$$\hat{y}(\mathbf{x}) = \text{mode}\{T_1(\mathbf{x}), T_2(\mathbf{x}), \dots, T_B(\mathbf{x})\}.$$

Vì các cây được huấn luyện trên các mẫu khác nhau nên sai số của chúng có xu hướng **không tương quan hoàn toàn**; việc lấy trung bình/biểu quyết giúp triệt tiêu bớt nhiễu ngẫu nhiên, giảm phương sai tổng thể mà không làm tăng đáng kể độ chệch.

1.3.3 Random Forest

Random Forest cải tiến bagging bằng cách thêm một nguồn ngẫu nhiên hoá thứ hai: tại **mỗi nút** của mỗi cây, thay vì xét toàn bộ p đặc trưng để tìm điểm chia tốt nhất, thuật toán chỉ xét một tập con ngẫu nhiên gồm $m < p$ đặc trưng (thường $m \approx \sqrt{p}$ cho bài toán phân loại). Cơ chế này **decorrelate** (giảm tương quan) giữa các cây: nếu không có bước này, các cây bagging vẫn có xu hướng chọn cùng một vài đặc trưng mạnh nhất ở gần gốc, khiến chúng giống nhau và

hạn chế hiệu quả giảm phương sai.

1.3.4 Độ quan trọng đặc trưng

Random Forest cung cấp một thước đo độ quan trọng đặc trưng dựa trên tổng độ giảm tạp chất (Mean Decrease in Impurity):

$$\text{Importance}(x_j) = \frac{1}{B} \sum_{b=1}^B \sum_{t \in T_b: \text{split trên } x_j} \frac{N_t}{N} \Delta \text{Gini}(t),$$

tức trung bình cộng (qua toàn bộ B cây) tổng mức giảm Gini tại các nút sử dụng đặc trưng x_j để chia, có trọng số theo tỷ lệ mẫu đi qua nút đó. Đây là thước đo `feature_importances_` mặc định của Random Forest trong scikit-learn.

1.3.5 Ưu điểm và hạn chế

Ưu điểm:

- Tự nắm bắt quan hệ phi tuyến và tương tác giữa các đặc trưng mà không cần khai báo thủ công.
- Bền vững với giá trị ngoại lai và không yêu cầu chuẩn hoá dữ liệu.
- Cơ chế tổng hợp nhiều cây giúp giảm phương sai, hạn chế học vẹt so với một cây đơn lẻ; đồng thời cung cấp thước đo độ quan trọng đặc trưng.

Hạn chế:

- Mô hình công kênh (gồm B cây), tốc độ dự báo chậm hơn và khó diễn giải chi tiết so với hồi quy tuyến tính.
- Với dữ liệu mất cân bằng, cần kết hợp thêm trọng số lớp hoặc kỹ thuật lấy mẫu lại mới nhận diện tốt nhóm thiểu số.
- Không hỗ trợ xử lý giá trị thiếu trực tiếp trong hầu hết cài đặt phổ biến (như scikit-learn). Đặc trưng tương quan mạnh cũng làm sai lệch thước đo độ quan trọng — tầm quan trọng thực sự bị “chia sẻ” giữa các đặc trưng tương quan với nhau.

1.4 Gradient Boosting và CatBoost

1.4.1 Nguyên lý Gradient Boosting


Khác với bagging (huấn luyện các cây **độc lập** rồi tổng hợp), boosting xây dựng mô hình theo kiểu **tuần tự** (additive): mỗi cây mới được huấn luyện để sửa chữa sai số của tổ hợp các cây trước đó. Gọi $F_m(\mathbf{x})$ là mô hình tổng hợp sau m vòng, gradient boosting cập nhật:

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta h_m(\mathbf{x}),$$

trong đó $\eta \in (0, 1]$ là tốc độ học (learning rate) và h_m là một cây quyết định yếu (thường nông, vài tầng), được huấn luyện để xấp xỉ **gradient âm** của hàm mất mát tại F_{m-1} — gọi là **giả phần dư** (pseudo-residual):

$$r_i^{(m)} = - \left[\frac{\partial \ell(y_i, F(\mathbf{x}_i))}{\partial F(\mathbf{x}_i)} \right]_{F=F_{m-1}}.$$

Với hàm mất mát log-loss (như ở Logistic Regression), giả phần dư có dạng đơn giản $r_i^{(m)} = y_i - \hat{p}_i^{(m-1)}$ — tức phần chênh lệch giữa nhãn thật và xác suất dự báo hiện tại. Cây h_m được huấn luyện để dự báo chính các giả phần dư này, và mô hình dần được "sửa lỗi" qua từng vòng lặp.



Hình 1.4: Sơ đồ boosting tuần tự: mỗi cây yếu h_m được huấn luyện để dự báo giả phần dư của mô hình tổng hợp ở vòng trước, sau đó được cộng dồn (có trọng số η) vào mô hình.

CatBoost và LightGBM đều thuộc họ **Gradient Boosted Decision Trees** (GBDT) — dùng cây quyết định làm bộ học yếu h_m — nhưng khác nhau đáng kể ở cách hiện thực hoá nhằm giải quyết các nhược điểm cố hữu của GBDT truyền thống, được trình bày ở các mục tiếp theo.

1.4.2 Ordered Boosting

Một vấn đề tinh vi của GBDT truyền thống là **prediction shift** (lệch dự báo, hay rò rỉ mục tiêu): giả phần dư $r_i^{(m)}$ của một mẫu $\mathbf{x}_i$ được tính từ mô hình F_{m-1} vốn **đã được huấn luyện trên chính mẫu đó** ở các vòng trước, khiến

giả phần dư bị chệch (thiên lệch lạc quan) so với giả phần dư thật sự trên dữ liệu chưa nhìn thấy.

CatBoost khắc phục vấn đề này bằng **Ordered Boosting**: tại mỗi vòng, dữ liệu được xáo trộn ngẫu nhiên theo một hoán vị π ; giả phần dư của mẫu thứ i trong hoán vị chỉ được tính từ một mô hình $F_{m-1}^{(i)}$ huấn luyện **riêng** trên các mẫu **đứng trước** i trong hoán vị đó ($\{\mathbf{x}_j : \pi(j) < \pi(i)\}$) — tức mô hình dùng để tính giả phần dư của một mẫu chưa từng “nhìn thấy” nhãn của chính mẫu đó. Trong thực tế, CatBoost duy trì đồng thời nhiều mô hình phụ trợ ứng với nhiều tiền tố của hoán vị để việc này khả thi về mặt tính toán, thay vì huấn luyện lại từ đầu cho mỗi mẫu.

1.4.3 Ordered Target Statistics cho đặc trưng phân loại

Với đặc trưng phân loại có nhiều mức giá trị (ví dụ **region** trong dữ liệu OULAD), CatBoost không dùng one-hot encoding (tốn kém khi số mức lớn) mà mã hoá mỗi mức giá trị bằng một **thống kê mục tiêu** (target statistic) — xấp xỉ giá trị trung bình của nhãn ứng với mức giá trị đó. Để tránh rò rỉ thông tin (một dạng leakage tương tự prediction shift), thống kê này cũng được tính theo nguyên tắc *ordered*, chỉ dùng các mẫu đứng trước trong hoán vị ngẫu nhiên:

$$\text{TS}(\mathbf{x}_i^{(k)}) = \frac{\sum_{j: \pi(j) < \pi(i), x_j^{(k)} = x_i^{(k)}} y_j + a \cdot P}{\sum_{j: \pi(j) < \pi(i), x_j^{(k)} = x_i^{(k)}} 1 + a},$$

trong đó $x_i^{(k)}$ là giá trị của đặc trưng phân loại thứ k tại mẫu i , P là giá trị tiên nghiệm (thường là tỷ lệ nhãn dương toàn cục) và $a > 0$ là trọng số làm trơn (smoothing), giúp tránh ước lượng cực đoan khi một mức giá trị chỉ xuất hiện ở rất ít mẫu đứng trước nó trong hoán vị.

1.4.4 Cây đối xứng (Oblivious Trees)

CatBoost sử dụng **cây đối xứng** (oblivious trees) làm bộ học yếu: tại mỗi **tầng** của cây, toàn bộ các nút sử dụng **cùng một** cặp (đặc trưng, ngưỡng) để chia, thay vì mỗi nút được chọn độc lập như cây CART thông thường. Nhờ vậy, cây đối xứng có thể được biểu diễn như một **bảng tra cứu** (decision table) với 2^d lá ứng với d tầng, cho phép dự báo cực nhanh (chỉ cần d phép so sánh, không cần

duyet cây), đồng thời đóng vai trò như một cơ chế điều chuẩn tự nhiên, giảm nguy cơ học vẹt so với cây bất đối xứng thông thường.

1.4.5 Ưu điểm và hạn chế

Ưu điểm:

- Xử lý trực tiếp và hiệu quả các đặc trưng phân loại nhờ Ordered Target Statistics, không cần mã hoá thủ công.
- Ordered Boosting giảm đáng kể prediction shift, giúp mô hình ổn định và ít học vẹt ngay cả khi chưa tinh chỉnh nhiều.
- Bền vững với ngoại lai, nắm bắt tốt quan hệ phi tuyến, hỗ trợ trọng số lớp để bù đắp mất cân bằng nhãn, và tự động xử lý giá trị thiếu.
- Tốc độ dự báo rất nhanh nhờ cấu trúc cây đối xứng.

Hạn chế:

- Thời gian huấn luyện thường lâu hơn LightGBM, do chi phí duy trì nhiều mô hình phụ trợ cho Ordered Boosting.
- Vẫn là mô hình dạng “hộp đen”, cần công cụ bổ trợ (như SHAP) để diễn giải chi tiết từng dự báo.
- Kích thước mô hình khi lưu trữ thường nặng hơn so với các thuật toán cây khác.

1.5 LightGBM

LightGBM cũng là một hiện thực hoá của GBDT (Mục 1.4), nhưng theo hướng tối ưu **tốc độ và bộ nhớ** trên tập dữ liệu lớn, thông qua ba cải tiến chính: cách cây tăng trưởng, cách lấy mẫu dữ liệu, và cách nén đặc trưng.

1.5.1 Tăng trưởng cây theo lá (Leaf-wise Growth)

Hầu hết cài đặt GBDT truyền thống (bao gồm cả cây đối xứng của CatBoost) phát triển cây theo **tầng** (level-wise/depth-wise): tại mỗi vòng, **tất cả** các lá ở tầng hiện tại đều được xét để chia trước khi chuyển sang tầng kế tiếp, tạo ra cây cân đối. LightGBM thay vào đó phát triển cây theo **lá** (leaf-wise, hay best-first):

ở mỗi bước, thuật toán chỉ chia **một** lá — lá mang lại mức giảm mất mát lớn nhất trong số tất cả các lá hiện có — bất kể lá đó nằm ở tầng nào.



(a) Level-wise: chia đều tất cả các lá ở mỗi tầng, cây cân đối.

(b) Leaf-wise: luôn chia lá giảm mất mát nhiều nhất, cây bất đối xứng.

Hình 1.5: So sánh chiến lược tăng trưởng cây level-wise (trái) và leaf-wise (phải) với cùng số lá.

Như minh họa ở Hình 1.5, với cùng số lượng lá, chiến lược leaf-wise thường đạt mức giảm mất mát lớn hơn level-wise (vì luôn ưu tiên “điểm nóng” của sai số), nhưng đổi lại có thể tạo ra cây **sâu và lệch** hơn — dễ học vẹt hơn trên tập dữ liệu nhỏ nếu không kiểm soát chặt các siêu tham số như `num_leaves`, `max_depth` hay `min_child_samples`.

1.5.2 GOSS — Gradient-based One-Side Sampling

Trực giác của GOSS: những mẫu có **gradient lớn** (mô hình hiện tại dự báo sai nhiều) đóng góp nhiều thông tin hơn cho việc tìm điểm chia tốt ở vòng tiếp theo, trong khi những mẫu có gradient nhỏ (đã được dự báo tốt) đóng góp ít hơn. GOSS khai thác điều này để giảm số mẫu cần xét khi tìm điểm chia:

- Giữ lại **toàn bộ** $a\%$ số mẫu có gradient (trị tuyệt đối) lớn nhất.
- Lấy mẫu **ngẫu nhiên** $b\%$ trong số các mẫu gradient nhỏ còn lại.
- Để không làm chệch ước lượng độ giảm mất mát (vì đã bỏ bớt mẫu gradient nhỏ), gradient của các mẫu được lấy mẫu ngẫu nhiên này được **nhân bù** với hệ số $\frac{1-a}{b}$ khi tính toán thống kê tại mỗi điểm chia tiềm năng.

Nhờ đó, LightGBM có thể tìm điểm chia gần chính xác như khi dùng toàn bộ dữ liệu, nhưng chỉ cần xét một tập con nhỏ hơn nhiều — giảm đáng kể thời gian huấn luyện trên tập dữ liệu lớn.

1.5.3 EFB — Exclusive Feature Bundling

Với dữ liệu có nhiều đặc trưng thưa và **loại trừ lẫn nhau** (mutually exclusive — hiếm khi cùng khác 0, điển hình là các đặc trưng one-hot từ mã hoá biến phân loại nhiều mức), EFB gộp nhiều đặc trưng như vậy thành **một** đặc trưng tổng hợp duy nhất, bằng cách gán cho mỗi đặc trưng gốc một khoảng giá trị riêng biệt trong đặc trưng gộp. Việc xác định nhóm đặc trưng nào có thể gộp với nhau (cho phép một tỷ lệ xung đột nhỏ, có kiểm soát) được quy về bài toán **tô màu đồ thị** (graph coloring) trên đồ thị xung đột giữa các đặc trưng, giải gần đúng bằng thuật toán tham lam (greedy). Kết quả là số lượng đặc trưng cần xét khi xây dựng histogram cho việc tìm điểm chia giảm đáng kể, kéo theo tốc độ huấn luyện nhanh hơn mà hầu như không đánh đổi độ chính xác.

1.5.4 Ưu điểm và hạn chế

Ưu điểm:

- Huấn luyện rất nhanh và tiết kiệm bộ nhớ nhờ GOSS và EFB, phù hợp với tập dữ liệu lớn (hàng trăm nghìn bản ghi khi tính theo nhiều mốc thời gian).
- Chiến lược leaf-wise giúp đạt độ chính xác cao với số lá ít hơn so với level-wise.
- Nắm bắt tốt quan hệ phi tuyến và tương tác; bền vững với đa cộng tuyến và giá trị ngoại lai; tự động xử lý được giá trị thiếu và hỗ trợ trọng số lớp để bù mất cân bằng nhãn.

Hạn chế:

- Dễ học vẹt nếu không tinh chỉnh cẩn thận — cây leaf-wise có thể phát triển sâu và lệch, nhất là khi dữ liệu tại một số mốc thời gian còn ít.
- Nhạy với việc chọn siêu tham số (đặc biệt `num_leaves` và `min_child_samples`), cần tinh chỉnh kỹ để đạt hiệu quả tốt.
- Là mô hình dạng “hộp đen”, khó diễn giải trực tiếp nếu không dùng công cụ hỗ trợ.

1.6 So sánh tổng quan bốn thuật toán

Bảng 1.1 tổng hợp bốn thuật toán theo các tiêu chí thực tiễn liên quan trực tiếp đến đặc điểm dữ liệu của bài toán cảnh báo sớm rủi ro học tập.

Bảng 1.1: So sánh đặc điểm lý thuyết của bốn thuật toán.

Tiêu chí	LogReg	Random Forest	CatBoost	LightGBM
Kiểu học tập hợp	Không	Bagging	Boosting	Boosting
Nắm bắt phi tuyến	Không	Có	Có	Có
Cần chuẩn hoá dữ liệu	Có	Không	Không	Không
Xử lý đặc trưng phân loại	Cần mã hoá	Cần mã hoá	Tự động (Ordered TS)	Tự động (giới hạn)
Xử lý giá trị thiếu	Không	Không	Có	Có
Bền vững với ngoại lai	Thấp	Cao	Cao	Cao
Khả năng diễn giải	Cao	Trung bình	Thấp	Thấp
Tốc độ huấn luyện	Rất nhanh	Trung bình	Chậm nhất	Nhanh nhất
Tốc độ dự báo	Rất nhanh	Trung bình	Rất nhanh	Nhanh
Nguy cơ học vẹt	Thấp	Trung bình	Thấp (Ordered Boosting)	Trung bình–cao (leaf-wise)

Bốn thuật toán trình bày ở trên bổ khuyết cho nhau về mặt lý thuyết: Logistic Regression cung cấp một mô hình cơ sở đơn giản, nhanh và dễ diễn giải nhưng bị giới hạn bởi giả định tuyến tính; Random Forest và hai thuật toán boosting (CatBoost, LightGBM) đều dựa trên cây quyết định nên tự nhiên nắm bắt được quan hệ phi tuyến và tương tác giữa các đặc trưng — đặc điểm sẽ được đối chiếu với dữ liệu thực tế qua quá trình phân tích khám phá ở Chương 2 — nhưng khác biệt về cơ chế tổng hợp (song song vs. tuần tự) và do đó có đặc tính bias–variance khác nhau. Trong hai thuật toán boosting, CatBoost ưu tiên xử lý đặc trưng phân loại và giảm rò rỉ mục tiêu một cách nguyên bản, còn LightGBM ưu tiên tốc độ và khả năng mở rộng trên dữ liệu lớn. Chương 2 đối chiếu các đặc điểm dữ liệu thực tế của bài toán cảnh báo sớm rủi ro học tập với bốn thuật toán trình bày ở trên; sau đó Chương 3 trình bày kết quả huấn luyện và so sánh trực tiếp cả bốn thuật toán này trên chính dữ liệu đó, đối chiếu những đánh đổi lý thuyết vừa nêu trên thực nghiệm.

Chương 2

Phân tích khám phá dữ liệu (EDA)


Sau khi trình bày cơ sở lý thuyết của bốn thuật toán ở Chương 1, phần này phân tích khám phá bộ dữ liệu OULAD nhằm xác nhận sự phù hợp của các thuật toán đó với đặc điểm dữ liệu thực tế, đồng thời rút ra các định hướng tiền xử lý cho bước xây dựng mô hình ở Chương 3.

2.1 Tổng quan bộ dữ liệu OULAD

Bộ dữ liệu OULAD được tổ chức thành bảy bảng dữ liệu liên kết với nhau qua các định danh duy nhất, bao gồm các nhóm thông tin: bài đánh giá, học phần, thông tin sinh viên, đăng ký học, kết quả bài đánh giá và nhật ký tương tác của sinh viên với hệ thống học trực tuyến (VLE). Sơ đồ quan hệ giữa các bảng được minh hoạ ở Hình 2.1.

Open University Learning Analytics Dataset (OULAD)

Entity Relationship Diagram — 7 bảng



Hình 2.1: Sơ đồ quan hệ thực thể (ERD) của bộ dữ liệu OULAD.

Quy mô tổng thể của bộ dữ liệu được tóm tắt trong Bảng 2.1.

Bảng 2.1: Thống kê tổng quan bộ dữ liệu OULAD.

Thực thể	Số lượng
Sinh viên tham gia khóa học	32,953
Đợt mở học phần	22
Trang/tài nguyên VLE	6,364
Nhật ký tương tác VLE	10,655,280
Bản ghi đăng ký học	32,953
Bài đánh giá	206
Bản ghi kết quả đánh giá	173,912
Tổng số thuộc tính	43

Mỗi đợt mở học phần được định danh bằng mã `code_presentation` gồm **năm khai giảng** kèm **một chữ cái chỉ tháng khai giảng**. Chữ cái này mã hoá tháng theo **vị trí của nó trong bảng chữ cái**: A là chữ thứ 1 ứng với tháng 1, B là chữ thứ 2 ứng với tháng 2, ..., J là chữ thứ 10 ứng với tháng 10. Trong bộ dữ liệu chỉ xuất hiện hai giá trị: B (**tháng 2**) và J (**tháng 10**). Ví dụ, mã 2013J là đợt khai giảng tháng 10 năm 2013, còn 2014B là đợt khai giảng tháng 2 năm 2014. Mọi mốc thời gian trong dữ liệu (ngày nộp bài, ngày đăng ký, ngày tương tác VLE...) đều được tính tương đối so với ngày bắt đầu khoá học (ngày 0), cho phép so sánh nhất quán giữa các đợt học khác nhau.

2.2 Phân tích dữ liệu đánh giá (Assessment)

2.2.1 Cấu trúc chung

Dữ liệu đánh giá được ghép với thông tin học phần để bổ sung độ dài của từng đợt học. Sau khi làm sạch, dữ liệu có các đặc điểm sau:


- Bộ dữ liệu gồm **7 học phần**: AAA, BBB, CCC, DDD, EEE, FFF và GGG. Trong đó FFF có nhiều bài đánh giá nhất với 52 bài.
- Có **4 đợt mở học phần**: 2013B, 2013J, 2014B và 2014J.
- Có **3 loại bài đánh giá**, trong đó TMA chiếm nhiều nhất với 106/206 bài ($\approx 51\%$):
 - **TMA** (*Tutor Marked Assessment*) — bài đánh giá do giảng viên hoặc trợ giảng chấm thủ công, thường là bài tập tự luận nộp theo từng mốc trong khoá học.
 - **CMA** (*Computer Marked Assessment*) — bài đánh giá được hệ thống chấm tự động bằng máy tính, thường ở dạng trắc nghiệm.
 - **Exam** (*bài thi cuối kỳ*) — bài thi tổng kết, quyết định phần lớn hoặc toàn bộ kết quả học phần.
- Toàn bộ 206 bài đánh giá đều có mã định danh duy nhất — **không có bài đánh giá nào bị trùng lặp**.

Bảng 2.2 tóm tắt thống kê mô tả các biến phân loại của dữ liệu đánh giá.

Bảng 2.2: Thống kê mô tả các biến phân loại của dữ liệu đánh giá.


Biến	N	Số nhóm	Giá trị phổ biến	Tần suất
code_module	206	7	FFF	52
code_presentation	206	4	2014J	57
assessment_type	206	3	TMA	106

Phân phối số bài đánh giá theo học phần và tỷ lệ các loại bài đánh giá lần lượt được thể hiện ở Hình 2.2 và Hình 2.3.



Hình 2.2: Phân phối số bài đánh giá theo học phần (code module).

Percentage of Assessment Types



Hình 2.3: Tỷ lệ các loại bài đánh giá (TMA, CMA, Exam).

2.2.2 Phân tích trọng số và phát hiện bất thường

Tổng trọng số (*weight*) của các bài đánh giá được tính theo từng cặp (học phần, đợt học), qua đó ghi nhận một số điểm đáng chú ý:

- Phần lớn học phần (AAA, BBB, DDD, EEE, FFF) có tổng trọng số = 200 theo quy ước chung: 100% cho nhóm bài TMA/CMA và 100% cho bài thi cuối kỳ. Ngoài ra, không phải học phần nào cũng được mở đủ cả 4 đợt — ví dụ AAA chỉ có 2013J và 2014J.
- **GGG có tổng trọng số = 100:** tất cả bài TMA và CMA của GGG đều có *weight* = 0, chỉ bài Exam mới có *weight* = 100. Nói cách khác, kết quả học phần GGG phụ thuộc **hoàn toàn** vào bài thi cuối kỳ.
- **CCC có tổng trọng số = 300:** học phần CCC có 2 bài Exam trong mỗi đợt (mỗi bài *weight* = 100), cộng với TMA + CMA = 100, dẫn đến tổng bằng 300.

- Ở học phần CCC, giá trị ngày thi bị thiếu (ký hiệu '?') ở các bài thuộc loại Exam.

2.2.3 Giá trị thiếu ở biến ngày thi

Kiểm tra các bài có giá trị ngày thi bị thiếu cho thấy:

- Giá trị '?' chỉ xuất hiện ở loại Exam, không có ở TMA hay CMA — đây là dạng **thiếu có tính hệ thống**, không ngẫu nhiên.
- Có 11/24 bản ghi Exam bị thiếu ngày, chiếm gần một nửa ($\approx 45.8\%$).
- Mức độ thiếu theo học phần:
 - AAA, BBB, CCC: thiếu hoàn toàn — không đợt học nào có ngày thi chính xác.
 - DDD: chỉ thiếu 1 đợt (2014J), 3 đợt còn lại đầy đủ.
 - EEE, FFF, GGG: đầy đủ ngày thi cho tất cả các đợt.
- Nhiều khả năng các học phần này có lịch thi linh hoạt nên ngày thi không được ấn định sẵn trong hệ thống. Do bài thi cuối kỳ thường nằm ngoài khoảng thời gian dự báo, ảnh hưởng thực tế của việc thiếu này là **không đáng kể**.

2.3 Phân tích hành vi tương tác VLE

Dữ liệu tương tác VLE được tổng hợp về mức **tuần**: với mỗi sinh viên, số lần click được cộng dồn theo tuần, trong đó tuần được tính bằng $\lfloor \text{ngày}/7 \rfloor$ kể từ ngày bắt đầu học phần. Sau khi tổng hợp, dữ liệu tương tác theo tuần còn **627,031** bản ghi — giảm khoảng 4 lần so với dữ liệu chi tiết ban đầu (2,518,170 dòng); mỗi bản ghi là tổng số click của một sinh viên trong một tuần.

2.3.1 Đặc điểm phân phối


Bảng 2.3 trình bày thống kê mô tả của số tuần (**week**) và số click theo tuần (**weekly_clicks**).

Bảng 2.3: Thống kê mô tả dữ liệu tương tác VLE theo tuần.

Biến	N	Trung bình	Độ lệch chuẩn	Min	Q1	Trung vị	Q3	Max
week	627,031	14.06	11.02	-4.00	4.00	13.00	23.00	38.00
weekly_clicks	627,031	63.16	96.59	1.00	9.00	30.00	78.00	6,999.00

- **Biến week:** giá trị nhỏ nhất = -4 cho thấy một số sinh viên đã truy cập VLE *trước* khi khoá học chính thức bắt đầu. 50% số bản ghi nằm trong khoảng tuần 4–23 (giai đoạn giữa khoá). Giá trị lớn nhất = 38 (≈ 9.5 tháng) phù hợp với độ dài các học phần trong OULAD (≈ 240 –270 ngày).
- **Biến weekly_clicks:** phân phối lệch phải nặng — trung vị chỉ bằng 30 trong khi trung bình lên tới 63.16, chứng tỏ giá trị trung bình bị đẩy lên bởi các giá trị ngoại lai; cá biệt có giá trị lớn nhất bằng 6,999 trong khi $Q_3 = 78$. Độ lệch chuẩn (96.59) còn lớn hơn cả giá trị trung bình, cho thấy mức độ phân tán rất lớn.

Để mô tả rõ hơn đuôi phải của phân phối, Hình 2.4 biểu diễn giá trị `weekly_clicks` theo các phân vị.



Hình 2.4: Giá trị `weekly_clicks` theo các phân vị (percentile).

- Từ P0 đến P75, `weekly_clicks` tăng chậm từ 1 đến khoảng 80 — phần lớn sinh viên tương tác ở mức vừa phải mỗi tuần.
- Từ P75 trở đi, đường cong dốc lên nhanh — dấu hiệu của phân phối lệch phải với đuôi dài.
- $P_{90} = 159$ và $P_{95} = 232$: nhóm 10% sinh viên tích cực nhất có lượng click gấp ≈ 2.5 lần mức trung bình chung (63.16).

2.4 Xây dựng tập dữ liệu dạng snapshot

2.4.1 Thiết kế panel theo thời gian

Để phù hợp với mục tiêu *dự báo sớm*, dữ liệu được tái cấu trúc thành dạng panel (dữ liệu bảng theo thời gian). Với mỗi mốc thời gian $T \in \{30, 60, 90, 120, 150, 180, 210, 240\}$ (ngày kể từ đầu khoá), ta tạo một *snapshot* thể hiện trạng thái của từng sinh viên tại thời điểm đó. Mỗi sinh viên xuất hiện tối đa 8 lần (8 snapshot).

Tại mỗi mốc T , quy trình tính đặc trưng như sau:

- **Lọc sinh viên còn hoạt động:** loại bỏ những sinh viên đã hủy đăng ký trước ngày T .
- **Đặc trưng VLE** (chỉ lấy dữ liệu đến tuần tương ứng với T): `total_clicks` (tổng click tích lũy), `active_weeks` (số tuần có tương tác), `avg_weekly_clicks` (click trung bình mỗi tuần).
- **Đặc trưng đánh giá** (chỉ lấy bài có hạn nộp $\leq T$ và đã nộp trước T): `num_submitted`, `avg_score` (điểm trung bình có trọng số), `avg_days_early` (độ sớm/trễ khi nộp), `num_failed` (số bài trượt, điểm < 40).
- **Đặc trưng tĩnh và nhãn:** thông tin nhân khẩu học của sinh viên và nhãn `final_result`.

Lưu ý: học phần GGG được loại khỏi tập dữ liệu do đặc thù trọng số bất thường đã phân tích ở trên — kết quả của học phần này phụ thuộc hoàn toàn vào bài thi cuối kỳ nên không phù hợp với cách dự báo dựa trên hành vi tích lũy.

2.4.2 Quy mô và giá trị thiếu

Tập dữ liệu thu được gồm **178,294 dòng** và **22 biến**, bao gồm thông tin nhân khẩu học, hành vi học tập (VLE), kết quả bài tập và kết quả cuối kỳ, với nhiều kiểu dữ liệu: 10 biến dạng phân loại, 10 biến số thực và 2 biến số nguyên.

Bảng 2.4 liệt kê các biến có giá trị thiếu cùng tỷ lệ tương ứng.

Bảng 2.4: Các biến có giá trị thiếu trong tập dữ liệu (tổng 178,294 dòng), sắp xếp theo tỷ lệ thiếu giảm dần.

Biến	Số dòng thiếu	Tỷ lệ thiếu (%)
<code>date_unregistration</code>	162,208	90.98
<code>avg_score</code>	18,532	10.39
<code>num_submitted</code>	16,183	9.08
<code>avg_days_early</code>	16,183	9.08
<code>num_failed</code>	16,183	9.08
<code>total_clicks</code>	3,035	1.70
<code>active_weeks</code>	3,035	1.70
<code>avg_weekly_clicks</code>	3,035	1.70


Nhận xét về giá trị thiếu:

- Biến **ngày hủy đăng ký** thiếu nhiều nhất ($\approx 91.0\%$) vì phần lớn sinh viên theo học đến hết khoá nên không có ngày hủy đăng ký — đây là dạng thiếu mang ý nghĩa tích cực.
- Các biến VLE (`total_clicks`, `active_weeks`, `avg_weekly_clicks`) thiếu $\approx 1.7\%$, nhiều khả năng do một số sinh viên chưa từng truy cập hệ thống.
- Các biến đánh giá (`avg_score`, `num_submitted`...) thiếu đáng kể ($\approx 9\text{--}10\%$), do một số sinh viên chưa nộp bài tại thời điểm dự báo.

Ngoài dạng thiếu thông thường (giá trị rỗng) nêu trên, biến `imd_band` còn có một dạng thiếu **được mã hoá bằng ký hiệu '?'** (khoảng 4% số sinh viên). Dạng thiếu này không xuất hiện khi thống kê giá trị rỗng nên cần được nhận diện và xử lý riêng; phân bố cụ thể sẽ được phân tích ở Mục 2.5.1.

2.4.3 Phân phối nhãn mục tiêu


Phân phối nhãn `final_result` ban đầu gồm bốn lớp (Hình 2.5):



Hình 2.5: Phân phối nhãn `final_result` (4 lớp).

- **Pass** chiếm tỷ lệ cao nhất với 89,944 bản ghi (50.4%).
- **Fail** đứng thứ hai với 50,525 bản ghi (28.3%) — gần 1/3 lượt đăng ký không đạt, là nhóm quan trọng nhất cần được dự báo sớm.
- **Distinction** chiếm 11.8% (21,024 bản ghi) — nhóm sinh viên xuất sắc.
- **Withdrawn** chiếm 9.4% (16,801 bản ghi) — lượt đăng ký bị hủy giữa chừng; nhóm này thường bộc lộ dấu hiệu sớm qua mức tương tác thấp.

Mỗi bản ghi là một bộ ba (sinh viên, học phần, đợt học) tại một snapshot T ; một sinh viên có thể xuất hiện nhiều lần nếu đăng ký nhiều học phần hoặc nhiều đợt. Với bài toán cảnh báo sớm, việc phân biệt Distinction với Pass là không cần thiết — mục tiêu là phát hiện sinh viên có nguy cơ trượt hoặc bỏ học. Do đó, **Distinction được gộp vào Pass** (Hình 2.6).



Hình 2.6: Phân phối nhãn sau khi gộp Distinction vào Pass (3 lớp).

Sau khi gộp, tỷ lệ Pass : Fail : Withdrawn = 62.2% : 28.3% : 9.4%, cho thấy tập dữ liệu có mức **mất cân bằng nhãn vừa phải** — cần lưu ý ở bước xây dựng mô hình.

2.4.4 Chia tập huấn luyện và kiểm tra

Tập dữ liệu được chia thành tập huấn luyện (train) và kiểm tra (test) theo **từng sinh viên**, đảm bảo toàn bộ lịch sử của một sinh viên chỉ nằm trong một tập duy nhất. Nếu chia theo từng dòng, cùng một sinh viên có thể xuất hiện ở cả train lẫn test với các snapshot khác nhau. Khi đó, mô hình được huấn luyện trên chính hành vi của sinh viên có mặt trong tập kiểm tra, dẫn đến hiện tượng rò rỉ dữ liệu (data leakage) và làm sai lệch kết quả đánh giá.

Với tỷ lệ train:test = 80 : 20, kết quả chia được tóm tắt ở Bảng 2.5.

Bảng 2.5: Kết quả chia tập train/test theo sinh viên.

Tập	Số sinh viên	Số snapshot
Train	17,921	142,384
Test	4,481	35,910


2.5 Phân tích khám phá các đặc trưng tĩnh

Thông tin tĩnh của sinh viên được xem xét theo hai nhóm phục vụ phân tích:

- **Thông tin nhân khẩu học** (`gender`, `region`, `age_band`, `imd_band`, `highest_education`, `disability`), xét mỗi sinh viên một lần (loại bỏ trùng lặp).
- **Đặc trưng hành vi tĩnh** (`num_of_prev_attempts`, `studied_credits`) gắn với từng lượt đăng ký học phần, kèm nhãn kết quả `final_result`.

2.5.1 Chỉ số thiếu thốn kinh tế (`imd_band`)

Biến `imd_band` đo mức độ thiếu thốn kinh tế theo khu vực địa lý (Index of Multiple Deprivation), được kỳ vọng có liên quan đến kết quả học tập. Hình 2.7 thể hiện phân phối của biến này.



Hình 2.7: Phân phối `imd_band` trong tập huấn luyện (nhóm '?' được tô màu cam).

Phân phối `imd_band` tập trung cao nhất ở band 30–40% (1,925 sinh viên) và giảm dần về hai phía. Nhìn chung, phần lớn sinh viên đến từ các khu vực có mức độ thiếu thốn trung bình đến cao, trong khi số sinh viên ở các khu vực khá giả ít hơn. Đáng chú ý, có 720 sinh viên ($\approx 4.2\%$) mang giá trị '?', cần được xử lý trước khi đưa vào mô hình.

Giá trị thiếu theo vùng. Giá trị '?' trong `imd_band` tập trung gần như hoàn toàn ở hai vùng: North Region (64.86%) và Ireland (25.42%) — cộng lại

chiếm $\approx 90.3\%$ tổng số giá trị thiếu; các vùng còn lại chỉ đóng góp $\approx 9.7\%$. Xét theo chiều ngược lại (tỷ lệ '?' trong mỗi vùng):

- North Region (45.65%) và Ireland (23.40%) có tỷ lệ '?' vượt trội so với tất cả các vùng còn lại (đều $\leq 2\%$), cho thấy tình trạng thiếu dữ liệu này gắn với đặc thù của từng vùng địa lý.
- North Western (0–10%: 23.09%), Yorkshire (0–10%: 19.42%) và West Midlands (0–10%: 17.52%) là những vùng tập trung nhiều sinh viên thuộc band IMD thấp nhất. London cũng nghiêng về các mức IMD thấp (10–20%: 19.30%; 20–30%: 18.37%).
- South Region (90–100%: 21.74%; 80–90%: 15.55%) và South East Region tập trung ở các band cao. East Anglian Region có xu hướng tương tự.
- Scotland, East Midlands, Wales và South West Region không lệch rõ về phía nào, các band dao động tương đối đều trong khoảng 7–13%.

Bảng 2.6 trình bày đầy đủ phân phối `imd_band` theo từng vùng (chuẩn hoá theo hàng), làm rõ các nhận xét trên.

Bảng 2.6: Phân phối `imd_band` (%) theo Region (chuẩn hoá theo hàng, sắp xếp giảm dần theo cột '?'). Màu đậm hơn = tỷ trọng cao hơn trong hàng.

Region	0-10	10-20	20-30	30-40	40-50	50-60	60-70	70-80	80-90	90-100	?
North Region	8.11	10.85	6.74	5.96	5.87	3.71	3.52	4.69	4.50	0.39	45.65
Ireland	9.72	10.10	6.91	7.80	5.75	8.82	7.80	6.65	6.65	6.39	23.40
South Region	1.05	4.50	5.73	6.55	10.93	10.40	8.88	12.62	15.55	21.74	2.05
West Midlands Region	17.52	14.43	11.03	8.99	10.35	7.48	8.61	8.99	5.74	4.98	1.89
South West Region	3.99	7.29	10.74	15.57	12.65	12.19	10.20	12.58	7.90	6.67	0.23
Yorkshire Region	19.42	12.21	12.31	10.48	9.62	9.62	7.31	10.48	5.00	3.37	0.19
Scotland	8.14	7.76	10.29	11.27	10.80	12.21	10.38	9.49	9.92	9.54	0.19
North Western Region	23.09	12.23	13.46	12.23	7.79	7.72	7.10	7.31	5.67	3.35	0.07
East Anglian Region	3.25	4.60	8.36	10.38	12.17	11.33	12.06	12.73	11.89	13.24	0.00
London Region	10.59	19.30	18.37	14.63	10.21	8.66	5.98	4.92	4.55	2.80	0.00
East Midlands Region	7.43	12.54	11.06	10.64	10.64	9.74	10.40	8.42	10.64	8.50	0.00
South East Region	2.58	7.49	8.61	11.46	10.85	11.02	13.95	10.42	11.20	12.40	0.00
Wales	11.87	10.71	12.67	11.51	9.40	9.98	8.96	8.81	8.89	7.21	0.00

Giá trị thiếu theo trình độ học vấn. Xét quan hệ giữa `imd_band` và `highest_education`:


- *No Formal quals* tập trung mạnh ở các band thấp (20–30%: 22.50%; 0–10%: 18.75%...), gần như không xuất hiện ở band 80–90%. Tỷ lệ '?' = 9.38% (cao thứ hai).
- *Lower Than A Level* giảm dần từ band thấp đến band cao (11.43% → 6.39%). Tỷ lệ '?' = 3.72%.
- *A Level or Equivalent* phân phối tương đối đồng đều (8–11%). Tỷ lệ '?' = 2.34%.
- *HE Qualification* phân bố đồng đều chủ yếu ở các band trung bình đến cao, nhóm 90–100% chiếm tỷ lệ lớn nhất (10.95%). Tỷ lệ '?' = 6.68%.
- *Post Graduate Qualification* có tỷ lệ '?' cao nhất (41.85%), gần như không có sinh viên ở band 0–10%, tập trung rõ ở band 90–100% (25%).

Bảng 2.7 trình bày đầy đủ các con số này.


Bảng 2.7: Phân phối *imd_band* (%) theo trình độ học vấn (chuẩn hoá theo hàng). Màu đậm hơn = tỷ trọng cao hơn trong hàng.

Highest education	0-10	10-20	20-30	30-40	40-50	50-60	60-70	70-80	80-90	90-100	?
No Formal quals	18.75	16.25	22.50	18.12	1.88	5.00	5.62	1.25	0.00	1.25	9.38
Lower Than A Level	11.43	11.37	11.55	10.70	10.05	9.56	8.59	8.67	7.95	6.39	3.72
A Level or Equivalent	8.72	9.90	9.97	10.89	10.65	10.16	9.62	10.02	8.93	8.80	2.34
HE Qualification	6.65	7.45	9.86	10.60	9.48	9.48	8.92	9.76	10.18	10.95	6.68
Post Graduate Qualification	0.00	4.35	6.52	1.63	1.63	3.80	4.89	1.63	8.70	25.00	41.85

Hình 2.8 và Hình 2.9 trực quan hoá xu hướng này. Ở nhóm band cực trị (Hình 2.8), hai band thấp (0–10%, 10–20%) và hai band cao (80–90%, 90–100%) biến động ngược chiều nhau theo trình độ học vấn: tỷ trọng band thấp giảm mạnh còn band cao tăng dần khi học vấn tăng — đặc biệt band 90–100% tăng vọt ở nhóm Post Graduate Qualification. Bốn đường gần như giao nhau quanh mức *A Level or Equivalent*, cho thấy đây là ngưỡng học vấn mà mối liên hệ với *imd_band* bắt đầu đảo chiều. Ở nhóm band trung gian (20–80%, Hình 2.9), các đường biến động khá tương đồng và không band nào nổi bật hẳn.




Hình 2.8: Tỷ lệ imd_band theo trình độ học vấn — nhóm band cực trị (0–20% và 80–100%).



Hình 2.9: Tỷ lệ imd_band theo trình độ học vấn — nhóm band trung gian (20–80%).

2.5.2 Tình trạng khuyết tật (disability)

Phân phối *disability* trong tập huấn luyện được thể hiện ở Hình 2.10: phần lớn sinh viên không khai báo khuyết tật (91.1%), nhóm có khuyết tật chỉ chiếm 8.9%.




Hình 2.10: Phân phối tình trạng khuyết tật (disability).

Tỷ lệ khuyết tật thể hiện xu hướng **ngịch biến rõ rệt** với `imd_band`: các band thấp (0–40%) có tỷ lệ sinh viên khuyết tật cao hơn (11–13%), trong khi các band cao (70–100%) có tỷ lệ thấp hơn (5–7%). Như vậy, sinh viên ở những khu vực khó khăn hơn về kinh tế có tỷ lệ khai báo khuyết tật cao hơn — điều này có thể phản ánh sự chênh lệch trong khả năng tiếp cận hỗ trợ y tế và giáo dục giữa các nhóm kinh tế – xã hội.


2.5.3 Lịch sử học lại (`num_of_prev_attempts`)

Biến `num_of_prev_attempts` cho biết số lần sinh viên đã đăng ký học phần này trước đây, qua đó phân biệt sinh viên học lần đầu với sinh viên học lại (retake). Phân phối được thể hiện ở Hình 2.11.



Hình 2.11: Phân phối số lần đăng ký học phần trước đó.

Từ biến này, ta tạo biến nhị phân `is_retake_the_course`: nhận giá trị 1 nếu sinh viên đã từng đăng ký học phần trước đó và 0 nếu học lần đầu. Các mức học lại (1, 2, 3...) được gộp thành một nhóm duy nhất, vì điều quan trọng là sinh viên *đã từng* phải học lại hay chưa, chứ không phải học lại bao nhiêu lần (Hình 2.12).




Hình 2.12: Phân phối biến `is_retake_the_course`.

Phần lớn sinh viên (86.5%) đăng ký học phần lần đầu, 13.5% còn lại là các trường hợp học lại. Tỷ lệ này giảm rất nhanh theo số lần học lại: học lại lần đầu chiếm 10.8%, lần hai chỉ còn 2.1%, và từ ba lần trở lên rất hiếm ($< 0.5\%$). Điều


này cho thấy phần lớn sinh viên không đăng ký học lại sau khi trượt học phần.

Học lại và tình trạng khuyết tật. Hình 2.13 cho thấy nhóm sinh viên khuyết tật có tỷ lệ học lại (20.1%) cao hơn rõ rệt so với nhóm không khuyết tật (12.9%). Kết quả này gợi ý khuyết tật là một yếu tố rủi ro trong học tập: nhóm này gặp nhiều trở ngại hơn nên phải học lại thường xuyên hơn.



Hình 2.13: Tỷ lệ học lại theo tình trạng khuyết tật.

Học lại và khối lượng tín chỉ. Hình 2.14 so sánh phân phối `studied_credits` giữa hai nhóm. Sinh viên học lại đăng ký nhiều tín chỉ hơn đáng kể so với nhóm học lần đầu: trung vị 90 so với 60 tín chỉ, trung bình 98.9 so với 77.8. Phân phối của nhóm học lại cũng rộng hơn (độ lệch chuẩn ≈ 47 so với 35). Điều này có thể do sinh viên học lại chủ động đăng ký thêm học phần để bù lại tiến độ của kỳ trước, hoặc do nhóm này quyết tâm hoàn thành chương trình cao hơn sau lần học chưa đạt.



Hình 2.14: Biểu đồ hộp: `studied_credits` theo nhóm học lần đầu / học lại.

Thống kê mô tả chi tiết của số tín chỉ theo hai nhóm được trình bày ở Bảng 2.8.


Bảng 2.8: Thống kê mô tả số tín chỉ (`studied_credits`) theo nhóm học lần đầu / học lại.

Nhóm	N	Trung bình	Độ lệch chuẩn	Min	Q1	Trung vị	Q3	Max
Học lần đầu	17,283	77.76	35.00	30.00	60.00	60.00	90.00	630.00
Học lại	2,705	98.92	47.41	30.00	60.00	90.00	120.00	360.00

2.5.4 Phân tích theo nhãn mục tiêu

Đặc điểm ba nhóm kết quả

Giá trị trung bình của các đặc trưng tính theo từng nhóm kết quả được chuẩn hoá và biểu diễn bằng biểu đồ radar (Hình 2.15). Từ biểu đồ, có thể nhận thấy ba nhóm mang ba đặc điểm rủi ro khác biệt:



Hình 2.15: Biểu đồ radar các đặc trưng tính theo nhóm kết quả.

Giá trị trung bình của từng đặc trưng theo nhóm kết quả — số liệu gốc của biểu đồ radar — được trình bày ở Bảng 2.9.

Bảng 2.9: Giá trị trung bình các đặc trưng tính theo nhóm kết quả.

Nhóm	Tỷ lệ học lại	Số tín chỉ TB	Số lần học trước TB	Tỷ lệ khuyết tật	Tỷ lệ tuổi ≤ 35
Pass	9.7%	78.23	0.12	7.4%	67.7%
Fail	20.5%	80.98	0.27	9.5%	75.4%
Withdrawn	15.5%	87.02	0.19	13.6%	71.4%


- **Pass** là nhóm an toàn nhất: đa giác của nhóm này nhỏ nhất, tức các chỉ số rủi ro đều ở mức thấp. Phần lớn sinh viên học lần đầu với khối lượng đăng ký vừa phải, tỷ lệ khuyết tật thấp nhất; tỷ lệ sinh viên trẻ cũng thấp nhất, cho thấy nhóm lớn tuổi có xu hướng hoàn thành học phần tốt hơn.
- **Fail** nổi bật ở các đặc trưng về lịch sử học tập: số lần học trước và tỷ lệ học lại đều cao nhất, tỷ lệ sinh viên trẻ cũng cao nhất. Trong khi đó, khối lượng tín chỉ không cao hơn Pass đáng kể — vấn đề của nhóm này nằm ở việc học lại nhiều lần mà kết quả chưa cải thiện, chứ không phải do học quá tải.
- **Withdrawn** có xu hướng ngược lại: khối lượng tín chỉ và tỷ lệ khuyết tật

cao nhất, trong khi các chỉ số học lại chỉ ở mức trung bình. Nguyên nhân bỏ học vì vậy thiên về quá tải học tập và các trở ngại cá nhân hoặc sức khỏe.

Như vậy, Fail và Withdrawn đại diện cho hai dạng rủi ro khác nhau: Fail gắn với lịch sử học lại và nhóm sinh viên trẻ, còn Withdrawn gắn với khối lượng đăng ký và tình trạng khuyết tật.

Kết quả theo trình độ học vấn

Hình 2.16 thể hiện tỷ lệ Pass / Fail / Withdrawn theo từng bậc học vấn khi nhập học.



Hình 2.16: Tỷ lệ kết quả học tập theo trình độ học vấn.


- **Pass** tăng liên tục theo trình độ học vấn: từ 38.3% (*No Formal quals*) lên 73.1% (*Post Graduate Qualification*).
- **Fail** giảm theo chiều ngược lại: từ 34.9% xuống còn 11.5% — sinh viên có nền tảng học vấn cao hơn ít trượt môn hơn.
- **Withdrawn** cũng giảm nhưng chậm hơn Fail.

Đáng chú ý, *No Formal quals* là nhóm rủi ro cao nhất: tỷ lệ Pass chỉ đạt 38.3%, trong khi Fail và Withdrawn cộng lại chiếm tới **61.7%** — đây là nhóm duy nhất có tỷ lệ không hoàn thành vượt quá tỷ lệ hoàn thành. *Post Graduate Qualification* là nhóm duy nhất có tỷ lệ Withdrawn (15.4%) cao hơn Fail (11.5%): sinh viên sau đại học ít trượt môn nhưng lại có xu hướng rút lui nhiều hơn, có thể vì lý do cá nhân hoặc công việc. Khoảng cách giữa Pass và hai nhóm còn lại

mở rộng rõ rệt từ *A Level or Equivalent* trở lên, cho thấy đây có thể là ngưỡng mà nền tảng học vấn bắt đầu tạo ra lợi thế rõ ràng.

Kết quả theo chỉ số thiếu thốn kinh tế

Hình 2.17 thể hiện tỷ lệ Pass / Fail / Withdrawn theo từng nhóm IMD.



Hình 2.17: Tỷ lệ kết quả học tập theo nhóm imd_band.

- **Pass** tăng đều từ 43.4% (0–10%) lên 65.3% (90–100%) — sinh viên từ khu vực khá giả hơn có tỷ lệ hoàn thành cao hơn.
- **Fail** giảm từ 33.8% xuống 18.5% — nghịch biến với mức độ kinh tế, giảm tương đối đều.
- **Withdrawn** giảm nhẹ và không đều, dao động 18–23% ở các band giữa.

Đáng chú ý, mối liên hệ giữa tỷ lệ Pass và IMD **yếu hơn** rõ rệt so với mối liên hệ giữa Pass và trình độ học vấn ở mục trước: tỷ lệ Pass tăng theo học vấn với biên độ lớn hơn (38.3% → 73.1%) so với theo IMD (43.4% → 65.3%). Điều này gợi ý **nền tảng học vấn ảnh hưởng đến kết quả học tập nhiều hơn điều kiện kinh tế**. Ngoài ra, tỷ lệ Withdrawn gần như không thay đổi theo IMD, và nhóm '?' có tỷ lệ Pass cao bất thường (71.6% — cao nhất trong tất cả các nhóm).

2.6 Phân tích khám phá các đặc trưng động

Các đặc trưng động được tính trong khoảng thời gian $[0, T]$ tại mỗi mốc dự đoán, phản ánh mức độ tương tác VLE và kết quả bài kiểm tra tích lũy đến thời

điểm đó. Bảy đặc trưng động gồm: `total_clicks`, `active_weeks`, `avg_weekly_clicks`, `num_submitted`, `avg_score`, `num_failed` và `avg_days_early`.

2.6.1 Thống kê mô tả

Thống kê mô tả của bảy đặc trưng động được trình bày ở Bảng 2.10.


Bảng 2.10: Thống kê mô tả các đặc trưng động (tính trên tập huấn luyện).

Đặc trưng	N	Trung bình	Độ lệch chuẩn	Min	Q1	Trung vị	Q3	Max
<code>total_clicks</code>	139,934	1,072.27	1,358.44	1.00	269.00	617.00	1,334.00	23,115.00
<code>active_weeks</code>	139,934	15.65	9.21	1.00	8.00	14.00	22.00	39.00
<code>avg_weekly_clicks</code>	139,934	60.74	56.40	1.00	25.44	44.09	76.92	1,070.50
<code>num_submitted</code>	129,388	3.81	2.68	1.00	2.00	3.00	5.00	14.00
<code>avg_score</code>	127,544	73.54	15.51	0.00	64.73	76.00	85.00	100.00
<code>num_failed</code>	129,388	0.16	0.49	0.00	0.00	0.00	0.00	8.00
<code>avg_days_early</code>	129,388	0.94	8.10	-123.00	-1.50	0.00	1.50	236.00

- Các đặc trưng VLE lệch phải mạnh: `total_clicks` có độ lệch chuẩn (1,358) lớn hơn cả giá trị trung bình (1,072), giá trị lớn nhất lên tới 23,115; `avg_weekly_clicks` cũng tương tự (trung bình 60.7 nhưng giá trị lớn nhất 1,070.5).
- `num_failed` có giá trị nhỏ nhất, trung vị và Q_3 đều bằng 0 — phần lớn sinh viên không trượt bài nào trong khoảng thời gian quan sát. Trung bình chỉ đạt 0.16 nhưng giá trị lớn nhất lên tới 8, tức vẫn có một nhóm nhỏ trượt nhiều bài.
- `avg_days_early` trải trên khoảng giá trị rất rộng: từ -123 (nộp trễ 123 ngày) đến 236 (nộp sớm 236 ngày). Trung vị bằng 0, với $Q_1 = -1.5$ và $Q_3 = 1.5$: khoảng một nửa số sinh viên nộp bài trong vòng ± 1.5 ngày quanh hạn nộp.
- `avg_score` tương đối tập trung: $Q_1 = 64.7$ và $Q_3 = 85$ — phần lớn sinh viên đạt điểm trung bình ở mức khá trở lên.

2.6.2 Số sinh viên còn học theo thời gian

Hình 2.18 thể hiện số sinh viên còn hoạt động tại mỗi mốc dự đoán.




Hình 2.18: Số sinh viên còn hoạt động theo mốc dự đoán (mỗi 30 ngày).

- Số sinh viên còn hoạt động giảm đều qua các mốc: từ **17,921** (ngày 30) xuống **15,171** (ngày 240) — tổng cộng **2,750 sinh viên** ($\approx 15.3\%$) rút khỏi khoá học trong 210 ngày quan sát.
- Mức giảm lớn nhất rơi vào giai đoạn đầu (ngày 30 $\rightarrow$ ngày 60: -629), sau đó chậm dần và ổn định hơn về cuối khoá (ngày 180 $\rightarrow$ ngày 210: -214 ; ngày 210 $\rightarrow$ ngày 240: -208 — chỉ bằng khoảng $1/3$ giai đoạn đầu).
- Trung bình mỗi 30 ngày có ≈ 393 sinh viên rời khoá học; tuy nhiên con số trung bình này chưa phản ánh đúng thực tế, vì phần lớn trường hợp rút lui tập trung ở giai đoạn đầu khoá.

2.6.3 Phân tích tương quan

Ma trận tương quan giữa các đặc trưng động được thể hiện ở Hình 2.19.




Hình 2.19: Ma trận tương quan giữa các đặc trưng động.

- **Cụm hoạt động trực tuyến** (`total_clicks`, `active_weeks`, `avg_weekly_clicks`) tương quan chặt với nhau; đặc biệt `total_clicks` và `avg_weekly_clicks` gần như đo lường cùng một khía cạnh — đưa cả hai vào mô hình có thể gây **đa cộng tuyến** (multicollinearity). `active_weeks` có tương quan khá cao với `num_submitted`, nhưng số click mỗi tuần lại gần như không liên quan đến số bài nộp — cho thấy lượng click không phải lúc nào cũng phản ánh việc học có mục đích.
- **Cặp nghịch chiều rõ nhất** là `avg_score` và `num_failed`: điểm trung bình cao đi kèm số bài trượt thấp, do đó có thể cân nhắc chỉ giữ lại một trong hai đặc trưng.
- `avg_days_early` tương quan thấp với hầu hết các đặc trưng còn lại — đây là một tín hiệu tương đối độc lập, phản ánh thói quen quản lý thời gian của sinh viên.
- `num_failed` gần như không tương quan với các đặc trưng hoạt động — tương

tác nhiều hay học đều đặn không bảo đảm tránh được điểm kém; kết quả còn phụ thuộc vào chất lượng của việc học.

Quan hệ giữa `avg_score` và `num_failed` được thể hiện rõ hơn qua biểu đồ bong bóng ở Hình 2.20.




Hình 2.20: Biểu đồ bong bóng: `avg_score` theo `num_failed`.

Phần lớn sinh viên không trượt bài nào (`num_failed` = 0) và có `avg_score` tập trung ở mức cao, rõ nhất trong vùng 80–100 điểm. Khi số bài trượt tăng, số sinh viên giảm dần và điểm trung bình phân tán hơn. Tuy nhiên, ở các mức `num_failed` thấp (1–5) vẫn có những sinh viên đạt điểm khá cao. Đây là lý do hai đặc trưng này không thể thay thế cho nhau: `num_failed` nắm bắt được một dạng rủi ro mà điểm trung bình bỏ sót — sinh viên học ổn định nhưng bỏ hoặc trượt một vài bài, có thể do thiếu chuyên cần hoặc do hoàn cảnh cá nhân.

2.6.4 Đặc trưng động theo nhãn mục tiêu

Biểu đồ radar các đặc trưng động theo nhóm kết quả (Hình 2.21) làm rõ hơn sự khác biệt giữa các nhóm.



Hình 2.21: Biểu đồ radar các đặc trưng động theo nhóm kết quả.

Giá trị trung bình các đặc trưng động theo nhóm kết quả được trình bày ở Bảng 2.11.


Bảng 2.11: Giá trị trung bình các đặc trưng động theo nhóm kết quả.

Nhóm	total_clicks	active_weeks	avg_weekly_clicks	num_submitted	avg_score	num_failed	avg_days_early
Pass	1,377.99	18.48	70.24	4.27	78.21	0.09	1.59
Fail	548.59	11.06	42.49	3.08	63.48	0.33	-0.19
Withdrawn	542.78	9.93	50.11	2.29	65.47	0.27	-0.91

- **Pass** chiếm diện tích lớn nhất, vượt trội ở cả ba đặc trưng tương tác VLE (`active_weeks`, `total_clicks`, `avg_weekly_clicks`) lẫn số bài nộp. Đây là nhóm duy nhất vừa duy trì mức độ tham gia cao, vừa đạt kết quả bài đánh giá tốt.
- **Fail** nổi bật nhất ở số bài trượt (`num_failed`), cao hơn cả hai nhóm còn lại, trong khi số bài nộp tương đương nhóm Pass. Như vậy, sinh viên Fail vẫn nộp bài đầy đủ nhưng kết quả không đạt yêu cầu — dấu hiệu của khó khăn học tập kéo dài.

- **Withdrawn** thì ngược lại: số bài nộp thấp nhất trong ba nhóm, còn số bài trượt gần như bằng 0. Điều này không có nghĩa là họ làm bài tốt — họ nộp quá ít bài nên hầu như không có bài nào bị tính trượt. Đáng chú ý, những bài đã nộp vẫn đạt điểm ở mức trung bình khá, cho thấy nhóm này bỏ học không hẳn vì học kém, mà nhiều khả năng do mất dần sự gắn kết với khoá học.

Cuối cùng, xét `avg_days_early` theo nhóm kết quả (Hình 2.22): Pass là nhóm duy nhất có giá trị dương (+1.59 ngày, tức nộp trước hạn), thể hiện thái độ học tập chủ động. Hai nhóm còn lại đều mang giá trị âm, trong đó Withdrawn nộp trễ nhiều nhất (−0.91 ngày, gấp gần 5 lần mức −0.19 ngày của Fail) — phù hợp với xu hướng giảm dần sự gắn kết đã ghi nhận ở trên. Tuy vậy, mức chênh lệch giữa ba nhóm đều nhỏ (dưới 2 ngày), nên khi đứng một mình, `avg_days_early` có thể chưa đủ mạnh để phân biệt các nhóm.



Hình 2.22: Giá trị trung bình `avg_days_early` theo nhóm kết quả.

2.7 Xác nhận sự phù hợp của các thuật toán học máy

Từ quá trình phân tích khám phá dữ liệu, có thể rút ra một số đặc điểm của dữ liệu ảnh hưởng trực tiếp đến việc lựa chọn thuật toán — đối chiếu với bốn thuật toán đã trình bày cơ sở lý thuyết ở Chương 1:

- Bài toán ở dạng **phân loại nhị phân và mất cân bằng nhãn**: gộp hai

nhóm Fail và Withdrawn thành nhóm **có nguy cơ** (At-risk), nhóm Pass còn lại; nhóm có nguy cơ chiếm tỷ lệ nhỏ hơn.

- Dữ liệu gồm **nhiều kiểu đặc trưng**: vừa có biến phân loại (khu vực, trình độ học vấn, `imd_band...`) vừa có biến số (số click, điểm trung bình, số bài nộp...).
- Giữa các đặc trưng tồn tại **quan hệ phi tuyến và tương tác**, đồng thời một số nhóm đặc trưng có **đa cộng tuyến** (cụm hoạt động trực tuyến).
- Nhiều đặc trưng **lệch phải mạnh**, có giá trị ngoại lai và tồn tại giá trị thiếu.

Dựa trên các đặc điểm này, bốn thuật toán đã trình bày cơ sở lý thuyết ở Chương 1 — **Logistic Regression**, **Random Forest**, **CatBoost** và **LightGBM** — đều phù hợp để đưa vào thử nghiệm trong nghiên cứu. Kết quả huấn luyện và so sánh thực nghiệm trên chính dữ liệu này được trình bày ở Chương 3.

Chương 3

Xây dựng và so sánh mô hình

3.1 Tiền xử lý dữ liệu

Kế thừa cơ sở lý thuyết bốn thuật toán ở Chương 1 và kết quả phân tích khám phá dữ liệu ở Chương 2, phần này trình bày quá trình xây dựng và so sánh mô hình học máy cho bài toán cảnh báo sớm rủi ro học tập. Bài toán được xác định lại ở dạng **phân loại nhị phân**: nhận diện sinh viên **có nguy cơ** (At-risk) — gộp từ hai nhóm kết quả trượt môn (Fail) và bỏ học (Withdrawn) — so với nhóm **hoàn thành** (Pass), dựa trên đặc trưng nhân khẩu học và hành vi học tập tích lũy đến một mốc thời gian xác định trong khoá học.

3.1.1 Điền giá trị thiếu ở đặc trưng động

Các đặc trưng phản ánh hành vi học tập tích lũy (tương tác với hệ thống học trực tuyến và kết quả bài đánh giá) có giá trị thiếu ở những sinh viên chưa từng tương tác hoặc chưa nộp bài nào tính đến mốc thời gian quan sát. Quy tắc điền khuyết được áp dụng riêng cho từng nhóm đặc trưng:

- **Đặc trưng tương tác VLE** (`total_clicks`, `active_weeks`, `avg_weekly_clicks`) và **đặc trưng bài đánh giá** (`num_submitted`, `num_failed`) — điền bằng 0, vì giá trị thiếu ở đây đồng nghĩa với việc sinh viên chưa phát sinh hoạt động nào.
- `avg_score` — điền bằng giá trị **-1** (nằm ngoài thang điểm $[0, 100]$) để phân biệt rõ ràng với trường hợp sinh viên nộp bài và bị điểm 0.

- `avg_days_early` — điền bằng 0; thông tin về việc sinh viên không nộp bài dù đã đến hạn đã được nắm bắt riêng bởi đặc trưng nhị phân `no_submission_despite_due`, nên việc điền 0 ở đây không gây nhầm lẫn.

Sau bước điền khuyết, toàn bộ đặc trưng động không còn giá trị thiếu.

3.1.2 Xử lý giá trị thiếu ở `imd_band`

Như đã trình bày ở Mục 2.5.1 (Chương 2), biến `imd_band` (chỉ số thiếu thôn kinh tế theo khu vực) có một dạng thiếu riêng biệt, được mã hoá bằng ký hiệu '?' thay vì giá trị rỗng thông thường. Trước khi điền khuyết, cơ chế thiếu được kiểm định thống kê để lựa chọn phương án xử lý phù hợp:

- Kiểm định **Mann–Whitney U** với các biến số (`num_of_prev_attempts`, `studied_credits`) đều cho $p < 0.05$ — bác bỏ giả thuyết thiếu hoàn toàn ngẫu nhiên (MCAR).
- Kiểm định **Chi-square** với các biến phân loại (`region`, `gender`, `highest_education`, `disability`, `final_result`, `code_module`) đều cho $p < 0.05$, trong đó `region` có hệ số Cramér's V cao nhất ($V = 0.577$) — xác nhận cơ chế **thiếu ngẫu nhiên có điều kiện** (MAR), phụ thuộc mạnh vào vùng địa lý.

Với kết luận MAR, giá trị thiếu được điền theo **phân phối riêng của từng vùng** (ước lượng trên tập huấn luyện), đồng thời một biến chỉ báo `imd_missing` được tạo thêm để mô hình có thể tận dụng chính tín hiệu “thiếu dữ liệu” như một đặc trưng dự báo. Sau bước xử lý, biến `imd_band_filled` không còn giá trị thiếu ở cả hai tập huấn luyện và kiểm tra.

3.1.3 Mã hoá đặc trưng phân loại

Các đặc trưng phân loại được mã hoá theo bản chất của từng biến, tóm tắt ở Bảng 3.1.

Bảng 3.1: Phương án mã hoá các đặc trưng phân loại.

Đặc trưng	Kiểu mã hoá	Lý do
<code>disability</code>	Nhị phân	$Y \rightarrow 1, N \rightarrow 0$
<code>highest_education</code>	Thứ tự (ordinal)	Có thứ bậc học vấn rõ ràng
<code>imd_band_filled</code>	Thứ tự (ordinal)	Có thứ bậc mức độ nghèo

Ba đặc trưng nhân khẩu học còn lại từ dữ liệu gốc — `gender`, `region`, `age_band` — không được đưa vào ma trận đặc trưng huấn luyện. Các đặc trưng nhân khẩu học được giữ lại (`highest_education`, `disability`, `imd_band_filled`) là những đặc trưng đã cho thấy liên hệ rõ ràng với kết quả học tập ở Chương 2.

3.1.4 Tập đặc trưng cuối cùng

Sau các bước xử lý trên, ma trận đặc trưng dùng cho huấn luyện mô hình gồm **15 đặc trưng**:

- **Tĩnh (5):** `highest_education`, `disability`, `num_of_prev_attempts`, `studied_credits`, `imd_band_filled`, cùng biến chỉ báo `imd_missing`.
- **Động (9):** `total_clicks_filled`, `active_weeks_filled`, `avg_weekly_clicks_filled`, `num_due`, `num_submitted_filled`, `avg_score_filled`, `num_failed_filled`, `avg_days_early_filled`, `no_submission_despite_due`.

Việc chia tập huấn luyện và kiểm tra được giữ nguyên theo **từng sinh viên** như đã thiết lập ở Bảng 2.5 (Chương 2, tỷ lệ 80:20), đảm bảo không xảy ra rò rỉ dữ liệu giữa hai tập.

3.1.5 Chuẩn hoá bài toán về phân loại nhị phân

Với mục tiêu cảnh báo sớm, ranh giới quan trọng nhất không nằm giữa Fail và Withdrawn, mà giữa nhóm **hoàn thành** và nhóm **không hoàn thành** học phần. Do đó, nhãn mục tiêu được chuẩn hoá lại:

$$\text{At-risk (1)} = \text{Fail} \cup \text{Withdrawn}, \quad \text{Pass (0)} = \text{Pass}.$$

Phép gộp nhãn này được áp dụng thống nhất cho toàn bộ dữ liệu dạng panel, tức trên mọi bản ghi ở cả tám mốc dự đoán $T \in \{30, 60, \dots, 240\}$ đã thiết kế ở Mục 2.4.1 (Chương 2) — không giới hạn ở một mốc thời gian cụ thể nào. Với dữ liệu đã ở dạng nhị phân, câu hỏi tiếp theo là mốc dự đoán nào nên được chọn để huấn luyện và đánh giá mô hình; đây là nội dung được khảo sát ở phần kế tiếp.

3.2 Khảo sát sơ bộ theo các mốc dự đoán

Trước khi đi sâu so sánh nhiều thuật toán tại một mốc thời gian cố định, cần khảo sát sơ bộ hiệu suất mô hình học máy **xuyên suốt toàn bộ các mốc dự đoán** đã thiết kế ở Mục 2.4.1 (Chương 2), nhằm hai mục đích: (i) hiểu xu hướng biến động hiệu suất theo thời gian khi sinh viên tích lũy ngày càng nhiều hành vi học tập, và (ii) làm cơ sở lựa chọn một mốc thời gian đại diện, phù hợp cho các thử nghiệm chuyên sâu ở phần sau.

3.2.1 Thiết lập thử nghiệm

Với mỗi mốc dự đoán T , một mô hình **Logistic Regression** được huấn luyện riêng, chỉ sử dụng dữ liệu của đúng mốc đó — đây cũng là thuật toán cơ sở, đơn giản và dễ diễn giải nhất trong bốn thuật toán đã trình bày cơ sở lý thuyết ở Chương 1, phù hợp để khảo sát nhanh xu hướng hiệu suất theo thời gian trước khi mở rộng sang các mô hình phức tạp hơn. Quy trình tinh chỉnh áp dụng cho từng mô hình tương tự cách tiếp cận sẽ được dùng ở giai đoạn so sánh nhiều thuật toán tại Mục 3.3: dữ liệu được chuẩn hoá bằng **StandardScaler** (fit trên train-fold, tránh rò rỉ dữ liệu), siêu tham số điều chuẩn C của mô hình (Mục 1.2.3), tỷ lệ oversampling SMOTE và trọng số lớp At-risk được tinh chỉnh đồng thời bằng Optuna (30 lượt thử nghiệm, kiểm định chéo phân tầng 3-fold), sau đó huấn luyện lại trên toàn bộ tập huấn luyện của mốc đó và đánh giá trên tập kiểm tra giữ nguyên.

Một lưu ý về mặt phương pháp: ở lần thử đầu tiên, hàm mục tiêu tối ưu là *recall thuần* của lớp At-risk, nhưng cách làm này khiến mô hình suy biến về việc dự đoán **toàn bộ** sinh viên đều là At-risk (recall đạt gần tuyệt đối nhưng precision rất thấp, không có giá trị thực tiễn). Hàm mục tiêu sau đó được đổi sang **F1-score của lớp At-risk** để buộc mô hình cân bằng giữa precision và recall — đây là hàm mục tiêu được giữ nguyên xuyên suốt các thử nghiệm còn lại của báo cáo.


3.2.2 Kết quả theo thời gian

Bảng 3.2 tổng hợp hiệu suất trên tập kiểm tra của tám mô hình, mỗi mô hình ứng với một mốc dự đoán.

Bảng 3.2: Kết quả sơ bộ của mô hình Logistic Regression — một mô hình riêng cho mỗi mốc dự đoán T — trên tập kiểm tra. Precision/Recall/F1 tính riêng cho lớp At-risk.

T (ngày)	Train	Test	Accuracy	Precision	Recall	F1
30	19,988	5,043	0.6488	0.5750	0.8013	0.6695
60	19,123	4,835	0.7231	0.6429	0.7666	0.6993
90	18,508	4,680	0.7402	0.6442	0.7857	0.7080
120	17,917	4,518	0.7915	0.7123	0.7555	0.7333
150	17,386	4,363	0.8263	0.7524	0.7659	0.7591
180	16,786	4,215	0.8451	0.7533	0.7987	0.7754
210	16,486	4,162	0.8659	0.7976	0.7894	0.7935
240	16,190	4,094	0.8796	0.8269	0.7814	0.8035

Hình 3.1 trực quan hoá xu hướng của bốn chỉ số theo mốc thời gian.




Hình 3.1: Xu hướng hiệu suất mô hình theo từng mốc dự đoán (mỗi mốc một mô hình riêng).

- **Accuracy** và **precision At-risk** tăng **đơn điệu tuyệt đối** theo thời gian — không có mốc nào sụt giảm so với mốc liền trước (accuracy từ 0.6488 ở $T = 30$ lên 0.8796 ở $T = 240$; precision từ 0.5750 lên 0.8269) — phù hợp với trực giác: sinh viên càng tích lũy nhiều hành vi học tập, tín hiệu dự báo càng rõ ràng và đáng tin cậy hơn.
- **Recall At-risk** lại dao động trong một biên độ hẹp (0.7555–0.8013) mà không theo xu hướng rõ ràng, thậm chí đạt giá trị cao nhất ngay ở mốc sớm nhất

$T = 30$ (0.8013) — khi độ chính xác tổng thể còn rất thấp (accuracy 0.6488, precision 0.5750). Điều này cho thấy ở giai đoạn đầu khoá, khi tín hiệu hành vi còn thừa thớt, ranh giới tuyến tính của Logistic Regression có xu hướng dự báo At-risk khá rộng rãi — bắt được phần lớn sinh viên có nguy cơ nhưng đánh đổi bằng rất nhiều cảnh báo nhầm.

- **F1 At-risk** — chỉ số tổng hợp được dùng làm mục tiêu tối ưu — vì vậy cũng tăng đơn điệu tuyệt đối theo thời gian, từ 0.6695 ($T = 30$) lên 0.8035 ($T = 240$), nhưng động lực tăng chủ yếu đến từ **precision** chứ không phải recall, vốn gần như đi ngang xuyên suốt khoá học.

Mã trận nhầm lẫn của cả tám mô hình được thể hiện ở Hình 3.2.



Hình 3.2: Ma trận nhầm lẫn trên tập kiểm tra tại từng mốc dự đoán.

Bảng 3.3 cho thấy siêu tham số xử lý mất cân bằng nhãn mà Optuna lựa chọn theo từng mốc thời gian.

Bảng 3.3: Siêu tham số xử lý mất cân bằng nhãn được Optuna lựa chọn cho từng mốc dự đoán, cùng F1 At-risk trung bình qua 3-fold cross-validation.

T (ngày)	F1 At-risk (CV)	Tỷ lệ SMOTE	Trọng số At-risk
30	0.6734	+0.67x	1.12
60	0.7065	+0.56x	1.24
90	0.7160	+0.57x	1.33
120	0.7486	+0.69x	1.01
150	0.7767	+0.55x	1.05
180	0.7918	+0.90x	1.01
210	0.8047	+0.51x	1.03
240	0.8182	+0.42x	1.01

Trọng số At-risk tối ưu hầu như luôn hội tụ gần giá trị 1 (1.01–1.33) ở mọi mốc thời gian, trong khi tỷ lệ SMOTE dao động ở mức khá cao và không theo xu hướng rõ rệt (0.42–0.90x). Nói cách khác, với Logistic Regression, việc bổ sung mẫu tổng hợp qua SMOTE đóng vai trò chủ đạo trong xử lý mất cân bằng nhãn, hơn là điều chỉnh trọng số lớp — đây là đặc điểm nhất quán của thuật toán này, cũng sẽ được quan sát lại khi so sánh với ba thuật toán còn lại ở Bảng 3.9.

3.2.3 Lựa chọn mốc dự đoán cho phân tích chuyên sâu

Kết quả khảo sát cho thấy một sự đánh đổi rõ ràng giữa **độ tin cậy của dự báo** và **thời gian còn lại để can thiệp**: các mốc càng muộn cho hiệu suất càng cao, nhưng đồng thời càng gần thời điểm kết thúc khoá học, làm giảm giá trị thực tiễn của một cảnh báo sớm. Với khoá học OULAD kéo dài khoảng 240–270 ngày, hai mốc cho F1 cao nhất ($T = 210$ và $T = 240$, lần lượt 0.7935 và 0.8035) chỉ còn lại khoảng 10–20% thời lượng khoá học — quá muộn để nhà trường triển khai các biện pháp hỗ trợ có ý nghĩa.

Mốc $T = 180$ **ngày** được chọn làm đại diện cho các thử nghiệm chuyên sâu ở phần còn lại của báo cáo, vì đạt được điểm cân bằng hợp lý nhất: hiệu suất đã ở mức khá cao (accuracy 0.8451, F1 At-risk 0.7754 — chỉ thấp hơn khoảng 0.02 so với mốc $T = 210$ liền sau), trong khi vẫn còn khoảng 60–90 ngày (25–35% thời lượng khoá học) để nhà trường can thiệp trước khi khoá học kết thúc.

Bảng 3.4 tóm tắt quy mô và phân phối nhãn tại mốc $T = 180$ sau khi gộp nhãn, được dùng thống nhất cho toàn bộ các thử nghiệm từ Mục 3.3 trở đi.

Bảng 3.4: Quy mô và phân phối nhãn nhị phân tại mốc dự đoán $T = 180$, sau khi gộp Fail và Withdrawn thành At-risk.

	Tập	Pass	At-risk	Tổng
	Train	11,067 (65.9%)	5,719 (34.1%)	16,786
	Test	2,804 (66.5%)	1,411 (33.5%)	4,215

Tỷ lệ At-risk chiếm khoảng **1/3** tổng số sinh viên ở cả hai tập, tương đồng giữa train và test — xác nhận việc chia dữ liệu theo sinh viên không gây lệch phân phối nhãn. Đây vẫn là một bài toán **mất cân bằng nhãn vừa phải**, cần được xử lý ở bước huấn luyện mô hình.

3.3 Phương pháp xây dựng mô hình

Kế thừa kết luận ở Mục 3.2.3, các thử nghiệm từ đây trở đi tập trung vào mốc $T = 180$, mở rộng từ một mô hình cơ sở duy nhất (đã dùng để khảo sát xu hướng theo thời gian ở Mục 3.2) sang so sánh trực tiếp **bốn thuật toán học máy** khác nhau.

3.3.1 Các thuật toán sử dụng

Bốn thuật toán đã trình bày cơ sở lý thuyết ở Chương 1 — Logistic Regression, Random Forest, CatBoost và LightGBM — được đưa vào huấn luyện và so sánh trực tiếp trên dữ liệu thực tế. Thuật toán **SVM (kernel RBF)** được loại khỏi phạm vi thử nghiệm do độ phức tạp huấn luyện tăng theo bậc hai với số lượng mẫu, không khả thi với quy mô dữ liệu ở mốc $T = 180$ (hơn 16 nghìn bản ghi huấn luyện) trong khuôn khổ tài nguyên tính toán của nghiên cứu.

3.3.2 Xử lý mất cân bằng nhãn

Hai kỹ thuật được kết hợp đồng thời để xử lý mất cân bằng nhãn:

- **SMOTE** (Synthetic Minority Over-sampling Technique): sinh thêm mẫu tổng hợp cho lớp At-risk, với tỷ lệ oversampling là một siêu tham số được tinh chỉnh riêng cho từng mô hình.
- **Trọng số lớp** (`class_weight`): tăng chi phí phân loại sai đối với lớp At-risk trong hàm mất mát của mô hình, cũng được tinh chỉnh như một siêu tham

số — tương ứng về mặt toán học với hàm mất mát có trọng số đã trình bày ở Mục 1.2.4 (Chương 1) cho riêng trường hợp Logistic Regression.

Để tránh rò rỉ dữ liệu, **SMOTE chỉ được áp dụng trên từng fold huấn luyện** trong quá trình kiểm định chéo, không áp dụng lên fold kiểm định. Tương tự, với Logistic Regression — mô hình duy nhất cần chuẩn hoá dữ liệu số (**StandardScaler**) — bước chuẩn hoá cũng chỉ được ước lượng (fit) trên fold huấn luyện.

3.3.3 Thiết lập thực nghiệm

Với mỗi mô hình, siêu tham số của thuật toán được tinh chỉnh **đồng thời** với tỷ lệ SMOTE và trọng số lớp At-risk, thông qua khung tối ưu Bayesian **Optuna** (thuật toán lấy mẫu TPE), với 30 lượt thử nghiệm cho mỗi mô hình. Hàm mục tiêu được tối ưu là **F1-score của lớp At-risk**, đánh giá qua kiểm định chéo phân tầng 3-fold (**StratifiedKFold**) nhằm giữ nguyên tỷ lệ lớp ở mỗi fold. Sau khi xác định bộ siêu tham số tốt nhất, mô hình được huấn luyện lại trên toàn bộ tập huấn luyện và đánh giá lần cuối trên tập kiểm tra giữ nguyên (holdout), độc lập hoàn toàn với quá trình tinh chỉnh.

Các chỉ số đánh giá trên tập kiểm tra gồm: accuracy, precision, recall, F1 (tính riêng cho lớp At-risk) và ROC-AUC.

3.4 Kết quả trên bộ đặc trưng đầy đủ

Bảng 3.5 tổng hợp hiệu suất của bốn mô hình trên tập kiểm tra, sử dụng đầy đủ 15 đặc trưng.

Bảng 3.5: So sánh các mô hình trên bộ 15 đặc trưng đầy đủ (T=180). Chỉ số Precision/Recall/F1 tính riêng cho lớp **At-risk**.


Model	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.8451	0.7533	0.7987	0.7754	0.9163
Random Forest	0.8681	0.8251	0.7690	0.7960	0.9248
CatBoost	0.8728	0.8464	0.7576	0.7996	0.9304
LightGBM	0.8686	0.8076	0.7973	0.8024	0.9292

- **CatBoost** đạt accuracy (0.8728) và precision At-risk (0.8464) cao nhất, đồng thời có ROC-AUC cao nhất (0.9304) — mô hình phân biệt tốt nhất giữa hai

lớp trên toàn dải ngưỡng.

- **LightGBM** đạt F1 At-risk cao nhất (0.8024), nhờ cân bằng tốt giữa precision (0.8076) và recall (0.7973) — ít bỏ sót sinh viên có nguy cơ hơn CatBoost (recall 0.7576) trong khi độ chính xác dự báo vẫn ở mức cao.
- **Random Forest** cho kết quả khá tương đồng với hai mô hình boosting, nhưng không vượt trội ở bất kỳ chỉ số nào.
- **Logistic Regression** có hiệu suất thấp nhất ở mọi chỉ số, phù hợp với kỳ vọng đặt ra từ Chương 1 và Chương 2: dữ liệu tồn tại quan hệ phi tuyến và đa cộng tuyến giữa các đặc trưng hành vi trực tuyến, là những đặc điểm mà mô hình tuyến tính khó nắm bắt đầy đủ.

Ma trận nhầm lẫn (confusion matrix) của từng mô hình trên tập kiểm tra được thể hiện ở Hình 3.3.




Hình 3.3: Ma trận nhầm lẫn trên tập kiểm tra — bộ đặc trưng đầy đủ ($T=180$).

Nhìn chung, phần lớn sai số của cả bốn mô hình đều nằm ở việc **bỏ sót sinh viên At-risk** (dự báo Pass trong khi thực tế At-risk) nhiều hơn là cảnh báo nhầm (dự báo At-risk trong khi thực tế Pass). Đây là điểm cần lưu ý khi triển khai thực tế: có thể cân nhắc hạ ngưỡng phân loại để tăng recall, chấp nhận đánh đổi thêm một số cảnh báo nhầm nhằm giảm thiểu rủi ro bỏ sót sinh viên cần hỗ trợ.

3.5 Độ quan trọng của đặc trưng

Hình 3.4 thể hiện độ quan trọng đặc trưng theo định nghĩa riêng của từng thuật toán (hệ số hồi quy tuyệt đối với Logistic Regression, độ giảm tạp chất Gini với Random Forest — theo công thức ở Mục 1.3.4 — PredictionValuesChange với CatBoost, và số lần được dùng để phân tách với LightGBM) — các giá trị này **không cùng đơn vị** nên chỉ so sánh được thứ hạng, không so sánh trực tiếp độ lớn giữa các mô hình.



Hình 3.4: Độ quan trọng đặc trưng (theo định nghĩa riêng của từng mô hình) tại T=180.

Để tổng hợp một thứ hạng chung, mỗi đặc trưng được xếp hạng riêng trong từng mô hình rồi lấy trung bình cộng bốn hạng. Bảng 3.6 trình bày kết quả, sắp xếp tăng dần theo hạng trung bình.

Bảng 3.6: Thứ hạng độ quan trọng của từng đặc trưng theo mỗi mô hình (1 = quan trọng nhất) và hạng trung bình, sắp xếp tăng dần theo hạng trung bình.

Đặc trưng	LogReg	RF	CatBoost	LightGBM	Hạng TB
num_submitted_filled	1	1	1	3	1.50
avg_score_filled	5	2	4	1	3.00
num_due	4	7	3	7	5.25
total_clicks_filled	2	4	10	6	5.50
active_weeks_filled	9	3	6	4	5.50
highest_education	7	8	2	9	6.50
avg_days_early_filled	11	6	8	2	6.75
avg_weekly_clicks_filled	3	9	11	5	7.00
num_failed_filled	8	5	7	12	8.00
imd_band_filled	10	11	9	8	9.50
num_of_prev_attempts	13	12	5	11	10.25
no_submission_despite_due	6	10	15	15	11.50
studied_credits	15	13	13	10	12.75
disability	14	14	12	14	13.50
imd_missing	12	15	14	13	13.50

- **Nhóm dẫn đầu** — num_submitted_filled (số bài đã nộp) đứng hạng 1 ở cả ba mô hình cây và hạng 3 ở Logistic Regression, khẳng định đây là tín hiệu dự báo mạnh và nhất quán nhất. Theo sau là avg_score_filled (điểm trung bình) và num_due (số bài đến hạn) — cả ba đều là đặc trưng **động**, phản ánh trực tiếp mức độ tham gia và kết quả học tập tích lũy.
- **Nhóm giữa** gồm các đặc trưng tương tác VLE (total_clicks_filled, active_weeks_filled) và highest_education — đóng góp bổ sung nhưng không mang tính quyết định.
- **Nhóm cuối** — studied_credits, disability, imd_missing có hạng trung bình cao nhất (ít quan trọng nhất), cho thấy các đặc trưng tĩnh mang tính nhân khẩu học có vai trò dự báo khiêm tốn hơn nhiều so với các đặc trưng hành vi động.

3.6 Rút gọn đặc trưng: Top-10 và Top-5

Dựa trên thứ hạng ở Bảng 3.6, mười đặc trưng quan trọng nhất (Top-10) và năm đặc trưng quan trọng nhất (Top-5) được chọn ra để huấn luyện lại theo đúng quy trình tinh chỉnh đã mô tả ở Mục 3.3, nhằm kiểm tra hiệu suất mô

hình có **ổn định** hay không khi giảm số lượng đặc trưng đầu vào — một yếu tố quan trọng khi triển khai hệ thống cảnh báo thực tế, nơi việc thu thập và duy trì ít đặc trưng hơn giúp đơn giản hoá quy trình vận hành.

Bảng 3.7 và Bảng 3.8 trình bày kết quả tương ứng với hai bộ đặc trưng rút gọn.


Bảng 3.7: So sánh các mô hình sau khi rút gọn về 10 đặc trưng quan trọng nhất (Top-10).

Model	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.8536	0.7873	0.7711	0.7791	0.9157
Random Forest	0.8631	0.7966	0.7938	0.7952	0.9260
CatBoost	0.8614	0.7762	0.8235	0.7992	0.9303
LightGBM	0.8655	0.7972	0.8023	0.7997	0.9304

Bảng 3.8: So sánh các mô hình sau khi rút gọn về 5 đặc trưng quan trọng nhất (Top-5).


Model	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.8529	0.7876	0.7675	0.7775	0.9148
Random Forest	0.8700	0.8116	0.7966	0.8040	0.9279
CatBoost	0.8667	0.7979	0.8058	0.8018	0.9302
LightGBM	0.8626	0.7950	0.7945	0.7948	0.9286

Hình 3.5 tổng hợp ma trận nhầm lẫn của toàn bộ 8 tổ hợp (bộ đặc trưng $\times$ mô hình) trên cùng một lưới để tiện đối chiếu.



Hình 3.5: Ma trận nhầm lẫn của bốn mô hình trên hai bộ đặc trưng rút gọn Top-10 và Top-5 (T=180).

Hình 3.6 theo dõi sự biến động của cả năm chỉ số khi số lượng đặc trưng giảm dần từ 15 xuống 10 rồi 5.




Hình 3.6: Biến động các chỉ số hiệu suất khi giảm số lượng đặc trưng: Full(15) → Top-10 → Top-5 (T=180).

- Hiệu suất của cả bốn mô hình **rất ổn định** qua ba bộ đặc trưng — không có chỉ số nào sụt giảm đáng kể khi giảm từ 15 xuống chỉ còn 5 đặc trưng. Điều này khẳng định thêm kết luận ở Mục 3.5: phần lớn sức mạnh dự báo tập trung ở một nhóm nhỏ đặc trưng hành vi động.

- Đáng chú ý, **Random Forest** ở bộ **Top-5** đạt **F1 At-risk** cao nhất trong toàn bộ thực nghiệm (0.8040), nhỉnh hơn cả LightGBM ở bộ đặc trưng đầy đủ (0.8024). CatBoost cũng cải thiện nhẹ recall khi giảm đặc trưng (từ 0.7576 ở Full lên 0.8058 ở Top-5).
- **Logistic Regression** là mô hình duy nhất có xu hướng giảm nhẹ ở hầu hết chỉ số khi giảm đặc trưng — phù hợp với đặc tính tuyến tính đã trình bày ở Chương 1: mô hình này hưởng lợi từ việc có nhiều biến hơn để bù đắp cho khả năng nắm bắt tương tác hạn chế.

Hình 3.7 so sánh trực tiếp F1 At-risk giữa Top-10 và Top-5 cho từng mô hình.



Hình 3.7: So sánh F1 At-risk giữa bộ Top-10 và Top-5 theo từng mô hình.

Chênh lệch F1 giữa hai bộ đặc trưng rút gọn đều nhỏ hơn 0.01 ở mọi mô hình, củng cố nhận định rằng **bộ Top-5 là lựa chọn hợp lý cho triển khai thực tế**, cân bằng tốt giữa hiệu suất và chi phí thu thập/duy trì đặc trưng.

Cuối cùng, Bảng 3.9 tổng hợp siêu tham số liên quan đến xử lý mất cân bằng nhãn mà Optuna lựa chọn cho từng mô hình, ở cả ba bộ đặc trưng.

Bảng 3.9: Siêu tham số tối ưu liên quan đến xử lý mất cân bằng nhãn — tỷ lệ oversampling SMOTE và trọng số lớp At-risk — được Optuna lựa chọn cho từng mô hình và từng bộ đặc trưng, cùng F1 At-risk trung bình qua 3-fold cross-validation.

Bộ đặc trưng	Model	F1 At-risk (CV)	Tỷ lệ SMOTE	Trọng số At-risk
Full (15)	Logistic Regression	0.7918	+0.90x	1.01
	Random Forest	0.7986	+0.51x	1.10
	CatBoost	0.8074	+0.62x	1.04
	LightGBM	0.8043	+0.10x	1.46
Top-10	Logistic Regression	0.7927	+0.55x	1.05
	Random Forest	0.8008	+0.50x	1.27
	CatBoost	0.8060	+0.47x	1.79
	LightGBM	0.8042	+0.18x	1.58
Top-5	Logistic Regression	0.7887	+0.51x	1.03
	Random Forest	0.8021	+0.66x	1.03
	CatBoost	0.8069	+0.57x	1.33
	LightGBM	0.8043	+0.10x	1.46


Xu hướng chung: các mô hình cây (Random Forest, CatBoost, LightGBM) có trọng số At-risk tối ưu dao động rộng (1.03–1.79) tùy mô hình và bộ đặc trưng, trong khi Logistic Regression luôn hội tụ về trọng số gần 1.0 và tỷ lệ SMOTE tương đối cao (0.51–0.90x) — mô hình tuyến tính dựa nhiều hơn vào việc tạo thêm mẫu tổng hợp thay vì điều chỉnh trọng số lớp để xử lý mất cân bằng, nhất quán với xu hướng đã quan sát được ở Mục 3.2.

3.7 Diễn giải mô hình bằng SHAP

Để hiểu sâu hơn cơ chế ra quyết định của mô hình, phương pháp **SHAP** (SHapley Additive exPlanations) được áp dụng cho mô hình có F1 At-risk cao nhất trên bộ đặc trưng đầy đủ — **LightGBM** — trên cả ba bộ đặc trưng (Full, Top-10, Top-5) để đối chiếu mức độ nhất quán của các diễn giải khi số lượng đặc trưng thay đổi.

3.7.1 Biểu đồ tổng quan (beeswarm và mean|SHAP|)


Hình 3.8 trình bày kết quả SHAP trên bộ đặc trưng đầy đủ: biểu đồ beeswarm cho biết chiều và độ phân tán ảnh hưởng của từng đặc trưng lên từng sinh viên cụ thể, trong khi biểu đồ cột thể hiện mức độ quan trọng trung bình.




Hình 3.8: Diễn giải SHAP của LightGBM trên bộ đặc trưng đầy đủ (15 đặc trưng).

Kết quả SHAP đồng thuận cao với thứ hạng độ quan trọng đặc trưng gốc ở Bảng 3.6: `num_submitted_filled`, `avg_score_filled` và `active_weeks_filled` là ba đặc trưng có ảnh hưởng lớn nhất. Chiều tác động phù hợp với trực giác nghiệp vụ: giá trị `num_submitted_filled` và `avg_score_filled` **thấp** (màu xanh) đẩy dự báo về phía **At-risk** (SHAP dương), trong khi giá trị **cao** (màu đỏ/tím) kéo dự báo về phía Pass. Riêng `num_due` (số bài đến hạn) thể hiện chiều **ngược lại**: giá trị cao (màu đỏ) lại đẩy về phía At-risk — hợp lý vì số bài đến hạn cao đồng nghĩa với khối lượng công việc dồn lại lớn, thường đi kèm nguy cơ trễ hạn hoặc bỏ bài cao hơn.

Hình 3.9 và Hình 3.10 lặp lại phân tích trên với hai bộ đặc trưng rút gọn.



Hình 3.9: Diễn giải SHAP của LightGBM trên bộ đặc trưng Top-10.




Hình 3.10: Diễn giải SHAP của LightGBM trên bộ đặc trưng Top-5.

Thứ tự và chiều ảnh hưởng của các đặc trưng còn lại hầu như **không đổi** khi loại bỏ dần các đặc trưng ít quan trọng — một bằng chứng bổ sung cho tính ổn định của mô hình đã quan sát ở Hình 3.6, đồng thời cho thấy các đặc trưng bị loại bỏ đóng góp thông tin trùng lặp hoặc không đáng kể.

3.7.2 Diễn giải cục bộ: hai trường hợp minh họa

Để minh họa cách mô hình đưa ra quyết định ở cấp độ từng cá nhân, Hình 3.11 trình bày biểu đồ waterfall của hai sinh viên đại diện, sử dụng mô hình LightGBM trên bộ đặc trưng đầy đủ: một trường hợp bị đẩy mạnh về phía At-risk và một trường hợp bị đẩy mạnh về phía Pass.



Hình 3.11: Diễn giải cục bộ (waterfall) cho hai sinh viên đại diện.

- **Trường hợp At-risk:** sinh viên chưa nộp bài nào (`num_submitted_filled` = 0) trong khi đã có 11 bài đến hạn (`num_due` = 11) — hai yếu tố này đóng góp lần lượt +3.05 và +1.31 vào điểm số dự báo, đẩy tổng điểm lên 7.71 (rất cao so với giá trị nền -0.447), tương ứng xác suất At-risk gần như tuyệt đối.

- **Trường hợp Pass:** sinh viên có điểm trung bình cao (`avg_score_filled` = 94.68) và số tuần hoạt động nhiều (`active_weeks_filled` = 28), mỗi yếu tố kéo điểm số dự báo giảm gần 1 đơn vị, tổng hợp lại cho điểm số rất thấp (−5.92) — tương ứng xác suất Pass gần như tuyệt đối.

Hai ví dụ trên cho thấy mô hình đưa ra quyết định dựa trên những tín hiệu phù hợp với trực giác sư phạm: mức độ hoàn thành bài tập và điểm số tích lũy là yếu tố quyết định, đúng như đã được xác nhận qua phân tích độ quan trọng đặc trưng ở quy mô toàn cục.

3.8 Kết luận

Từ toàn bộ quá trình nghiên cứu — phân tích khám phá dữ liệu, cơ sở lý thuyết, xây dựng và so sánh mô hình — có thể rút ra các kết luận chính sau:

- Việc gộp nhãn Fail và Withdrawn thành nhóm At-risk và giới hạn dữ liệu về mốc dự đoán $T = 180$ đưa bài toán về dạng phân loại nhị phân, mất cân bằng nhãn ở mức vừa phải (khoảng 1 At-risk trên 2 Pass) — được xử lý hiệu quả bằng cách kết hợp SMOTE và trọng số lớp, đồng thời tinh chỉnh cả hai kỹ thuật này cùng với siêu tham số của từng mô hình thông qua Optuna.
- Trong số bốn thuật toán thử nghiệm, **LightGBM** đạt F1 At-risk cao nhất trên bộ đặc trưng đầy đủ (0.8024), trong khi **CatBoost** có ROC-AUC và precision cao nhất — hai mô hình boosting này đều vượt trội hơn Random Forest và Logistic Regression một cách nhất quán trên mọi bộ đặc trưng, đúng như dự đoán từ đặc tính lý thuyết của từng thuật toán ở Chương 1.
- Hiệu suất mô hình **ổn định cao** khi giảm số lượng đặc trưng từ 15 xuống chỉ còn 5 — thậm chí Random Forest trên bộ Top-5 đạt F1 At-risk cao nhất toàn thực nghiệm (0.8040). Kết quả này gợi ý một bộ **5 đặc trưng** (`num_submitted_filled`, `avg_score_filled`, `num_due`, `total_clicks_filled`, `active_weeks_filled`) — toàn bộ đều là đặc trưng hành vi học tập, không yêu cầu thông tin nhân khẩu học — là đủ để xây dựng một hệ thống cảnh báo sớm gọn nhẹ, dễ triển khai và duy trì.
- Phân tích SHAP xác nhận các dự báo của mô hình dựa trên những tín hiệu phù hợp với trực giác sư phạm — mức độ hoàn thành bài tập, điểm số tích lũy và khối lượng công việc còn tồn đọng — và các diễn giải này giữ nguyên tính nhất quán qua cả ba bộ đặc trưng.

Hạn chế và hướng phát triển. Nghiên cứu hiện chỉ đánh giá tại một mốc thời gian duy nhất ($T = 180$); một hướng mở rộng tự nhiên là huấn luyện và so sánh mô hình tại **nhiều mốc dự đoán** khác nhau để xác định thời điểm cảnh báo sớm nhất mà mô hình vẫn đạt độ tin cậy chấp nhận được, đồng thời theo dõi cách các dự báo về cùng một sinh viên thay đổi theo thời gian. Bên cạnh đó, việc **hiệu chỉnh ngưỡng phân loại** theo chi phí thực tế của việc bỏ sót so với cảnh báo nhầm, cũng như thử nghiệm mô hình trên dữ liệu của các cơ sở đào tạo khác, là những bước cần thiết trước khi đưa hệ thống vào vận hành thực tế.